

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

LUẬN VĂN TỐT NGHIỆP

DỰ ĐOÁN VÀ KHUYẾN NGHỊ THÀNH
TÍCH HỌC TẬP CỦA SINH VIÊN BẰNG
KIẾN TRÚC LẠI CNN-BiLSTM VÀ
CONTEXT MLP

*Predicting and Recommending Student Academic Performance using a Hybrid CNN-
BiLSTM + Context MLP Architecture*

Sinh viên thực hiện: [HỌ VÀ TÊN SINH VIÊN]

Mã số sinh viên: [MSSV]

Giảng viên hướng dẫn: [HỌ VÀ TÊN GIẢNG VIÊN]

Ngành / Chuyên ngành: [TÊN NGÀNH / CHUYÊN NGÀNH]

Thành phố Hồ Chí Minh, 2026

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP

**DỰ ĐOÁN VÀ KHUYẾN NGHỊ THÀNH
TÍCH HỌC TẬP CỦA SINH VIÊN BẰNG KIẾN
TRÚC LẠI CNN-BiLSTM VÀ CONTEXT MLP**

Giảng viên hướng dẫn: [HỌ VÀ TÊN GIẢNG VIÊN]

Sinh viên thực hiện: [HỌ VÀ TÊN SINH VIÊN]

Mã số sinh viên: [MSSV]

TP. HỒ CHÍ MINH - 2026

LỜI CẢM ƠN

Trong quá trình thực hiện khóa luận, tác giả đã nhận được sự hướng dẫn, hỗ trợ và góp ý từ giảng viên, nhà trường, gia đình và bạn bè. Tác giả xin bày tỏ lòng biết ơn sâu sắc đến giảng viên hướng dẫn [HỌ VÀ TÊN GIẢNG VIÊN], người đã định hướng phương pháp nghiên cứu, góp ý về thiết kế thực nghiệm và hỗ trợ tác giả hoàn thiện báo cáo theo chuẩn mực khoa học.

Tác giả trân trọng cảm ơn Trường Đại học Ngoại ngữ - Tin học Thành phố Hồ Chí Minh và Khoa Công nghệ Thông tin đã cung cấp môi trường học tập, nền tảng kiến thức và điều kiện cần thiết để triển khai đề tài. Tác giả cũng cảm ơn gia đình và bạn bè đã đồng hành trong suốt quá trình thu thập tài liệu, xây dựng hệ thống, thực hiện thí nghiệm và biên soạn khóa luận.

Mặc dù đã nỗ lực kiểm tra nội dung và kết quả, khóa luận khó tránh khỏi những hạn chế. Tác giả kính mong nhận được các ý kiến phản biện để tiếp tục hoàn thiện hệ thống và phương pháp nghiên cứu trong tương lai.

LỜI CAM ĐOAN

Tác giả cam đoan khóa luận này là kết quả nghiên cứu và triển khai của cá nhân dưới sự hướng dẫn của giảng viên hướng dẫn. Các kết quả thực nghiệm được trích xuất từ mã nguồn, tệp metric, tệp dự đoán và nhật ký huấn luyện trong dự án; không có số liệu đánh giá nào được tự ý tạo ra hoặc sửa đổi nhằm làm tăng kết quả.

Các tài liệu, công trình và dữ liệu tham khảo được ghi nguồn theo chuẩn IEEE. Những nội dung kế thừa từ nghiên cứu trước được diễn giải và trích dẫn rõ ràng. Tác giả chịu trách nhiệm về tính trung thực của nội dung, tính tái lập của quy trình thực nghiệm và việc sử dụng kết quả đúng mục đích học thuật.

TP. Hồ Chí Minh, tháng ... năm 2026

Sinh viên thực hiện
[HỌ VÀ TÊN SINH VIÊN]

TÓM TẮT

Nghiên cứu xây dựng hệ thống phân loại thành tích học tập theo ba mức Low, Medium và High, sau đó sinh lộ trình hỗ trợ theo luật. Mô hình gồm hai nhánh. Nhánh CNN-BiLSTM xử lý G1-G2 của hai tập Student hoặc bốn chỉ báo tương tác của xAPI. Nhánh Context MLP nhận các biến số và embedding của biến phân loại. Hai vector được ghép trước tầng dự đoán. Student-Mat và Student-Por dùng đầu ra softmax ba lớp; xAPI dùng hai logit ordinal và chuyển chúng thành xác suất của ba mức. Locked test 20% được tách trước khi tối ưu. Trong huấn luyện, validation được tách trước resampling; Student dùng ADASYN, còn xAPI dùng SMOTENC.

Trên locked test, F1-Macro đạt 0,8690 với Student-Mat, 0,8156 với Student-Por và 0,7850 với xAPI. Accuracy lần lượt là 0,8608; 0,8462; và 0,7813. So với điểm CV tốt nhất, F1 giảm 0,0345; 0,0648; và 0,0382. Student-Por có chênh lệch CV-test lớn nhất và lớp Low còn khó nhận diện. xAPI cải thiện so với lần chạy trước, nhưng Recall của lớp High chỉ đạt 0,6786. Các kết quả này được xem là kết quả của một lần phân hoạch locked test; chưa có khoảng tin cậy để kết luận về độ ổn định giữa nhiều phép chia dữ liệu.

Sau bước dự đoán, bộ luật đọc các dấu hiệu như chuyên cần, kết quả giữa kỳ, thời gian học và mức tương tác để tạo kế hoạch theo tuần. PostgreSQL lưu phiên chạy, xác suất, metric và khuyến nghị. Phần khuyến nghị mới dừng ở mức hỗ trợ cố vấn; nghiên cứu chưa đo được tác động của lộ trình đối với kết quả học tập thực tế.

Từ khóa: Educational Data Mining; dự đoán thành tích học tập; CNN-BiLSTM; Context MLP; ordinal classification; SMOTENC; ADASYN; Optuna; learning path.

ABSTRACT

This thesis develops a three-class student-performance prediction system and a rule-based learning-path module. The model combines a CNN-BiLSTM sequence branch with a context MLP using numerical variables and categorical embeddings. Student-Mat and Student-Por use a three-class softmax output, whereas xAPI uses two ordinal logits. A locked 20% test set is isolated before optimization, and validation is split before resampling. The locked-test F1-Macro scores are 0.8690 for Student-Mat, 0.8156 for Student-Por and 0.7850 for xAPI. The corresponding best-CV gaps are 0.0345, 0.0648 and 0.0382. These results describe the current experimental split and do not establish statistical significance. A deterministic rule engine produces staged recommendations, while PostgreSQL stores predictions, metrics and recommendation records.

MỤC LỤC

Mục lục sẽ được cập nhật tự động trong Microsoft Word.

DANH MỤC BẢNG

Danh mục bảng sẽ được cập nhật tự động trong Microsoft Word.

DANH MỤC HÌNH

Danh mục hình sẽ được cập nhật tự động trong Microsoft Word.

DANH MỤC TỪ VIẾT TẮT

Bảng 0.1. Danh mục từ viết tắt

Từ viết tắt	Diễn giải
CNN	Convolutional Neural Network
BiLSTM	Bidirectional Long Short-Term Memory
MLP	Multilayer Perceptron
EDM	Educational Data Mining
SMOTE	Synthetic Minority Over-sampling Technique
SMOTENC	SMOTE for Nominal and Continuous features
ADASYN	Adaptive Synthetic Sampling
CV	Cross-validation
TPE	Tree-structured Parzen Estimator
RMSE	Root Mean Squared Error
R ²	Coefficient of Determination
LMS	Learning Management System

CHƯƠNG 1. GIỚI THIỆU

1.1. Bối cảnh nghiên cứu

Chuyển đổi số trong giáo dục tạo ra lượng lớn dữ liệu về điểm số, chuyên cần, hoạt động trên hệ thống quản lý học tập, đặc điểm xã hội và mức độ tham gia của người học. Educational Data Mining và Learning Analytics sử dụng các nguồn dữ liệu này để mô tả hành vi, phát hiện rủi ro và hỗ trợ can thiệp sớm. Trong thực tế, giá trị của hệ thống không chỉ nằm ở việc dự đoán đúng nhân thành tích, mà còn ở khả năng giải thích tín hiệu rủi ro, duy trì khả năng khái quát hóa khi chuyển sang người học chưa quan sát, và chuyển kết quả dự đoán thành hành động giáo dục có thể kiểm tra.

Dữ liệu giáo dục thường đồng thời chứa hai cấu trúc. Thứ nhất là cấu trúc có thứ tự hoặc gần thời gian, chẳng hạn điểm giai đoạn G1-G2 hoặc các chỉ báo tương tác được sắp theo một quy ước nhất định. Thứ hai là dữ liệu bảng mô tả bối cảnh, chẳng hạn thời gian học, số lần trượt, hỗ trợ gia đình, loại trường, chủ đề, mức độ hài lòng và chuyên cần. Một mô hình chỉ dùng MLP có thể bỏ qua quan hệ theo thứ tự; ngược lại, một mô hình tuần tự thuần túy khó tận dụng đầy đủ các biến bối cảnh dị thể. Vì vậy, kiến trúc lai hai nhánh là lựa chọn hợp lý về mặt thiết kế.

1.2. Phát biểu bài toán

Bài toán chính là phân loại mỗi người học vào một trong ba mức thành tích Low, Medium hoặc High. Đối với Student-Mat và Student-Por, điểm cuối kỳ G3 được rời rạc hóa thành Low = 0-9, Medium = 10-14 và High = 15-20. Đối với xAPI, nhãn L, M và H có sẵn được ánh xạ thành 0, 1 và 2. Đầu ra của mô hình bao gồm nhãn dự đoán, vector xác suất ba lớp và độ tin cậy. Đầu ra của mô-đun khuyến nghị là một lộ trình theo giai đoạn, được tạo từ tổ hợp giữa lớp dự đoán, độ tin cậy và các yếu tố rủi ro quan sát được.

Các thách thức khoa học và kỹ thuật trọng yếu gồm:

CHƯƠNG 1. GIỚI THIỆU

- Mất cân bằng lớp làm Accuracy có thể che khuất chất lượng ở lớp thiểu số; do đó F1-Macro là chỉ số trung tâm.
- Dữ liệu nhỏ làm mô hình sâu nhạy với seed, lựa chọn siêu tham số và cách chia tập.
- Dữ liệu hỗn hợp số-phân loại đòi hỏi resampling giữ nguyên ngữ nghĩa của biến danh mục.
- Chuỗi Student chỉ dài hai bước G1-G2; chuỗi xAPI gồm bốn chỉ báo tổng hợp, không phải nhật ký theo timestamp.
- Kết quả CV có thể lạc quan do lựa chọn cấu hình tốt nhất trong nhiều trial; locked test phải được cô lập hoàn toàn.
- Khuyến nghị theo luật cần được phân biệt với can thiệp đã được kiểm chứng nhân quả.

1.3. Mục tiêu nghiên cứu

1. Xây dựng mô hình lai CNN-BiLSTM + Context MLP cho phân loại thành tích học tập ba lớp.
2. Thiết kế quy trình dữ liệu chống rò rỉ, bao gồm locked test, fit tiền xử lý trên train, chọn đặc trưng trong train và resampling chỉ trên train.
3. Tối ưu siêu tham số bằng Optuna và repeated stratified 5-fold CV, sau đó huấn luyện ensemble nhiều seed.
4. Đánh giá bằng Accuracy, Precision-Macro, Recall-Macro, F1-Macro, RMSE và R^2 trên locked test.
5. Phân tích chênh lệch CV-test, mất cân bằng lớp, ma trận nhầm lẫn và giới hạn năng lực biểu diễn.
6. Sinh learning path theo luật và tích hợp PostgreSQL để theo dõi toàn bộ vòng đời dự đoán.

1.4. Câu hỏi nghiên cứu

7. Kiến trúc lai có đạt F1-Macro ổn định trên ba bộ dữ liệu có cấu trúc khác nhau hay không?
8. Khoảng cách giữa CV tốt nhất và locked test phản ánh mức độ khái quát hóa như thế nào?

CHƯƠNG 1. GIỚI THIỆU

9. Mất cân bằng lớp được phản ánh ra sao trong Precision, Recall, F1 theo lớp và ma trận nhầm lẫn?
10. Những giới hạn biểu diễn nào xuất hiện khi áp dụng CNN-BiLSTM cho chuỗi rất ngắn hoặc chỉ báo tổng hợp xAPI?
11. Làm thế nào chuyển dự đoán thành lộ trình học tập có thể truy vết mà không tuyên bố quá mức về hiệu quả can thiệp?

1.5. Phạm vi và đóng góp

Nghiên cứu giới hạn ở ba bộ dữ liệu công khai Student-Mat, Student-Por và xAPI-Edu-Data; nhiệm vụ đầu ra là phân loại ba lớp. Kiến trúc được giới hạn ở CNN, BiLSTM, attention pooling, MLP và fusion dense. Hệ thống không sử dụng Transformer, DeepFM, DCN-V2 hoặc tìm kiếm phản thực tế trong mô hình chính. Đóng góp thực hành nằm ở một pipeline end-to-end tái lập được, tách locked test, lưu metric và dự đoán, sinh khuyến nghị theo luật và cung cấp schema PostgreSQL. Đóng góp khoa học nằm ở việc đánh giá nghiêm ngặt chênh lệch CV-test và công khai các giới hạn của dữ liệu, biểu diễn và giao thức.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ BỐI CẢNH NGHIÊN CỨU

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ BỐI CẢNH NGHIÊN CỨU

2.1. Educational Data Mining và dự đoán thành tích

Educational Data Mining nghiên cứu các phương pháp khai phá mẫu từ dữ liệu giáo dục để hỗ trợ hiểu biết về người học và quá trình học. Bộ Student Performance của UCI được xây dựng từ dữ liệu trường trung học Bồ Đào Nha và thường được dùng để dự đoán điểm G3 từ đặc điểm cá nhân, gia đình, nhà trường và điểm các giai đoạn trước [1]. xAPI-Edu-Data được thu thập từ môi trường Kalboard 360, nhấn mạnh các thuộc tính hành vi như raisedhands, VisITedResources, AnnouncementsView và Discussion [2]. Hai họ dữ liệu đại diện cho hai tình huống: dự đoán dựa mạnh vào lịch sử điểm và dự đoán dựa trên tương tác LMS cùng bối cảnh.

2.2. CNN cho quan hệ cục bộ

Convolution một chiều áp dụng bộ lọc trượt trên trục thứ tự để học các mẫu cục bộ. Với đầu vào X thuộc $\mathbb{R}^{(T \times C)}$, một kênh đầu ra tại vị trí t có thể được mô tả khái quát bởi $h_t = \sigma(W * X_{(t:t+k-1)} + b)$. Trong hệ thống, Conv1D được theo sau bởi BatchNorm, ReLU và Dropout. Vai trò dự kiến là tái mã hóa sự kết hợp cục bộ giữa các mốc điểm hoặc chỉ báo tương tác trước khi đưa vào BiLSTM. Tuy nhiên, khi T chỉ bằng 2 hoặc 4, không gian mẫu cục bộ rất hạn chế; đây là một giới hạn cần được đánh giá thay vì mặc định rằng CNN luôn mang lại lợi ích.

2.3. LSTM và BiLSTM

LSTM sử dụng các cổng vào, quên và đầu ra để điều khiển dòng thông tin qua trạng thái ô nhớ, qua đó giảm khó khăn gradient suy giảm trong RNN truyền thống [3]. BiLSTM mở rộng bằng hai hướng xử lý: hướng thuận và hướng nghịch; biểu diễn tại mỗi vị trí là phép ghép hai trạng thái [4]. Trong bài toán này, BiLSTM không được dùng để dự báo tương lai theo thời gian thực, mà để mã hóa toàn bộ chuỗi đầu

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ BỐI CẢNH NGHIÊN CỨU

vào đã quan sát trước thời điểm dự đoán. Vì vậy, điều kiện triển khai là mọi phần tử của chuỗi phải sẵn có tại thời điểm suy luận, tránh rò rỉ thông tin tương lai.

2.4. Context MLP và fusion

Nhánh Context MLP nhận biến số sau chuẩn hóa Min-Max và embedding của các biến phân loại. Vector context đi qua hai tầng tuyến tính với ReLU và Dropout, sau đó được ghép với vector chuỗi từ attention pooling. Hai tập Student dùng classifier ba lớp. xAPI dùng hai logit biểu diễn xác suất vượt qua hai ngưỡng thứ tự.

2.5. Xử lý mất cân bằng

SMOTE tạo mẫu tổng hợp từ các láng giềng lớp thiểu số [5], còn ADASYN tập trung nhiều hơn vào vùng khó phân loại [6]. Phiên bản hiện tại dùng ADASYN cho hai tập Student và SMOTENC cho xAPI. SMOTENC nội suy biến số nhưng xử lý biến danh mục theo cơ chế riêng, phù hợp hơn SMOTE thông thường đối với dữ liệu hỗn hợp.

2.6. Optuna và tối ưu siêu tham số


Optuna dùng TPE và MedianPruner để tìm siêu tham số [7]. Phiên bản hiện tại đánh giá mỗi trial bằng Repeated Stratified 5-fold CV với ba lần lặp trên train pool. Điểm tốt nhất dùng để chọn cấu hình, còn locked test chỉ được dùng sau khi cấu hình đã cố định.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

3.1. Quy trình nghiên cứu tổng thể

12. Nạp dữ liệu gốc và chuyển nhãn về bài toán ba lớp.
13. Tách stratified locked test 20% với random seed 42 trước tối ưu.
14. Trong từng fold CV: feature engineering, fit encoder/scaler trên train fold, resampling train fold, chọn đặc trưng trên train fold và transform validation fold.
15. Optuna tối đa hóa F1-Macro của repeated stratified 5-fold CV với ba lần lặp.
16. Tách validation trước resampling trong từng seed, huấn luyện ensemble và trung bình hóa xác suất.
17. Đánh giá locked test một lần, xuất metric, dự đoán, feature importance và learning path.
18. Ghi phiên chạy, dự đoán, metric và khuyến nghị vào PostgreSQL trong một giao dịch.



Dự đoán → phân tích rủi ro theo luật → lộ trình học tập → lưu PostgreSQL

Hình 3.1. Quy trình tổng thể của hệ thống dự đoán và khuyến nghị

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.


3.2. Kiến trúc hai nhánh

Bảng 3.1. Cấu trúc chức năng của mô hình lai

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

Khối	Đầu vào	Phép biến đổi	Đầu ra
Nhánh tuần tự	G1-G2 hoặc 4 chỉ báo xAPI	Conv1D → BatchNorm → ReLU → Dropout → BiLSTM → Attention Pooling	Vector chuỗi 2h
Nhánh bối cảnh	Biến số và biến phân loại	Min-Max cho biến số; embedding cho biến phân loại; MLP hai tầng	Vector context
Fusion	Vector chuỗi + context	Concatenate → Linear → ReLU → Dropout	Vector hợp nhất
Đầu ra	Vector hợp nhất	Student: 3 logits; xAPI: 2 logits ordinal	P(Low), P(Medium), P(High)

Kiến trúc CNN-BiLSTM + Context MLP



Hình 3.2. Kiến trúc nội bộ CNN-BiLSTM + Context MLP

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

3.3. Nhánh CNN-BiLSTM

Tensor đầu vào tuần tự có dạng $\text{batch} \times T \times 1$. Trước Conv1D, tensor được chuyển thành $\text{batch} \times 1 \times T$. Conv1D dùng padding bằng $\text{floor}(\text{kernel}/2)$, vì vậy giữ gần nguyên chiều dài đối với kernel lẻ. Đầu ra được chuyển về $\text{batch} \times T \times \text{channels}$ và đưa qua LSTM hai chiều. Nếu kích thước ẩn mỗi hướng là h , đầu ra tại mỗi bước có kích thước $2h$. AttentionPooling1D học một điểm số vô hướng cho từng bước, chuẩn hóa bằng softmax và tính tổng có trọng số để thu vector chuỗi.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

Với Student-Mat và Student-Por, $T = 2$ tương ứng G1 và G2. Với xAPI, $T = 4$ tương ứng raisedhands, VisITedResources, AnnouncementsView và Discussion. Cần nhấn mạnh rằng bốn biến xAPI là các tổng hợp hành vi theo thuộc tính, không phải chuỗi sự kiện có timestamp. Do đó, thuật ngữ 'sequential branch' mô tả cách tensor được xử lý trong mô hình hơn là khẳng định dữ liệu xAPI là time series chuẩn.

3.4. Nhánh Context MLP

Nhánh bối cảnh loại các cột đã đưa vào nhánh tuần tự. Biến số được chuẩn hóa Min-Max. Biến phân loại được Label Encoding để tạo chỉ số, sau đó đi qua embedding riêng cho từng cột. Các embedding được ghép với biến số và đưa qua MLP hai tầng. Cách này tránh xem mã danh mục như một đại lượng liên tục.

3.5. Hàm mất mát và ensemble


Student-Mat và Student-Por dùng Weighted Cross-Entropy. xAPI được mô hình hóa theo thứ tự Low < Medium < High bằng hai ngưỡng và BCEWithLogitsLoss. Hai xác suất vượt ngưỡng được đổi thành ba xác suất lớp trước khi lấy argmax. Adam, ReduceLROnPlateau, early stopping và SWA được dùng trong quá trình huấn luyện. Kết quả cuối là trung bình xác suất của các mô hình theo seed; thư mục checkpoint hiện có 5 seed cho mỗi tập Student và 11 seed cho xAPI.

3.6. Rule-based Learning Path Engine

Bộ máy khuyến nghị không thay đổi dự đoán của mạng nơ-ron. Nó đọc feature gốc, lớp dự đoán và confidence để phát hiện RiskFactor có mã, tiêu đề, bằng chứng và mức ưu tiên. Với dữ liệu Student, luật xét số buổi vắng, tỷ lệ vắng/thời gian học, số lần trượt, G1-G2, studytime, Dalc+Walc và goout. Với xAPI, luật xét StudentAbsenceDays, VisITedResources, raisedhands, Discussion, AnnouncementsView, ParentAnsweringSurvey và ParentschoolSatisfaction.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

Quy trình sinh lộ trình học tập



Hình 3.3. Luồng xử lý của Rule-based Learning Path Engine

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

Bảng 3.2. Ví dụ ánh xạ luật sang learning path

Nhóm rủi ro	Ví dụ điều kiện	Hành động điển hình	Giai đoạn
Chuyên cần	absences ≥ 10 ; hoặc Above-7	Xác minh nguyên nhân, học bù, theo dõi chuyên cần	Tuần 1
Lỗi hỏng kiến thức	failures > 0 ; G2 < 10 ; G2 $< G1$	Bài chẩn đoán, học lại chủ đề yếu, bài luyện có phản hồi	Tuần 1-2
Sử dụng học liệu	VisITedResources < 40	Truy cập LMS ≥ 4 ngày/tuần, hoàn thành tài nguyên trọng tâm	Tuần 1-2
Tương tác lớp	raisedhands < 30 hoặc Discussion < 30	Đặt câu hỏi, phản hồi, tham gia thảo luận	Tuần 2-4
Quản lý thời gian	studytime thấp; goout cao	Tăng giờ tự học có kế hoạch, điều chỉnh lịch	Tuần 2-4
Gia đình-nhà trường	Khảo sát phụ huynh = No; hài lòng = Bad	Báo cáo tiến độ và thống nhất mục tiêu tuần	Trong 2 tuần

Về bản chất, learning path là khuyến nghị có thể kiểm toán: mỗi hành động liên kết với một tín hiệu đầu vào cụ thể. Tuy nhiên, các ngưỡng là heuristic miễn ứng dụng; chưa có thử nghiệm ngẫu nhiên hoặc nghiên cứu người dùng chứng minh rằng lộ trình làm tăng điểm số. Vì vậy, hệ thống phải được triển khai như công cụ hỗ trợ cố vấn, không phải cơ chế tự động ra quyết định kỷ luật hoặc phân luồng có hệ quả cao.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU

CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU


4.1. Mô tả bộ dữ liệu

Bảng 4.1. So sánh ba bộ dữ liệu

Bộ dữ liệu	Số mẫu	Số cột gốc	Đích	Chuỗi mô hình	Nguồn thông tin chính
Student-Mat	395	33	G3 $\rightarrow$ 3 lớp	G1, G2	Điểm, cá nhân, gia đình, trường học
Student-Por	649	33	G3 $\rightarrow$ 3 lớp	G1, G2	Điểm, cá nhân, gia đình, trường học
xAPI-Edu-Data	480	17	Class L/M/H	4 chỉ báo hành vi	Nhân khẩu, học phần, phụ huynh, tương tác LMS

Student-Mat và Student-Por có cùng schema 33 cột, khác môn học. G3 là điểm cuối kỳ trên thang 0-20. xAPI có 17 cột, trong đó Class là nhãn; các biến hành vi chính có thang đếm 0-100. Không có tuyên bố rằng ba tập đại diện cho cùng quần thể. Vì vậy, so sánh metric giữa tập chỉ mang tính mô tả năng lực của pipeline trên ba bối cảnh, không phải kiểm định trực tiếp bộ dữ liệu nào 'dễ' hay 'khó' nếu chưa kiểm soát phân bố và nhiễu nhãn.

Phân bố lớp trong locked test




CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU

Hình 4.1. Phân bố lớp trong ba tập locked test

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

4.2. Tách dữ liệu và chống rò rỉ

Mỗi tập được tách stratified thành train pool 80% và locked test 20% bằng seed 42. Locked test có 79 mẫu Student-Mat, 130 mẫu Student-Por và 96 mẫu xAPI. Tập này không tham gia Optuna, fit bộ tiền xử lý, chọn đặc trưng hoặc chọn epoch. Trong CV và trong từng seed ensemble, validation được tách trước khi fit tiền xử lý và resampling.



Hình 4.2. Giao thức tách dữ liệu và kiểm soát rò rỉ

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

Ở giai đoạn ensemble, train pool được chia train-validation theo từng seed. Bộ tiền xử lý, resampling và feature selector chỉ fit trên phần train của seed đó; validation và locked test chỉ được transform. Thay đổi này loại bỏ hạn chế tách validation sau resampling của phiên bản trước.

4.3. Feature engineering

Các đặc trưng dẫn xuất được tạo theo quy tắc xác định trước:

- Student: $\text{grade_growth} = G2 - G1$; $\text{grade_avg} = (G1 + G2) / 2$; $\text{absence_study_ratio}$; failure_risk ; alcohol_risk ; social_risk .

CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU

- xAPI: engagement_score; absence_risk; parent_support_signal; hands_resource_ratio; active_participation; resource_engagement_ratio.

Một lưu ý khoa học quan trọng là grade_avg và grade_growth được suy ra trực tiếp từ G1-G2, vốn đồng thời được đưa vào nhánh tuần tự. Điều này làm tăng tính lặp thông tin giữa hai nhánh, có thể giúp tối ưu nhưng cũng làm khó tách riêng đóng góp của CNN-BiLSTM và MLP. Cần ablation để xác định lợi ích độc lập của từng nhánh.

4.4. Chuẩn hóa, mã hóa và chọn đặc trưng

Biến số được Min-Max scaling. Biến phân loại được Label Encoding để tạo chỉ số embedding; giá trị chưa thấy ở validation hoặc test ánh xạ về 0. FeatureSelector dùng Pearson cho biến số và Chi-square cho biến phân loại với p-value < 0,1; các biến chuỗi luôn được giữ. Đây là bước lọc kỹ thuật, không phải kiểm định quan hệ nhân quả.

4.5. Xử lý mất cân bằng

Student-Mat và Student-Por dùng ADASYN. Với xAPI, cấu hình 'smote' được triển khai bằng SMOTENC vì dữ liệu có cả biến số và biến phân loại. Sampling ratio và số láng giềng do Optuna chọn. Trọng số lớp vẫn được tính từ nhãn train gốc cho hai tập Student; xAPI dùng BCE trên hai ngưỡng ordinal. Chưa có ablation để tách đóng góp của từng thành phần.

Giới hạn dữ liệu: Cần ablation trong cùng dataset để so sánh không resampling, ADASYN, SMOTENC và class weighting.

4.6. Optuna và cấu hình huấn luyện

Student-Mat và Student-Por dùng kết quả tìm kiếm 50 trial. Cơ sở dữ liệu Optuna xAPI hiện lưu 100 trial; trial tốt nhất đạt F1-Macro CV 0,823258 và có đúng bộ tham số dùng cho lần huấn luyện cuối. Mỗi trial dùng Repeated Stratified 5-fold CV với ba lần lặp. Mã nguồn hiện đặt mục tiêu tối đa 250 trial cho xAPI, nhưng báo cáo này chỉ ghi nhận 100 trial đã có trong cơ sở dữ liệu.

Bảng 4.2. Thiết lập tối ưu siêu tham số

CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU

Thành phần	Student-Mat	Student-Por	xAPI
Số trial đã ghi nhận	50	50	100
CV	Repeated 5-fold $\times$ 3	Repeated 5-fold $\times$ 3	Repeated 5-fold $\times$ 3
Epoch tối đa/trial	50	50	80
Early stopping patience	15	15	25
Sampler	TPE	TPE	TPE đa biến
Pruner	MedianPruner	MedianPruner	MedianPruner
Mục tiêu	F1-Macro trung bình	F1-Macro trung bình	F1-Macro trung bình

Bảng 4.3. Siêu tham số tốt nhất được dùng trong báo cáo chính thức

Siêu tham số	Student-Mat	Student-Por	xAPI
Learning rate	0,00285449	0,00223983	0,00240941
Weight decay	$3,2425 \times 10^{-4}$	$1,2372 \times 10^{-5}$	$1,6526 \times 10^{-5}$
Batch size	16	16	8
Resampling	ADASYN	ADASYN	SMOTENC
Sampling ratio	0,5238	0,4090	0,4331
k-neighbors	5	5	9
CNN channels	64	64	32
CNN kernel	3	3	3
BiLSTM hidden	64	32	96
Context hidden	32	128	256
Fusion hidden	64	128	128
Embedding dim	Tự động	Tự động	3
Dropout	0,1382 chung	0,3018 chung	0,2673 / 0,3829 / 0,2553

4.7. Chỉ số đánh giá

Accuracy là tỷ lệ dự đoán đúng. $\text{Precision}_k = \text{TP}_k / (\text{TP}_k + \text{FP}_k)$, $\text{Recall}_k = \text{TP}_k / (\text{TP}_k + \text{FN}_k)$, và F1_k là trung bình điều hòa của Precision_k và Recall_k . F1-Macro là trung bình không trọng số của F1 trên ba lớp, nên mỗi lớp có đóng góp ngang nhau bất kể support. RMSE được tính trên mã lớp thứ tự 0-1-2; R^2 so sánh sai số bình phương với phương sai nhãn. Vì phân loại là nhiệm vụ chính, F1-Macro là

CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU

metric quyết định; RMSE và R^2 chỉ được dùng như chỉ số phụ phản ánh độ xa thứ tự giữa nhãn dự đoán và nhãn thật.

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

5.1. Nguyên tắc đánh giá

Chương này dùng các tệp metrics, predictions và final report không có hậu tố phiên bản, vì đây là nhóm tệp được cập nhật gần nhất. Riêng final report của xAPI ghi CV F1 bằng 0 do lần chạy cuối nạp tham số từ JSON nhưng JSON không lưu `\_best\_value`. Giá trị CV dùng trong phân tích là 0,823258 lấy từ cơ sở dữ liệu Optuna; bộ tham số của trial tốt nhất trùng với bộ tham số của mô hình cuối.


5.2. Kết quả locked test tổng hợp

Bảng 5.1. Metric locked-test cuối cùng

Dataset	Accuracy	Precision-Macro	Recall-Macro	F1-Macro	RMSE	R ²
Student-Mat	0,8608	0,8600	0,8995	0,8690	0,3731	0,7213
Student-Por	0,8462	0,7967	0,8394	0,8156	0,3922	0,5626
xAPI	0,7813	0,7940	0,7879	0,7850	0,4677	0,6108

Student-Mat có F1-Macro cao nhất, đạt 0,8690. Student-Por đạt 0,8156; chênh lệch giữa Accuracy và F1-Macro cho thấy lớp Medium chiếm ưu thế vẫn ảnh hưởng kết quả tổng hợp. xAPI đạt F1-Macro 0,7850. RMSE của xAPI là 0,4677 và không còn cao hơn quá xa hai tập Student, nhưng phân tích theo lớp cho thấy mô hình vẫn bỏ sót nhiều mẫu High.

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC



Hình 5.1. So sánh các metric phân loại trên locked test

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

5.3. CV so với locked test


Bảng 5.2. So sánh F1-Macro CV và locked test

Dataset	Optuna best CV F1	Locked-test F1	Chênh lệch CV-Test	Tỷ lệ giữ lại
Student-Mat	0,9035	0,8690	0,0345	96,18%
Student-Por	0,8804	0,8156	0,0648	92,64%
xAPI	0,8233	0,7850	0,0382	95,35%

Điểm locked test đều thấp hơn điểm CV tốt nhất. Student-Por giảm 0,0648, lớn nhất trong ba tập. Student-Mat giảm 0,0345 và xAPI giảm 0,0382. Như vậy, lần chạy mới không còn cho thấy xAPI có khoảng cách tổng quát hóa lớn nhất; vấn đề rõ hơn nằm ở Student-Por.

Không có tập nào sụt giảm đến mức mất hoàn toàn khả năng dự đoán, nhưng khoảng giảm 6,48 điểm phần trăm của Student-Por là đáng lưu ý. Do chỉ có một locked split và chưa có bootstrap confidence interval, báo cáo không dùng kết quả này để khẳng định mô hình không overfit.

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC



Hình 5.2. So sánh F1-Macro giữa cross-validation và locked test

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

Giới hạn dữ liệu: Cần lưu mean và standard deviation của 15 fold lặp, đồng thời tính bootstrap confidence interval cho locked-test F1.

Giới hạn dữ liệu: Cần train/validation loss và F1 theo epoch của từng seed để đánh giá trực tiếp divergence, thời điểm early stopping và overfitting động.

5.4. Phân tích theo lớp và ma trận nhầm lẫn

Bảng 5.3. Metric theo lớp từ classification report

Dataset	Lớp	Precision	Recall	F1	Support
Student-Mat	Low	0,78	0,96	0,86	26
Student-Mat	Medium	0,97	0,74	0,84	38
Student-Mat	High	0,83	1,00	0,91	15
Student-Por	Low	0,65	0,75	0,70	20
Student-Por	Medium	0,91	0,85	0,88	84
Student-Por	High	0,83	0,92	0,87	26
xAPI	Low	0,77	0,92	0,84	26
xAPI	Medium	0,74	0,76	0,75	42
xAPI	High	0,86	0,68	0,76	28

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

Student-Mat nhận đúng toàn bộ 15 mẫu High và 25/26 mẫu Low. Trong 38 mẫu Medium, 7 mẫu bị hạ xuống Low và 3 mẫu bị nâng lên High; Recall Medium vì vậy chỉ còn 0,74. Student-Por nhận đúng 71/84 mẫu Medium. Lớp Low có F1 thấp nhất, bằng 0,70, do chỉ nhận đúng 15/20 mẫu và có thêm 8 mẫu Medium bị dự đoán thành Low.

xAPI nhận đúng 24/26 mẫu Low và 32/42 mẫu Medium. Lớp High có Precision 0,86 nhưng Recall chỉ 0,68 vì 9/28 mẫu bị dự đoán thành Medium. Không có lỗi trực tiếp giữa Low và High; phần lớn sai số nằm giữa hai mức kề nhau.

Bảng 5.4. Ma trận nhầm lẫn Student-Mat

Thật / Dự đoán	Low	Medium	High
Low	25	1	0
Medium	7	28	3
High	0	0	15

Bảng 5.5. Ma trận nhầm lẫn Student-Por

Thật / Dự đoán	Low	Medium	High
Low	15	5	0
Medium	8	71	5
High	0	2	24

Bảng 5.6. Ma trận nhầm lẫn xAPI

Thật / Dự đoán	Low	Medium	High
Low	24	2	0
Medium	7	32	3
High	0	9	19


CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

Ma trận nhầm lẫn trên locked test

Hàng: nhãn thật; cột: nhãn dự đoán

Student-Mat				Student-Por				xAPI			
	Low	Medium	High		Low	Medium	High		Low	Medium	High
Low	25	1	0	Low	15	5	0	Low	24	2	0
Medium	7	28	3	Medium	8	71	5	Medium	7	32	3
High	0	0	15	High	0	2	24	High	0	9	19

Hình 5.3. Ma trận nhầm lẫn của ba bộ dữ liệu
Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.



Hình 5.4. F1-score theo từng lớp Low, Medium và High
Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

5.5. Đánh giá xử lý mất cân bằng

Phân bố locked test là 26/38/15 với Student-Mat, 20/84/26 với Student-Por và 26/42/28 với xAPI. Student-Por lệch lớp mạnh nhất. Trên tập này, Recall Low giảm

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

còn 0,75, trong khi Recall High đạt 0,92. Weighted-F1 là 0,8483 nhưng Macro-F1 chỉ 0,8156, cho thấy kết quả của lớp Low bị che bớt khi dùng trung bình theo support.

Student-Mat và Student-Por dùng ADASYN; xAPI dùng SMOTENC. Kết quả giữa các dataset không thể dùng để kết luận phương pháp resampling nào tốt hơn. Muốn so sánh cần giữ nguyên dataset, seed, kiến trúc và không gian siêu tham số.


5.6. Giới hạn năng lực và biểu diễn trên xAPI

xAPI đạt best CV F1 0,8233 và locked-test F1 0,7850. Cấu hình được chọn gồm CNN 32 kênh, BiLSTM hidden 96, Context MLP 256 và Fusion 128. Đây vẫn là cấu hình lớn so với cỡ mẫu 480, nhưng khoảng cách CV-test chỉ 0,0382. Kết quả không cho thấy cần tiếp tục tăng kích thước mạng một cách đơn thuần.

Hai hạn chế còn lại nằm ở dữ liệu. Bốn chỉ báo raisedhands, VisITedResources, AnnouncementsView và Discussion là số tổng hợp, không phải chuỗi sự kiện theo thời gian. Ngoài ra, nhãn chỉ có ba mức rộng nên các trường hợp gần ranh giới Medium-High có thể có hành vi tương tự. Phiên bản mới đã dùng embedding và SMOTENC, vì vậy hai nhược điểm mã hóa danh mục và nội suy danh mục của phiên bản trước đã được giảm bớt.

Ma trận nhầm lẫn vẫn cho thấy ranh giới Medium-High là phần khó nhất: 9/28 mẫu High bị hạ xuống Medium và 3/42 mẫu Medium bị nâng lên High. Việc dùng ordinal head giúp phản ánh thứ tự lớp, nhưng chưa giải quyết được sự chồng lấn của dữ liệu đầu vào.

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC



Hình 5.5. Permutation feature importance trên ba bộ dữ liệu

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

Permutation importance của lần chạy mới gần như bằng 0 trên Student-Mat và xAPI. Vì vậy, báo cáo không dùng kết quả này để xếp hạng nguyên nhân hoặc tuyên bố đặc trưng nào quan trọng nhất.


Giới hạn dữ liệu: Cần ablation xAPI gồm Context MLP-only, CNN-BiLSTM-only, hybrid và ordinal head so với softmax ba lớp.

5.7. Diễn giải RMSE và R^2

R^2 đạt 0,7213 trên Student-Mat, 0,5626 trên Student-Por và 0,6108 trên xAPI. RMSE lần lượt là 0,3731; 0,3922; và 0,4677. Hai chỉ số này dùng mã lớp 0-1-2 nên giả định khoảng cách giữa Low-Medium và Medium-High là như nhau. Vì vậy, chúng chỉ bổ sung cho F1-Macro, không thay thế metric phân loại.

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

5.8. Những đánh giá chưa thể kết luận



Hình 5.6. Phân bố độ tin cậy của dự đoán ensemble

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

Giới hạn dữ liệu: Không có confidence interval hoặc kiểm định paired bootstrap để kết luận khác biệt giữa ba dataset/model có ý nghĩa thống kê.

Giới hạn dữ liệu: Không có Brier score, Expected Calibration Error hoặc reliability diagram để đánh giá xác suất/confidence có được hiệu chỉnh hay không.

Giới hạn dữ liệu: Không có metric fairness theo giới tính, trường, quốc tịch hoặc nhóm xã hội; không được tuyên bố mô hình công bằng.

Giới hạn dữ liệu: Không có external validation trên cơ sở giáo dục khác; kết quả hiện chỉ dựa trên một locked split của mỗi dataset công khai.

Giới hạn dữ liệu: Không có thử nghiệm người dùng hoặc A/B test để đánh giá learning path cải thiện kết quả học tập.

5.9. Kết luận khoa học của chương

Trong lần chạy mới, Student-Mat đạt F1-Macro cao nhất. Student-Por có khoảng cách CV-test lớn nhất và lớp Low là điểm yếu chính. xAPI tăng lên 0,7850, nhưng Recall High còn thấp. Embedding, SMOTENC và ordinal head đã sửa một số

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

hạn chế kỹ thuật của phiên bản trước; phần còn lại chủ yếu liên quan đến cỡ mẫu, chuỗi đầu vào ngắn và thiếu dữ liệu theo thời gian.

CHƯƠNG 6. THẢO LUẬN VÀ TRIỂN KHAI THỰC TIỄN

CHƯƠNG 6. THẢO LUẬN VÀ TRIỂN KHAI THỰC TIỄN

6.1. Ý nghĩa thực tiễn của dự đoán


Một hệ thống dự đoán giáo dục hữu ích phải hỗ trợ ưu tiên nguồn lực chứ không thay thế đánh giá chuyên môn. Người học dự đoán Low hoặc có risk factor ưu tiên 1 có thể được đưa vào danh sách cố vấn xem xét. Người học Medium có confidence thấp cần được xem là trường hợp không chắc chắn, không phải nhãn cố định. Người học High vẫn có thể nhận khuyến nghị nếu xuất hiện rủi ro chuyên cần hoặc suy giảm G2 so với G1.

6.2. Vận hành Learning Path

19. Mô hình tạo nhãn, xác suất và confidence cho từng người học.
20. Rule engine đọc feature snapshot và tạo danh sách risk factor có bằng chứng.
21. Risk band được xác định từ lớp dự đoán và mức ưu tiên rủi ro.
22. Các hành động được sắp theo Tuần 1, Tuần 1-2, Tuần 2-4 và kiểm tra cuối tuần.
23. Cố vấn xác nhận tính phù hợp, điều chỉnh mục tiêu và ghi nhận việc thực hiện.
24. Dữ liệu theo dõi mới được đưa vào lần đánh giá sau để so sánh xu hướng.

Trong vận hành, mỗi khuyến nghị cần có trạng thái proposed, accepted, modified, completed hoặc rejected; người thực hiện; ngày bắt đầu; ngày đánh giá; và outcome. Schema hiện tại lưu recommended_learning_path dưới dạng JSONB nhưng chưa có bảng sự kiện thực thi chi tiết. Đây là hướng mở rộng cần thiết để biến hệ thống từ máy sinh khuyến nghị thành nền tảng theo dõi can thiệp.

CHƯƠNG 6. THẢO LUẬN VÀ TRIỂN KHAI THỰC TIỄN



Hình 6.1. Phân bố risk band do Learning Path Engine tạo ra

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

6.3. Tích hợp PostgreSQL


Bảng 6.1. Vai trò các bảng PostgreSQL

Bảng	Mục đích	Trường quan trọng
paper_runs	Quản lý phiên chạy	generated_at, status, run_payload
paper_predictions	Lưu dự đoán locked test hoặc production	true/pred label, probability, confidence, original_features, seed
paper_evaluation_metrics	Lưu metric theo dataset và protocol	accuracy, precision_macro, recall_macro, f1_macro, rmse, r2
paper_learning_recommendations	Lưu risk và learning path	risk_band, feature_snapshot, recommended_learning_path
students / student_grades	Liên kết hồ sơ và điểm nguồn	dataset_name, source_row_index, G1, G2, G3, target_class

Việc lưu `original_features` và `probability` cho phép kiểm toán sau này: có thể tái tạo đầu vào, kiểm tra drift, xem confidence và đối chiếu learning path. Giao dịch ghi dữ liệu cần bảo đảm atomicity để tránh tồn tại prediction mà thiếu metric hoặc recommendation. Trong môi trường thật, cần bổ sung `model_version`, `preprocessing_version`, `feature_schema_version`, consent status, retention policy và audit log.

CHƯƠNG 6. THẢO LUẬN VÀ TRIỂN KHAI THỰC TIỄN

Các bảng PostgreSQL dùng để lưu kết quả



Hình 6.2. Quan hệ giữa các bảng lưu trữ PostgreSQL

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

6.4. Kiến trúc triển khai đề xuất

- Batch scoring định kỳ cho Student-Mat/Por khi có điểm G1-G2 mới.
- API scoring cho LMS khi chỉ báo xAPI được cập nhật.
- Model registry lưu trọng số, tham số, code commit và metric phê duyệt.
- Dashboard cố vấn hiển thị xác suất, risk factor và lộ trình; không chỉ hiển thị nhãn.
- Monitoring theo dõi phân bố feature, tỷ lệ lớp dự đoán, calibration và metric khi có nhãn thật.
- Cơ chế human-in-the-loop bắt buộc đối với mọi quyết định có ảnh hưởng đến người học.

6.5. Rủi ro đạo đức và quản trị

Dữ liệu học tập chứa thông tin nhạy cảm về kết quả, hành vi và bối cảnh gia đình. Hệ thống cần tuân thủ nguyên tắc tối thiểu hóa dữ liệu, phân quyền theo vai trò, mã hóa khi lưu và truyền, giới hạn thời gian lưu, và ghi log truy cập. Người học cần được thông báo mục đích sử dụng dữ liệu và có cơ chế phản hồi khi dự đoán sai. Không nên dùng nhãn Low để từ chối cơ hội học tập hoặc tạo kỳ vọng tiêu cực.

CHƯƠNG 6. THẢO LUẬN VÀ TRIỂN KHAI THỰC TIỄN

Các thuộc tính như giới tính, quốc tịch, trường hoặc quan hệ phụ huynh có thể trở thành proxy cho bất bình đẳng xã hội. Do chưa có fairness audit, triển khai thực tế phải tạm giới hạn vai trò của mô hình ở sàng lọc hỗ trợ, đồng thời đo performance theo nhóm trước khi mở rộng. Rule engine cũng cần được hội đồng chuyên môn phê duyệt ngưỡng và nội dung khuyến nghị.

6.6. Hạn chế của nghiên cứu

- Cỡ mẫu nhỏ làm metric nhảy với cách chia tập và seed.
- Chuỗi đầu vào quá ngắn; xAPI không có nhật ký thời gian thực trong dữ liệu hiện dùng.
- Chuỗi xAPI gồm các chỉ báo tổng hợp được đặt theo thứ tự quy ước, không phải nhật ký sự kiện có timestamp.
- Kết quả permutation importance của lần chạy mới phần lớn bằng 0 nên chưa hỗ trợ diễn giải đặc trưng.
- Thiếu ablation định lượng đóng góp của CNN, BiLSTM, attention, MLP, feature engineering và xử lý mất cân bằng.
- Thiếu khoảng tin cậy, calibration, fairness, external validation và kiểm định drift.
- Learning path dựa trên luật chuyên gia, chưa có bằng chứng nhân quả hoặc đánh giá người dùng.
- RMSE/ R^2 trên mã lớp chỉ có ý nghĩa phụ thuộc giả định ordinal.

CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1. Kết luận

Luận văn xây dựng pipeline dự đoán ba mức thành tích và sinh lộ trình hỗ trợ theo luật. Mô hình kết hợp CNN-BiLSTM với Context MLP, categorical embedding và attention pooling. Phiên bản mới bổ sung đầu ra ordinal cho xAPI, SMOTENC cho dữ liệu hỗn hợp và tách validation trước resampling trong từng seed.

F1-Macro trên locked test đạt 0,8690 với Student-Mat, 0,8156 với Student-Por và 0,7850 với xAPI. Student-Por có chênh lệch CV-test lớn nhất, bằng 0,0648. Với xAPI, lớp High có Recall 0,6786 và là điểm cần cải thiện. Kết quả mới tốt hơn trên xAPI nhưng thấp hơn trên hai tập Student so với lần chạy trước; báo cáo giữ nguyên các giá trị mới thay vì chọn phiên bản có metric cao hơn.

Bộ luật chuyển risk factor thành kế hoạch theo tuần, còn PostgreSQL lưu dự đoán, metric và khuyến nghị. Hai thành phần này hỗ trợ triển khai thử nghiệm, nhưng chưa có dữ liệu để kết luận lộ trình làm cải thiện kết quả học tập.

7.2. Hướng phát triển

25. Duy trì việc tách validation trước resampling và bổ sung nested CV khi so sánh nhiều kiến trúc.
26. Báo cáo bootstrap confidence interval, fold standard deviation và kiểm định paired khi so sánh cấu hình.
27. So sánh embedding hiện tại với one-hot encoding và kiểm tra độ nhạy của SMOTENC.
28. Thu thập event log có timestamp để hình thành chuỗi xAPI thực, kèm masking cho chuỗi độ dài khác nhau.
29. Thực hiện ablation MLP-only, sequence-only, hybrid, không attention, không feature engineering và các chiến lược imbalance.
30. Đánh giá calibration bằng Brier score/ECE và áp dụng temperature scaling nếu cần.

CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

31. Thực hiện fairness audit theo nhóm với tiêu chí phù hợp và quy trình phê duyệt đạo đức.
32. Thiết kế nghiên cứu can thiệp có đối chứng hoặc stepped-wedge để đo hiệu quả learning path.
33. Bổ sung drift monitoring, model registry, versioning và quy trình rollback trong PostgreSQL/MLOps.

7.3. Tuyên bố cuối cùng

Kết quả cho thấy hệ thống có thể chạy đầy đủ từ tiền xử lý, huấn luyện, đánh giá đến sinh khuyến nghị. Tuy nhiên, cỡ mẫu nhỏ, một locked split và việc chưa đánh giá tác động thực tế khiến mô hình chỉ phù hợp cho nghiên cứu và hỗ trợ cố vấn, không phù hợp để tự động ra quyết định đối với người học.

TÀI LIỆU THAM KHẢO

TÀI LIỆU THAM KHẢO

- [1] Cortez, P., & Silva, A. M. G. (2008). Using Data Mining to Predict Secondary School Student Performance. UCI Machine Learning Repository, Student Performance dataset. <https://archive.ics.uci.edu/dataset/320/student+performance>
- [2] Amrieh, E. A., Hamtini, T., & Aljarah, I. (2016). Mining Educational Data to Predict Student's Academic Performance Using Ensemble Methods. *International Journal of Database Theory and Application*, 9(8), 119-136. <https://doi.org/10.14257/ijdta.2016.9.8.13>
- [3] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- [4] Schuster, M., & Paliwal, K. K. (1997). Bidirectional Recurrent Neural Networks. *IEEE Transactions on Signal Processing*, 45(11), 2673-2681. <https://doi.org/10.1109/78.650093>
- [5] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. <https://doi.org/10.1613/jair.953>
- [6] He, H., Bai, Y., Garcia, E. A., & Li, S. (2008). ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning. *IEEE International Joint Conference on Neural Networks*, 1322-1328. <https://doi.org/10.1109/IJCNN.2008.4633969>
- [7] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of KDD 2019*. <https://doi.org/10.1145/3292500.3330701>
- [8] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 86(11), 2278-2324. <https://doi.org/10.1109/5.726791>
- [9] Mã nguồn dự án: `src/models.py`, `src/data_pipeline.py`, `src/train_pipeline.py`, `src/explainability.py`, `src/evaluation.py` và `scripts/run_pipeline.py`.
- [10] Kết quả thực nghiệm dự án: `reports/final/metrics/*_locked_test_metrics.json`; `reports/final/*_final_report.txt`; `reports/final/predictions/*_predictions.csv`; `models/saved/final/xapi_3class_optuna.db`.

PHỤ LỤC A. NGUỒN SỐ LIỆU THỰC NGHIỆM

Bảng A.1. Truy vết nguồn dữ liệu dùng trong luận văn

Nội dung	Tập nguồn
Metric Student-Mat	reports/final/metrics/student-mat_3class_locked_test_metrics.json
Metric Student-Por	reports/final/metrics/student-por_3class_locked_test_metrics.json
Metric xAPI	reports/final/metrics/xapi_3class_locked_test_metrics.json
CV và siêu tham số	reports/final/*_3class_final_report.txt
Ma trận nhầm lẫn	reports/final/predictions/*_3class_predictions.csv
Điểm CV và trial xAPI	models/saved/final/xapi_3class_optuna.db
Kiến trúc	src/models.py
Tiền xử lý	src/data_pipeline.py
Khuyến nghị	src/explainability.py
PostgreSQL	database/schema.sql

PHỤ LỤC B. CHECKLIST TÁI LẬP

- Cố định seed và lưu phiên bản thư viện/môi trường.
- Tạo locked split một lần; không dùng locked test trong Optuna hoặc chọn epoch.
- Fit feature engineering state, scaler, encoder và selector chỉ trên train tương ứng.
- Resampling chỉ trên train; ghi lại method, ratio và k-neighbors.
- Lưu toàn bộ best params, fold score, seed score và checkpoint.
- Tính metric từ prediction CSV và đối chiếu classification report.
- Ghi model version, preprocessing version và schema version khi đưa vào PostgreSQL.
- Không tuyên bố hiệu quả khuyến nghị nếu chưa có dữ liệu can thiệp.

PHỤ LỤC C. CÁC PHÂN TÍCH CẦN BỔ SUNG KHI CÓ DỮ LIỆU

Giới hạn dữ liệu: Cần bổ sung learning curves, biểu đồ calibration, khoảng tin cậy, đánh giá fairness và biểu đồ ablation khi có dữ liệu thực nghiệm tương ứng.