

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN
KHÓA LUẬN TỐT NGHIỆP

XÂY DỰNG MÔ HÌNH HỌC KẾT HỢP ĐỂ DỰ ĐOÁN
THÀNH TÍCH HỌC TẬP SINH VIÊN

Mô hình CNN-BiLSTM ensemble và khuyến nghị học tập

Sinh viên thực hiện: Trần Hoàng Phúc - MSSV: 23DH112780

Lớp: KH2302

Giảng viên hướng dẫn: ThS. Nguyễn Thị Phương Trang

Ngành: Công nghệ thông tin

TP. Hồ Chí Minh, 2026

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN
KHÓA LUẬN TỐT NGHIỆP

XÂY DỰNG MÔ HÌNH HỌC KẾT HỢP ĐỂ DỰ ĐOÁN
THÀNH TÍCH HỌC TẬP SINH VIÊN

Báo cáo khóa luận tốt nghiệp

Sinh viên thực hiện: Trần Hoàng Phúc

MSSV: 23DH112780

Lớp: KH2302

Giảng viên hướng dẫn: ThS. Nguyễn Thị Phương Trang

TP. Hồ Chí Minh, 2026

LỜI CẢM ƠN

Em xin trân trọng cảm ơn giảng viên hướng dẫn đã định hướng chuyên môn, góp ý nội dung và hỗ trợ em trong quá trình thực hiện khóa luận. Em cũng xin cảm ơn quý thầy cô Khoa Công nghệ thông tin đã trang bị nền tảng kiến thức cần thiết để em triển khai đề tài từ khâu xử lý dữ liệu, xây dựng mô hình đến đánh giá kết quả.

Em cảm ơn gia đình và bạn bè đã động viên trong suốt thời gian thực hiện khóa luận. Những thiếu sót còn lại trong báo cáo là trách nhiệm của cá nhân em và sẽ là cơ sở để em tiếp tục hoàn thiện năng lực nghiên cứu, triển khai và trình bày kết quả khoa học.

LỜI CAM ĐOAN

Em cam đoan nội dung khóa luận là kết quả nghiên cứu và triển khai của cá nhân em dưới sự hướng dẫn của giảng viên hướng dẫn. Các số liệu, bảng biểu, hình vẽ và nhận xét trong báo cáo được trình bày trung thực theo kết quả thực nghiệm của đề tài.

Các tài liệu tham khảo được trích dẫn theo quy định. Em chịu trách nhiệm về tính chính xác của nội dung trình bày trong báo cáo khóa luận này.

TÓM TẮT

Khóa luận nghiên cứu bài toán dự đoán thành tích học tập trên bộ dữ liệu Student Performance. Đề tài sử dụng hai mốc đánh giá G1 và G2 làm đầu vào, xây dựng nhãn ba lớp Low, Medium và High từ điểm G3, sau đó huấn luyện mô hình CNN-BiLSTM ensemble để dự đoán mức thành tích cuối cùng.

Kết quả thực nghiệm trên tập kiểm tra 79 bản ghi cho thấy mô hình đạt Accuracy 0,9114, Precision-Macro 0,9235, Recall-Macro 0,9305 và F1-Macro 0,9256. Trong nested cross-validation, CNN-BiLSTM đạt Macro-F1 $0,8736 \pm 0,0381$, gần với mô hình đối chứng HistGradientBoosting đạt $0,8690 \pm 0,0358$.

Bên cạnh mô hình dự đoán, khóa luận xây dựng chức năng khuyến nghị học tập theo luật. Từ mức thành tích dự đoán, hệ thống đưa ra gợi ý hỗ trợ tương ứng cho nhóm có nguy cơ cao, nhóm trung bình và nhóm có kết quả tốt.

Từ khóa: dự đoán thành tích học tập; khai phá dữ liệu giáo dục; CNN-BiLSTM; học kết hợp; phân loại đa lớp; khuyến nghị học tập.

ABSTRACT

This thesis studies student performance prediction using the Student Performance dataset. The final approach uses G1 and G2 as input, derives three classes from G3, and applies a CNN-BiLSTM probability ensemble for multiclass classification. The final test results are Accuracy 0.9114, Precision-Macro 0.9235, Recall-Macro 0.9305, and F1-Macro 0.9256.

The system also includes a rule-based learning recommendation component that translates predicted performance levels into learning suggestions.

Keywords: student performance prediction; educational data mining; CNN-BiLSTM; probability ensemble; multiclass classification; learning recommendation.

MỤC LỤC

CHƯƠNG 1. MỞ ĐẦU	1
1.1. Bối cảnh nghiên cứu.....	1
1.2. Lý do chọn đề tài.....	1
1.3. Mục tiêu nghiên cứu.....	1
1.4. Đối tượng và phạm vi.....	2
1.5. Phương pháp nghiên cứu.....	3
1.6. Đóng góp và bố cục báo cáo	3
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN.....	5
2.1. Khai phá dữ liệu giáo dục	5
2.2. Bài toán phân loại thành tích học tập	5
2.3. CNN và Conv1D.....	6
2.4. LSTM và Bi-LSTM.....	7
2.5. Học kết hợp bằng ensemble xác suất	8
2.6. Mất cân bằng dữ liệu và SMOTE	9
2.7. Optuna và nested cross-validation	10
2.8. Metric đánh giá	11
2.9. Khuyến nghị học tập có giải thích	12
2.10. Nghiên cứu liên quan	12
2.11. Thảo luận tổng hợp nghiên cứu liên quan.....	14
2.12. Nhận xét về độ tin cậy của bằng chứng khoa học.....	16
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT VÀ THIẾT KẾ THỰC NGHIỆM.....	17
3.1. Quy trình tổng quan	17
3.2. Bộ dữ liệu và định nghĩa nhãn	17
3.3. Tiền xử lý và chống rò rỉ dữ liệu.....	18
3.4. Kiến trúc CNN-BiLSTM ensemble	19
3.5. Tối ưu và lựa chọn mô hình	21
3.6. Vai trò lưu trữ dữ liệu bằng PostgreSQL	23
3.7. Logic khuyến nghị học tập.....	23
3.8. Biện minh thiết kế thực nghiệm	25

3.9. Công thức và diễn giải các thành phần chính	27
3.10. Kiểm soát diễn giải mô hình và dữ liệu	28
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ.....	28
4.1. Thiết lập thực nghiệm	28
4.2. Phân bố lớp.....	29
4.3. So sánh với mô hình đối chứng.....	30
4.4. Kết quả trên tập kiểm tra xác nhận	32
4.5. Kết quả theo từng lớp.....	32
4.6. Ma trận nhầm lẫn và phân tích lỗi.....	33
4.7. Đường Precision-Recall	34
4.8. Kết quả khuyến nghị học tập.....	35
4.9. Hạn chế của kết quả thực nghiệm	37
4.10. Thảo luận tổng hợp kết quả.....	38
4.11. Ý nghĩa thực tiễn và giới hạn sử dụng	39
4.12. Phân tích ý nghĩa từng nhóm kết quả.....	40
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	41
5.1. Kết quả đạt được	41
5.2. Hạn chế.....	42
5.3. Hướng phát triển	42
5.4. Kết luận	43
5.5. Bài học rút ra từ quá trình thực hiện	44
TÀI LIỆU THAM KHẢO.....	46
PHỤ LỤC.....	48
Phụ lục A. Siêu tham số cấu hình cuối	48
Phụ lục B. Pseudocode CNN-BiLSTM ensemble	48
Phụ lục C. Bảng metric đầy đủ.....	49
Phụ lục D. Ví dụ khuyến nghị học tập	49
Phụ lục E. Thông tin tái lập thực nghiệm tối giản	49

DANH MỤC BẢNG

Danh mục từ viết tắt sử dụng trong báo cáo

Bảng 2. Định nghĩa ba lớp thành tích từ G3	Error! Bookmark not defined.
Bảng 3. Các khối chính của mô hình CNN-BiLSTM	Error! Bookmark not defined.
Bảng 4. Protocol chọn mô hình	Error! Bookmark not defined.
Bảng 5. Ánh xạ dự đoán thành khuyến nghị học tập	Error! Bookmark not defined.
Bảng 6. Thiết lập thực nghiệm chính	Error! Bookmark not defined.
Bảng 7. Kết quả nested cross-validation	Error! Bookmark not defined.
Bảng 8. Metric trên tập kiểm tra xác nhận	Error! Bookmark not defined.
Bảng 9. Precision, Recall và F1 theo từng lớp	Error! Bookmark not defined.
Bảng 10. Ví dụ khuyến nghị học tập	Error! Bookmark not defined.
Bảng 11. Siêu tham số chính của CNN-BiLSTM ensemble ...	Error! Bookmark not defined.
Bảng 12. Metric đầy đủ trên tập kiểm tra xác nhận ..	Error! Bookmark not defined.
Bảng 13. Một số ví dụ khuyến nghị học tập	Error! Bookmark not defined.

DANH MỤC HÌNH

Hình 1. Quy trình tổng quan của hệ thống	17
Hình 2. Kiến trúc CNN-BiLSTM của một mô hình cơ sở	20
Hình 3. Phân bố ba lớp từ điểm G3	30
Hình 4. So sánh Macro-F1 giữa CNN-BiLSTM và mô hình đối chứng	31
Hình 5. Ma trận nhầm lẫn trên tập kiểm tra xác nhận	33
Hình 6. Đường Precision-Recall theo từng lớp	34

DANH MỤC TỪ VIẾT TẮT

Danh mục từ viết tắt sử dụng trong báo cáo

Ký hiệu	Diễn giải
EDM	Educational Data Mining - khai phá dữ liệu giáo dục
CNN	Convolutional Neural Network - mạng nơ-ron tích chập
LSTM	Long Short-Term Memory
Bi-LSTM	Bidirectional Long Short-Term Memory
SMOTE	Synthetic Minority Over-sampling Technique
PR	Precision-Recall

Nguồn: Tác giả tổng hợp.

CHƯƠNG 1. MỞ ĐẦU

1.1. Bối cảnh nghiên cứu

Trong các cơ sở giáo dục, dữ liệu điểm số và quá trình học tập ngày càng được lưu trữ có hệ thống. Nếu được khai thác đúng cách, dữ liệu này có thể hỗ trợ nhận diện sớm nhóm người học có nguy cơ đạt kết quả thấp, từ đó giúp giảng viên hoặc cố vấn học tập đưa ra hỗ trợ phù hợp hơn.

Đề tài tập trung vào bài toán dự đoán mức thành tích cuối cùng từ hai mốc đánh giá trước đó. Trong bộ dữ liệu Student Performance, G1 và G2 là hai điểm đánh giá trước, còn G3 là kết quả cuối cùng.

1.2. Lý do chọn đề tài

Dự đoán thành tích học tập có ý nghĩa thực tế vì kết quả dự đoán có thể hỗ trợ phát hiện sớm rủi ro học tập. Thay vì chỉ xem điểm cuối kỳ sau khi quá trình học đã kết thúc, hệ thống dự đoán có thể cung cấp tín hiệu tham khảo dựa trên những mốc đánh giá sớm hơn.

Khóa luận chọn mô hình CNN-BiLSTM vì kiến trúc này cho phép kết hợp khả năng trích xuất biểu diễn cục bộ của Conv1D với khả năng xử lý chuỗi ngắn của Bi-LSTM. Đề tài cũng sử dụng học kết hợp theo hướng ensemble xác suất nhằm giảm phụ thuộc vào một lần khởi tạo mô hình duy nhất.

1.3. Mục tiêu nghiên cứu

Mục tiêu tổng quát là xây dựng mô hình học kết hợp để dự đoán thành tích học tập theo ba mức Low, Medium và High, đồng thời xây dựng chức năng khuyến nghị học tập dựa trên kết quả dự đoán.

Các mục tiêu cụ thể gồm: tìm hiểu bộ dữ liệu Student Performance; xây dựng nhãn phân loại từ G3; tiền xử lý dữ liệu; xử lý mất cân bằng lớp; xây dựng mô hình CNN-BiLSTM ensemble; đánh giá mô hình bằng nested cross-validation và tập kiểm tra xác nhận; xây dựng logic khuyến nghị học tập theo luật.

Mục tiêu đánh giá không chỉ là tìm một giá trị Accuracy cao. Với bài toán giáo dục, mô hình cần được xem xét qua khả năng cân bằng giữa các nhóm kết quả, đặc

biệt là nhóm Low vì đây là nhóm có ý nghĩa hỗ trợ sớm. Vì vậy, F1-Macro được đặt ở vị trí trung tâm trong phần đánh giá.

Một mục tiêu phụ của đề tài là trình bày kết quả theo cách người đọc có thể kiểm tra được logic thực nghiệm. Các bảng metric, ma trận nhầm lẫn và đường Precision-Recall được dùng để giải thích mô hình đúng và sai ở đâu, thay vì chỉ nêu một con số tổng hợp.

Đề tài cũng hướng tới việc chuyển kết quả dự đoán thành gợi ý học tập. Phần này không đặt mục tiêu chứng minh hiệu quả can thiệp ngoài đời, mà minh họa cách một hệ thống dự đoán có thể tạo đầu ra dễ hiểu hơn cho người học hoặc cố vấn học tập.

1.4. Đối tượng và phạm vi

Đối tượng nghiên cứu là bài toán phân loại thành tích học tập ba lớp trên bộ dữ liệu student-mat gồm 395 bản ghi. Đầu vào chính của mô hình là hai điểm G1 và G2. Đầu ra là một trong ba mức thành tích được suy ra từ G3: Low, Medium hoặc High.

Bộ dữ liệu sử dụng là dữ liệu công khai về học sinh trung học tại Bồ Đào Nha, không phải dữ liệu sinh viên Việt Nam. Vì vậy, kết quả được hiểu là kết quả thực nghiệm trên một bộ dữ liệu benchmark.

Phạm vi đầu vào [G1, G2] giúp đề tài có một giả định rõ ràng: chỉ hai mốc đánh giá trước được dùng để dự đoán mức kết quả cuối cùng. Điều này làm bài toán hẹp hơn nhưng cũng giúp việc diễn giải mô hình rõ hơn, vì hiệu năng không bị trộn với nhiều đặc trưng nên khó kiểm soát.

Trong thực tế, thành tích học tập còn chịu ảnh hưởng bởi động lực cá nhân, môi trường gia đình, phương pháp giảng dạy, sức khỏe tinh thần và nhiều yếu tố xã hội khác. Bộ dữ liệu hiện tại không đủ để mô hình hóa đầy đủ các yếu tố đó, nên báo cáo chỉ kết luận trong phạm vi dữ liệu và đặc trưng đã chọn.

Tập kiểm tra xác nhận gồm 79 bản ghi được dùng để đánh giá cấu hình cuối. Do số mẫu không lớn, các kết quả trên tập này cần được đọc cùng với nested cross-

validation, thay vì xem như bằng chứng duy nhất về hiệu năng kỳ vọng của mô hình.

1.5. Phương pháp nghiên cứu

Quy trình nghiên cứu gồm phân tích dữ liệu, tạo nhãn ba lớp, tiền xử lý, huấn luyện mô hình, lựa chọn cấu hình và đánh giá bằng các chỉ số phân loại. Các kết quả được phân tích qua Accuracy, Precision, Recall, F1-Macro, ma trận nhầm lẫn và đường Precision-Recall.

Về mặt thực tiễn, bài toán này có ý nghĩa ở giai đoạn người học vẫn còn thời gian điều chỉnh cách học. Nếu mô hình chỉ dự đoán sau khi đã có điểm cuối cùng thì giá trị hỗ trợ sẽ thấp. Vì vậy, khóa luận đặt trọng tâm vào việc sử dụng G1 và G2 như hai tín hiệu sớm hơn để dự đoán nhóm kết quả cuối cùng từ G3.

Đề tài không xem mô hình như công cụ thay thế quyết định sự phạm của giảng viên. Đầu ra dự đoán chỉ nên được dùng như một nguồn tham khảo để ưu tiên quan sát, trao đổi hoặc hỗ trợ thêm cho nhóm có nguy cơ. Cách tiếp cận này phù hợp với bối cảnh giáo dục, nơi kết quả học tập chịu ảnh hưởng bởi nhiều yếu tố ngoài điểm số.

Việc chọn ba lớp Low, Medium và High giúp kết quả dễ diễn giải hơn đối với người dùng cuối. Thay vì yêu cầu hệ thống dự đoán chính xác một điểm số cụ thể trên thang 0-20, mô hình trả lời câu hỏi thực dụng hơn: người học đang có xu hướng thuộc nhóm cần hỗ trợ mạnh, nhóm trung bình hay nhóm có kết quả tốt.

Một điểm cần nhấn mạnh là bộ dữ liệu student-mat không đại diện cho toàn bộ sinh viên đại học. Do đó, mục tiêu của khóa luận là xây dựng và đánh giá quy trình mô hình hóa trên một bộ dữ liệu công khai, có thể tái lập, thay vì khẳng định khả năng triển khai trực tiếp trong mọi môi trường đào tạo.

1.6. Đóng góp và bố cục báo cáo

Đóng góp chính là xây dựng quy trình dự đoán thành tích học tập bằng CNN-BiLSTM ensemble trên chuỗi điểm G1, G2; so sánh với mô hình đối chứng HistGradientBoosting; phân tích lỗi dự đoán theo từng lớp; và đề xuất chức năng khuyến nghị học tập đơn giản, có thể giải thích.

Chương 1. Mở đầu

Báo cáo gồm năm chương: mở đầu, cơ sở lý thuyết, phương pháp đề xuất, thực nghiệm và đánh giá, kết luận và hướng phát triển.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ NGHIÊN CỨU LIÊN QUAN

2.1. Khai phá dữ liệu giáo dục

Khai phá dữ liệu giáo dục nghiên cứu các phương pháp phân tích dữ liệu sinh ra trong quá trình học tập nhằm hỗ trợ hiểu hành vi học tập, dự đoán kết quả và cá nhân hóa hỗ trợ người học [2], [3].

Khác với khai phá dữ liệu trong thương mại điện tử hoặc tài chính, dữ liệu giáo dục thường gắn trực tiếp với con người và quá trình học tập. Một dự đoán sai có thể dẫn đến khuyến nghị không phù hợp, vì vậy khả năng giải thích và giới hạn sử dụng cần được trình bày rõ.

Một hệ thống EDM có giá trị không chỉ vì nó dự đoán đúng, mà còn vì nó giúp người dạy hiểu nhóm nào cần hỗ trợ và hỗ trợ ở thời điểm nào. Trong phạm vi đề tài, mô hình đóng vai trò tạo tín hiệu tham khảo, còn quyết định sự phạm vẫn cần sự đánh giá của con người.

Các nghiên cứu EDM thường gặp thách thức về dữ liệu nhỏ, dữ liệu lệch lớp và dữ liệu phụ thuộc bối cảnh. Những thách thức này cũng xuất hiện trong đề tài: student-mat chỉ có 395 bản ghi và không phản ánh trực tiếp bối cảnh đại học Việt Nam.

Vì vậy, báo cáo ưu tiên cách diễn giải thận trọng: kết quả cho thấy quy trình đề xuất hoạt động tốt trên bộ dữ liệu benchmark, nhưng chưa đủ để khẳng định khả năng tổng quát hóa sang mọi môi trường đào tạo.

2.2. Bài toán phân loại thành tích học tập

Khóa luận mô hình hóa dự đoán thành tích như bài toán phân loại đa lớp. Điểm G3 được chia thành ba mức Low, Medium và High để kết quả dễ gắn với hành động hỗ trợ hơn so với dự đoán điểm liên tục.

Trong bài toán ba lớp, các ranh giới nhãn là điểm cần đặc biệt chú ý. Một mẫu có G3 bằng 9 thuộc Low, trong khi G3 bằng 10 thuộc Medium; hai trường hợp này

có thể rất gần nhau về mặt học tập nhưng lại nằm ở hai lớp khác nhau. Điều này giải thích vì sao lỗi Low-Medium là dạng lỗi dễ xảy ra.

Việc chọn ba lớp thay vì hai lớp giúp phân biệt nhóm kết quả cao với nhóm trung bình. Nếu chỉ chia đạt/không đạt, hệ thống sẽ bỏ mất thông tin về nhóm High. Tuy nhiên, chia nhiều lớp hơn cũng làm số mẫu mỗi lớp nhỏ hơn và khiến đánh giá khó ổn định hơn.

Trong thiết kế khuyến nghị, ba lớp cũng thuận tiện hơn hai lớp. Nhóm Low cần gợi ý củng cố nền tảng, nhóm Medium cần duy trì và cải thiện, còn nhóm High có thể được định hướng học nâng cao. Cách chia này phù hợp với mục tiêu minh họa chức năng hỗ trợ học tập.

Trong dự đoán thành tích học tập, lựa chọn giữa hồi quy và phân loại phụ thuộc vào mục tiêu sử dụng. Hồi quy phù hợp khi cần ước lượng điểm số cụ thể, nhưng thường khó chuyển trực tiếp thành hành động hỗ trợ. Phân loại theo mức thành tích giúp kết quả gần với nhu cầu ra quyết định hơn, đặc biệt khi người dùng cần xác định nhóm ưu tiên can thiệp.

Với dữ liệu nhỏ, bài toán phân loại đa lớp cũng đặt ra yêu cầu đánh giá cẩn trọng. Nếu một lớp chiếm ưu thế, mô hình có thể đạt Accuracy cao nhưng vẫn dự đoán kém ở lớp thiểu số. Vì lý do đó, báo cáo sử dụng F1-Macro như chỉ số chính để mỗi lớp có trọng số ngang nhau trong đánh giá tổng hợp.

2.3. CNN và Conv1D

Mạng nơ-ron tích chập có khả năng học các bộ lọc cục bộ từ dữ liệu [4]. Với chuỗi G1, G2, Conv1D được dùng để tạo biểu diễn từ hai mốc điểm trước khi đưa sang khối tuần tự.

Một bộ lọc Conv1D học các trọng số chia sẻ khi quét qua chuỗi đầu vào. Trong các bài toán chuỗi dài, cơ chế này giúp phát hiện mẫu cục bộ xuất hiện ở nhiều vị trí. Với chuỗi hai mốc điểm, lợi ích này bị giới hạn hơn, nhưng Conv1D vẫn có thể đóng vai trò biến đổi phi tuyến trước Bi-LSTM.

Batch Normalization thường được đặt sau Conv1D để làm ổn định phân phối kích hoạt trong quá trình huấn luyện [11]. ReLU sau đó đưa vào tính phi tuyến, giúp mô hình biểu diễn quan hệ không tuyến tính giữa G1, G2 và lớp kết quả.

Điều quan trọng là không nên gán cho Conv1D vai trò quá lớn trong bối cảnh dữ liệu chỉ có hai bước thời gian. Trong báo cáo, Conv1D được mô tả như một thành phần của kiến trúc đề xuất, còn kết quả thực nghiệm mới là căn cứ để đánh giá hiệu quả tổng thể.

Trong xử lý chuỗi một chiều, Conv1D trượt bộ lọc theo trục thời gian hoặc thứ tự đặc trưng. Với chuỗi rất ngắn gồm G1 và G2, Conv1D không được hiểu như mô hình phát hiện mẫu dài hạn, mà là phép biến đổi phi tuyến giúp tạo biểu diễn trung gian trước khi đưa vào khối Bi-LSTM.

Việc sử dụng Conv1D trong khóa luận có tính khảo sát kiến trúc: đề tài kiểm tra xem một khối trích xuất biểu diễn cục bộ có hỗ trợ mô hình học mối quan hệ giữa hai mốc điểm hay không. Cách diễn giải này thận trọng hơn so với việc xem CNN như mô hình khai thác cấu trúc không gian phức tạp.

2.4. LSTM và Bi-LSTM

LSTM xử lý dữ liệu tuần tự thông qua cơ chế cổng điều khiển trạng thái nhớ [5]. Bi-LSTM mở rộng LSTM bằng cách đọc chuỗi theo hai chiều [6], phù hợp để biểu diễn quan hệ giữa G1 và G2.

LSTM sử dụng trạng thái ẩn và trạng thái nhớ để truyền thông tin qua các bước thời gian. Cơ chế cổng cho phép mô hình quyết định thông tin nào cần giữ lại, thông tin nào cần quên và thông tin nào cần đưa ra đầu ra ở mỗi bước.

Bi-LSTM gồm một LSTM đọc chuỗi theo chiều thuận và một LSTM đọc chuỗi theo chiều ngược. Hai biểu diễn này được kết hợp để tạo vector giàu thông tin hơn. Với G1 và G2, chiều thuận tương ứng với diễn tiến điểm từ mốc đầu sang mốc sau, còn chiều ngược giúp mô hình nhìn lại mối quan hệ từ G2 về G1.

Tuy vậy, vì chuỗi chỉ dài hai, việc dùng Bi-LSTM cần được xem là khảo sát kiến trúc chứ không phải khai thác phụ thuộc dài hạn. Nếu dữ liệu tương lai có

nhiều mốc học tập hơn, chẳng hạn điểm theo tuần hoặc theo nhiều học kỳ, vai trò của Bi-LSTM sẽ có cơ sở mạnh hơn.

Điểm này được nêu rõ để tránh hiểu sai rằng mô hình đã học toàn bộ quá trình học tập của sinh viên. Trong đề tài, mô hình chỉ học quan hệ có thứ tự giữa hai mốc đánh giá trước trong cùng bộ dữ liệu.

LSTM được thiết kế để giảm vấn đề mất hoặc bùng nổ gradient trong mạng hồi quy truyền thống. Các cổng input, forget và output cho phép mô hình điều khiển lượng thông tin cần giữ lại hoặc loại bỏ khi đi qua chuỗi.

Bi-LSTM mở rộng LSTM bằng cách học biểu diễn từ cả chiều thuận và chiều ngược. Trong đề tài, điều này có nghĩa là mô hình có thể xem xét quan hệ G1 đến G2 và quan hệ phản chiếu từ G2 về G1. Tuy nhiên, vì chuỗi chỉ có hai bước thời gian, Bi-LSTM không được diễn giải như mô hình hóa phụ thuộc dài hạn.

2.5. Học kết hợp bằng ensemble xác suất

Học kết hợp trong khóa luận được hiểu là kết hợp nhiều mô hình CNN-BiLSTM cùng kiến trúc nhưng khác seed khởi tạo. Xác suất đầu ra của các mô hình cơ sở được lấy trung bình trước khi đưa ra nhãn cuối. Cách làm này gần với soft voting và deep ensemble [7].

Ensemble xác suất khác với bỏ phiếu cứng ở chỗ nó giữ lại mức độ tự tin tương đối của từng lớp. Ví dụ, hai mô hình cùng dự đoán Medium nhưng một mô hình có xác suất 0,51 và mô hình khác có xác suất 0,90 là hai tín hiệu khác nhau. Trung bình xác suất giúp giữ lại sự khác biệt đó.

Trong dữ liệu nhỏ, mô hình đơn lẻ dễ bị ảnh hưởng bởi khởi tạo trọng số, thứ tự mini-batch hoặc mẫu tổng hợp do SMOTE tạo ra. Ensemble nhiều seed giúp làm trơn các dao động này. Tuy nhiên, ensemble không thay thế cho đánh giá đúng protocol; nếu chọn seed dựa trên tập kiểm tra thì kết quả sẽ bị thiên lệch.

Cấu hình cuối sử dụng 11 mô hình cơ sở. Con số này không được diễn giải như giá trị tối ưu phổ quát, mà là cấu hình đã được chọn trong quy trình thực nghiệm của đề tài. Khi triển khai thực tế, số mô hình cơ sở cần cân nhắc giữa hiệu năng, thời gian suy luận và chi phí lưu trữ.

Một ưu điểm khác của ensemble là xác suất trung bình thường ổn định hơn xác suất của mô hình đơn. Điều này có ích cho thành phần khuyến nghị, vì mức độ tin cậy của dự đoán có thể được dùng để quyết định cách diễn đạt gợi ý học tập.

Nếu ký hiệu $p_m(y|x)$ là xác suất lớp y do mô hình cơ sở thứ m dự đoán, ensemble xác suất tính trung bình các xác suất này qua M mô hình cơ sở. Nhân cuối được xác định từ vector xác suất trung bình. Cách kết hợp này giữ lại thông tin độ tin cậy tương đối giữa các lớp thay vì chỉ bỏ phiếu theo nhãn cứng.

Lý do sử dụng ensemble là mô hình học sâu có thể nhạy với khởi tạo ban đầu, đặc biệt khi dữ liệu nhỏ. Nhiều mô hình cùng kiến trúc nhưng khác seed có thể học các nghiệm hơi khác nhau. Trung bình xác suất giúp giảm dao động của một mô hình đơn lẻ, dù đổi lại chi phí huấn luyện và lưu trữ mô hình tăng lên.

2.6. Mất cân bằng dữ liệu và SMOTE

Khi số lượng mẫu giữa các lớp không đồng đều, mô hình có thể thiên về lớp xuất hiện nhiều hơn. SMOTE tạo mẫu tổng hợp cho lớp thiểu số bằng nội suy giữa các điểm lân cận [8]. ADASYN là một hướng sinh mẫu khác điều chỉnh theo độ khó của vùng dữ liệu [9].

Mất cân bằng dữ liệu làm cho mô hình có xu hướng ưu tiên lớp phổ biến hơn. Trong student-mat, lớp Medium có số mẫu lớn hơn lớp High. Nếu chỉ tối ưu Accuracy, mô hình có thể đạt kết quả tổng thể tốt nhưng vẫn bỏ sót nhóm thiểu số.

SMOTE tạo mẫu mới bằng cách nội suy giữa một mẫu thiểu số và các láng giềng gần của nó. Vì vậy, mẫu sinh ra nằm trong không gian đặc trưng của lớp thiểu số, không phải bản ghi học tập thật. Điều này giúp mô hình nhìn thấy nhiều biến thể hơn nhưng cũng có nguy cơ tạo điểm không hoàn toàn thực tế.

ADASYN cũng là phương pháp oversampling, nhưng tập trung sinh nhiều mẫu hơn ở các vùng khó học. Đề tài trình bày ADASYN trong cơ sở lý thuyết vì đây là phương pháp liên quan; cấu hình cuối được xác minh sử dụng SMOTE.

Ngoài oversampling, weighted cross-entropy cũng hỗ trợ cân bằng lớp bằng cách tăng trọng số mất mát cho lớp ít mẫu. Hai kỹ thuật này xử lý mất cân bằng ở

hai mức khác nhau: một bên thay đổi dữ liệu huấn luyện, một bên thay đổi hàm mục tiêu.

SMOTE chỉ nên được áp dụng trong phạm vi tập huấn luyện. Nếu sinh mẫu tổng hợp trước khi tách dữ liệu, thông tin từ vùng lân cận của tập kiểm tra có thể rò rỉ vào huấn luyện. Vì vậy, thiết kế thực nghiệm của khóa luận đặt oversampling sau bước chia dữ liệu và bên trong từng fold huấn luyện của nested cross-validation.

Mặc dù SMOTE giúp tăng số mẫu cho lớp thiểu số, nó không tạo ra thông tin thật mới từ người học. Các mẫu tổng hợp là điểm nội suy trong không gian đặc trưng. Do đó, SMOTE được xem như kỹ thuật hỗ trợ huấn luyện, không phải bằng chứng rằng dữ liệu thực tế đã cân bằng hơn.

2.7. Optuna và nested cross-validation

Optuna hỗ trợ tìm kiếm siêu tham số có hệ thống [13]. Nested cross-validation tách vòng chọn cấu hình và vòng đánh giá, giúp hạn chế thiên lệch khi lựa chọn mô hình trên dữ liệu nhỏ [14], [15].

Các siêu tham số như learning rate, dropout, hidden dimension, batch size và tỷ lệ SMOTE có ảnh hưởng trực tiếp đến kết quả. Nếu chọn bằng tay, kết quả dễ phụ thuộc vào kinh nghiệm chủ quan. Optuna giúp tạo quy trình tìm kiếm có hệ thống hơn.

Tuy nhiên, tối ưu siêu tham số trên dữ liệu nhỏ luôn có nguy cơ overfitting vào validation. Nested cross-validation không loại bỏ hoàn toàn rủi ro này, nhưng giúp ước lượng thực tế hơn vì fold ngoài không tham gia trực tiếp vào việc chọn siêu tham số.

Trong báo cáo, kết quả nested CV được dùng để so sánh mô hình đề xuất và mô hình đối chứng. Đây là kết quả quan trọng hơn khi đánh giá khả năng cạnh tranh tổng quát, vì nó trung bình hóa qua nhiều cách chia dữ liệu.

Kết quả tập kiểm tra xác nhận được đặt sau khi cấu hình đã chọn. Vai trò của nó là kiểm tra cấu hình cuối trên một tập giữ riêng, không phải để tiếp tục chọn mô hình, chọn seed hoặc điều chỉnh ngưỡng.

Optuna giúp tự động hóa việc thử nhiều cấu hình siêu tham số. Tuy nhiên, kết quả tối ưu hóa chỉ đáng tin khi tập dùng để chọn cấu hình được tách khỏi tập dùng để báo cáo hiệu năng cuối. Nếu cùng một tập dữ liệu vừa dùng để chọn vừa dùng để công bố kết quả, hiệu năng có thể bị lạc quan.

Nested cross-validation giải quyết vấn đề này bằng hai vòng. Vòng trong tìm cấu hình tốt trên phần huấn luyện của từng fold, còn vòng ngoài ước lượng hiệu năng của cấu hình đã chọn trên phần chưa dùng để chọn. Với bộ dữ liệu 395 bản ghi, cách đánh giá này quan trọng vì sai lệch do split có thể lớn.

2.8. Metric đánh giá

Accuracy cho biết tỷ lệ dự đoán đúng tổng thể. Precision-Macro, Recall-Macro và F1-Macro đánh giá công bằng hơn giữa các lớp [17]. Ma trận nhầm lẫn và đường Precision-Recall giúp phân tích dạng lỗi và chất lượng xác suất [16].

Confusion matrix giúp nhìn thấy mô hình nhầm lớp nào với lớp nào. Trong đề tài, lỗi Low-Medium có ý nghĩa thực tế hơn lỗi ngẫu nhiên vì hai lớp này nằm gần ranh giới G3 bằng 9/10. Do đó, phân tích ma trận nhầm lẫn là cần thiết để hiểu kết quả F1-Macro.

Precision-Recall curve phù hợp khi dữ liệu có mất cân bằng lớp vì nó tập trung vào quan hệ giữa dự đoán dương và khả năng phát hiện lớp. Với bài toán đa lớp, mỗi lớp được xét theo hướng one-vs-rest để vẽ đường Precision-Recall riêng.

Average Precision tóm tắt đường Precision-Recall thành một giá trị. Báo cáo dùng đường cong và AP như thông tin bổ sung, không thay thế cho F1-Macro vì quyết định cuối cùng của hệ thống vẫn là một nhãn rời rạc.

Precision và Recall phản ánh hai mặt khác nhau của chất lượng dự đoán. Precision cao nghĩa là khi mô hình dự đoán một lớp, dự đoán đó thường đúng. Recall cao nghĩa là mô hình phát hiện được phần lớn mẫu thuộc lớp đó. F1 kết hợp hai đại lượng bằng trung bình điều hòa.

Trong báo cáo, RMSE và R^2 chỉ được dùng như chẩn đoán bổ sung trên mã lớp thứ tự 0/1/2. Chúng không biến bài toán thành hồi quy và không được dùng làm

chỉ số chính. Cách ghi này giúp người đọc không nhầm lẫn giữa kết quả phân loại và kết quả hồi quy điểm số.

2.9. Khuyến nghị học tập có giải thích

Với phạm vi khóa luận, phần khuyến nghị được xây dựng theo luật đề đầu ra dễ hiểu và dễ kiểm tra. Mỗi mức dự đoán được gắn với một nhóm gợi ý học tập phù hợp [21]-[23].

Khuyến nghị theo luật phù hợp với phạm vi khóa luận vì dễ giải thích và dễ kiểm tra. Người đọc có thể thấy rõ vì sao một dự đoán Low dẫn đến gợi ý củng cố kiến thức nền, trong khi dự đoán High dẫn đến gợi ý duy trì và mở rộng.

Điểm yếu của cách tiếp cận này là chưa học từ phản hồi người dùng. Nếu hai người học cùng được dự đoán Low nhưng nguyên nhân yếu khác nhau, hệ thống hiện tại chưa đủ dữ liệu để cá nhân hóa sâu cho từng trường hợp.

Vì vậy, báo cáo chỉ xem phần khuyến nghị như chức năng hỗ trợ đầu ra của mô hình, không khẳng định rằng khuyến nghị đã cải thiện kết quả học tập ngoài đời. Để chứng minh hiệu quả, cần nghiên cứu can thiệp hoặc dữ liệu phản hồi theo thời gian.

2.10. Nghiên cứu liên quan

Cortez và Silva công bố bộ dữ liệu Student Performance và cho thấy dữ liệu điểm số cùng thông tin nền có thể hỗ trợ dự đoán kết quả học tập [1]. Các khảo sát sau đó ghi nhận nhiều thuật toán học máy đã được áp dụng cho bài toán dự đoán thành tích [24].

Nhóm nghiên cứu đầu tiên tập trung vào dữ liệu Student Performance và các mô hình dữ liệu bảng. Các hướng này thường tận dụng nhiều đặc trưng nhân khẩu học, xã hội và điểm số. Ưu điểm là mô hình có nhiều thông tin; nhược điểm là khó tách riêng đóng góp của từng nhóm đặc trưng.

Nhóm nghiên cứu thứ hai dùng các mô hình tuần tự hoặc học sâu khi dữ liệu có diễn biến theo thời gian. Những mô hình này phù hợp hơn khi có chuỗi dài, ví dụ log học tập hoặc điểm theo nhiều tuần. Đề tài sử dụng CNN-BiLSTM trên chuỗi ngắn nên cần diễn giải thận trọng hơn.

Nhóm nghiên cứu thứ ba quan tâm đến khuyến nghị học tập và khả năng giải thích. Các hệ thống khuyến nghị phức tạp có thể dùng phản hồi người dùng hoặc mô hình học sâu, nhưng với dữ liệu nhỏ, quy tắc rõ ràng thường phù hợp hơn cho bản mẫu khóa luận.

So với các hướng trên, đề tài chọn phạm vi hẹp: dự đoán ba lớp từ G1/G2, đánh giá bằng nested CV và tập kiểm tra xác nhận, sau đó sinh khuyến nghị theo luật. Phạm vi này giúp báo cáo kiểm soát tốt hơn nguy cơ overclaim.

Các nghiên cứu về dự đoán thành tích học tập thường sử dụng ba nhóm hướng tiếp cận: mô hình thống kê và cây quyết định, mô hình học máy trên dữ liệu bảng, và mô hình học sâu khi dữ liệu có cấu trúc chuỗi hoặc nhiều nguồn. Với dữ liệu Student Performance, nhiều mô hình dữ liệu bảng có thể đạt kết quả tốt vì điểm G1 và G2 đã chứa tín hiệu mạnh về G3.

Khoảng trống mà khóa luận khai thác không phải là tạo ra mô hình phức tạp nhất, mà là xây dựng một quy trình có kiểm soát: chọn cấu hình bằng nested cross-validation, so sánh với mô hình đối chứng mạnh, phân tích lỗi theo từng lớp và chuyển đầu ra dự đoán thành khuyến nghị học tập theo luật.

Bảng 1. Một số hướng nghiên cứu liên quan và liên hệ với đề tài

Nhóm nghiên cứu	Dữ liệu / mô hình	Liên hệ với khóa luận
Cortez và Silva [1]	Student Performance; mô hình dự đoán kết quả học tập	Cung cấp bộ dữ liệu và bối cảnh cho bài toán dự đoán G3.

Romero và Ventura [2], [3]	Tổng quan Educational Data Mining	Đặt bài toán trong hướng khai phá dữ liệu giáo dục.
Shahiri và cộng sự [24]	Khảo sát mô hình dự đoán thành tích	Cho thấy nhiều mô hình học máy đã được dùng trong bài toán này.
Các mô hình cây tăng cường	Dữ liệu bảng, quan hệ phi tuyến	Là cơ sở chọn HistGradientBoosting làm mô hình đối chứng mạnh.
Deep ensemble [7]	Kết hợp nhiều mô hình xác suất	Gợi ý cách giảm dao động bằng trung bình xác suất nhiều mô hình cơ sở.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

2.11. Thảo luận tổng hợp nghiên cứu liên quan

Các nghiên cứu về dự đoán thành tích học tập cho thấy không có một mô hình duy nhất luôn tốt nhất trong mọi bối cảnh. Với dữ liệu bảng nhỏ, các mô hình cây, hồi quy hoặc boosting thường có ưu thế vì chúng khai thác tốt quan hệ phi tuyến mà không cần quá nhiều mẫu. Với dữ liệu tuần tự dài hơn, mô hình hồi quy, LSTM hoặc Transformer có thể phù hợp hơn.

Bộ dữ liệu Student Performance là nguồn dữ liệu phổ biến vì có cấu trúc rõ ràng và được công bố công khai. Tuy nhiên, đây cũng là bộ dữ liệu nhỏ, có bối cảnh cụ thể và không phản ánh đầy đủ môi trường giáo dục đại học hiện đại. Vì vậy, kết quả trên bộ này chủ yếu có giá trị kiểm chứng phương pháp và so sánh tương đối.

Một số nghiên cứu sử dụng nhiều đặc trưng như thông tin gia đình, thời gian học, số lần vắng, hoạt động ngoại khóa hoặc hỗ trợ giáo dục. Cách tiếp cận đó có thể tăng hiệu năng nhưng làm mô hình khó diễn giải hơn. Khóa luận chọn phạm vi hẹp hơn với G1 và G2 để tập trung vào chuỗi điểm số trước khi có kết quả cuối.

Điểm khác biệt của đề tài là cách đặt câu hỏi: liệu một kiến trúc CNN-BiLSTM ensemble có thể đạt hiệu năng cạnh tranh khi chỉ dùng hai mốc điểm hay không. Câu hỏi này không nhằm phủ nhận giá trị của mô hình dữ liệu bảng, mà nhằm khảo sát một hướng biểu diễn tuần tự trong phạm vi dữ liệu nhỏ.

Khi so sánh với các nghiên cứu sử dụng nhiều đặc trưng, cần lưu ý rằng kết quả không hoàn toàn tương đương. Một mô hình dùng hàng chục đặc trưng nên có

thể có lợi thế thông tin so với mô hình chỉ dùng G1/G2. Ngược lại, mô hình chỉ dùng G1/G2 có lợi thế về tính đơn giản và khả năng diễn giải trực tiếp.

Các nghiên cứu về mất cân bằng lớp cũng cho thấy oversampling không phải lúc nào cũng cải thiện kết quả. Nếu dữ liệu thiếu số có nhiều, sinh thêm mẫu quanh vùng nhiều có thể làm mô hình học sai. Vì vậy, việc dùng SMOTE trong khóa luận được xem là một lựa chọn có kiểm soát, không phải giả định luôn đúng.

Về đánh giá, nested cross-validation thường được khuyến nghị khi vừa cần chọn mô hình vừa cần ước lượng hiệu năng. Nếu chỉ dùng một validation split để chọn cấu hình rồi báo cáo kết quả trên cùng split, kết quả có thể bị lạc quan. Đây là lý do đề tài tách rõ nested CV và tập kiểm tra xác nhận.

Các nghiên cứu về recommender trong giáo dục thường nhấn mạnh tính cá nhân hóa và khả năng giải thích. Với dữ liệu hiện tại, đề tài không đủ điều kiện xây dựng hệ khuyến nghị học sâu theo hành vi dài hạn. Do đó, khuyến nghị theo luật là lựa chọn phù hợp với phạm vi khóa luận.

Từ tổng quan này, có thể thấy đóng góp của đề tài nằm ở việc kết hợp các thành phần quen thuộc trong một quy trình nhất quán: tạo nhãn ba lớp, xử lý mất cân bằng, lựa chọn cấu hình bằng nested CV, dùng ensemble xác suất và sinh khuyến nghị dễ hiểu.

Giá trị khoa học của kết quả không nằm ở việc tuyên bố mô hình phức tạp hơn thì luôn tốt hơn. Ngược lại, báo cáo cho thấy CNN-BiLSTM chỉ nhỉnh hơn nhẹ so với HistGradientBoosting trong nested CV. Đây là kết quả quan trọng vì nó giúp đặt mô hình học sâu vào đúng vị trí so với đối chứng dữ liệu bảng.

Một hướng nghiên cứu tiếp theo là so sánh nhiều nhóm đặc trưng: chỉ G1/G2, chỉ G2, toàn bộ đặc trưng điểm số và toàn bộ đặc trưng nền. Khi đó có thể trả lời rõ hơn phần nào của dữ liệu đóng góp nhiều nhất cho dự đoán.

Một hướng khác là dùng dữ liệu có nhiều mốc thời gian hơn. Nếu có điểm theo tuần hoặc log học tập theo phiên, kiến trúc tuần tự sẽ có điều kiện thể hiện ưu thế rõ hơn so với trường hợp chuỗi chỉ gồm hai bước.

2.12. Nhận xét về độ tin cậy của bằng chứng khoa học

Độ tin cậy của một báo cáo dự đoán không chỉ nằm ở giá trị metric cao mà còn ở cách metric được tạo ra. Nếu kết quả được chọn sau nhiều lần thử trên cùng tập kiểm tra, con số cuối cùng có thể phản ánh quá trình chọn may mắn hơn là năng lực thật của mô hình.

Trong đề tài, nested cross-validation đóng vai trò giảm rủi ro này. Dù không thể loại bỏ hoàn toàn biến động do dữ liệu nhỏ, nested CV giúp báo cáo có một ước lượng trung bình qua nhiều fold thay vì chỉ dựa vào một lần chia dữ liệu.

Tập kiểm tra xác nhận vẫn cần thiết vì nó cho thấy cấu hình cuối hoạt động như thế nào khi áp dụng một lần trên tập giữ riêng. Tuy nhiên, tập này không nên được xem là bằng chứng tuyệt đối. Cách đọc phù hợp là kết hợp cả nested CV, holdout, confusion matrix và phân tích theo lớp.

Một tiêu chí quan trọng khác là tính nhất quán giữa mô tả phương pháp và kết quả. Nếu báo cáo nói mô hình chỉ dùng G1/G2 thì mọi bảng metric phải được hiểu trong phạm vi đó. Không nên so sánh trực tiếp với nghiên cứu dùng nhiều đặc trưng hơn mà không ghi rõ khác biệt.

Độ tin cậy cũng phụ thuộc vào việc không phóng đại kết quả. Chênh lệch nhỏ giữa CNN-BiLSTM và HistGradientBoosting cần được gọi là hiệu năng cạnh tranh, không phải vượt trội mạnh. Cách diễn giải này phù hợp hơn với độ lệch chuẩn trong nested CV.

Cuối cùng, phần khuyến nghị cần được tách khỏi đánh giá mô hình. Một mô hình dự đoán tốt không tự động chứng minh khuyến nghị hiệu quả ngoài đời. Hai vấn đề này cần hai loại bằng chứng khác nhau.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT VÀ THIẾT KẾ THỰC NGHIỆM

3.1. Quy trình tổng quan

Quy trình của hệ thống bắt đầu từ dữ liệu học tập, sau đó thực hiện tiền xử lý, huấn luyện mô hình CNN-BiLSTM ensemble, tạo dự đoán thành tích và cuối cùng sinh khuyến nghị học tập tương ứng.

Quy trình tổng quan của hệ thống



Hình 1. Quy trình tổng quan của hệ thống

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Quy trình được thiết kế theo thứ tự từ dữ liệu, xử lý, mô hình đến khuyến nghị. Thứ tự này quan trọng vì mọi bước sau đều phụ thuộc vào giả định của bước trước. Nếu nhận được tạo sai hoặc dữ liệu bị rò rỉ, metric cuối cùng sẽ không còn phản ánh năng lực thật của mô hình.

Trong quá trình huấn luyện, dữ liệu kiểm tra xác nhận không tham gia vào việc fit scaler, tạo mẫu SMOTE, chọn siêu tham số hoặc chọn seed. Đây là nguyên tắc giúp kết quả đánh giá cuối có ý nghĩa hơn.

3.2. Bộ dữ liệu và định nghĩa nhãn

Bộ dữ liệu student-mat gồm 395 bản ghi. Trong phạm vi đề tài, G1 và G2 được sử dụng làm đầu vào chính, còn G3 được dùng để tạo nhãn mục tiêu.

Bảng 2. Định nghĩa ba lớp thành tích từ G3

Lớp	Điều kiện	Ý nghĩa
Low	$G3 \leq 9$	Nhóm có nguy cơ kết quả thấp, cần hỗ trợ sớm.
Medium	$10 \leq G3 \leq 14$	Nhóm đạt mức trung bình, cần duy trì và cải

		thiện.
High	$G3 \geq 15$	Nhóm có kết quả tốt, có thể mở rộng kiến thức.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Các cột G1, G2 và G3 đều nằm trên thang điểm 0-20. G1 và G2 có thể được hiểu như hai mốc đánh giá trước trong cùng môn học, còn G3 là kết quả cuối. Vì G3 có liên hệ trực tiếp với G1/G2, bài toán có tín hiệu dự đoán rõ, nhưng vẫn còn sai số do thay đổi kết quả giữa các mốc.

Tạo nhãn ba lớp làm giảm độ chi tiết của điểm G3 nhưng tăng khả năng diễn giải. Một mô hình dự đoán điểm 13 hay 14 có thể khó chuyển thành hành động, trong khi nhóm Medium dễ gắn với khuyến nghị duy trì và cải thiện. Đây là đánh đổi giữa độ chi tiết và tính ứng dụng.

Một hạn chế của cách chia lớp là các điểm gần ranh giới có thể rất giống nhau nhưng bị gán nhãn khác. Do đó, các lỗi gần ranh giới Low/Medium không nên bị diễn giải như lỗi hoàn toàn bất hợp lý của mô hình.

Ngưỡng 10 được sử dụng để phân biệt nhóm dưới mức đạt trên thang điểm 0-20. Ngưỡng 15 được dùng như định nghĩa vận hành cho nhóm kết quả cao trong thực nghiệm. Các ngưỡng này phục vụ mục tiêu mô hình hóa của đề tài, không được xem như chuẩn xếp loại phổ quát cho mọi hệ đào tạo.

Việc tạo nhãn từ G3 có một hệ quả quan trọng: G3 không được đưa vào đặc trưng đầu vào. G3 chỉ được dùng để xây dựng nhãn thật trong huấn luyện và đánh giá. Nếu G3 hoặc thông tin suy ra trực tiếp từ G3 lọt vào đặc trưng, kết quả dự đoán sẽ mất ý nghĩa vì mô hình đã nhìn thấy mục tiêu.

3.3. Tiền xử lý và chống rò rỉ dữ liệu

Dữ liệu được tách thành tập huấn luyện và tập kiểm tra trước khi thực hiện các bước liên quan đến học máy. Các thao tác chuẩn hóa và sinh mẫu tổng hợp chỉ được fit trên phần huấn luyện nhằm hạn chế rò rỉ thông tin.

MinMaxScaler được dùng để đưa G1 và G2 về thang giá trị phù hợp cho mô hình học sâu. Việc fit scaler trên tập huấn luyện rồi áp dụng cho tập kiểm tra giúp đảm bảo thông tin thông kê từ tập kiểm tra không ảnh hưởng đến huấn luyện.

SMOTE được áp dụng sau khi dữ liệu đã được chia. Điều này bảo đảm rằng mẫu tổng hợp không được tạo từ thông tin của tập kiểm tra. Trong nested CV, nguyên tắc tương tự được áp dụng bên trong từng fold.

Metadata phục vụ quản lý dữ liệu không được đưa vào ma trận đặc trưng. Nếu các định danh kỹ thuật lọt vào mô hình, mô hình có thể học mẫu không có ý nghĩa giáo dục và tạo ra kết quả không tổng quát.

Rõ ràng dữ liệu có thể xuất hiện ở nhiều bước nhỏ, chẳng hạn fit scaler trên toàn bộ dữ liệu trước khi chia train/test, sinh SMOTE trên toàn bộ dữ liệu hoặc để metadata nhận dạng bản ghi đi vào ma trận đặc trưng. Khóa luận xử lý các bước này theo nguyên tắc: mọi phép học tham số tiền xử lý chỉ được fit trên dữ liệu huấn luyện.

Đặc trưng đầu vào của mô hình cuối được giữ tối giản ở G1 và G2. Cách thiết kế này giúp giải thích kết quả rõ hơn: mô hình dự đoán từ hai mốc đánh giá trước, không dựa vào các biến nền khác. Đổi lại, mô hình có ít thông tin hơn và không thể nắm bắt đầy đủ bối cảnh gia đình, xã hội hoặc thói quen học tập.

3.4. Kiến trúc CNN-BiLSTM ensemble

Mỗi mô hình cơ sở nhận chuỗi [G1, G2], đưa qua Conv1D, BatchNorm, ReLU, Bi-LSTM, Dropout và lớp tuyến tính sinh ba logits. Softmax được dùng ở giai đoạn suy luận để chuyển logits thành xác suất ba lớp. Cấu hình cuối sử dụng 11 mô hình cơ sở với seed khác nhau; xác suất của các mô hình được trung bình hóa để tạo xác suất cuối.

Kiến trúc CNN-BiLSTM sử dụng trong đề tài



Hình 2. Kiến trúc CNN-BiLSTM của một mô hình cơ sở

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Bảng 3. Các khối chính của mô hình CNN-BiLSTM

Khối	Vai trò
Conv1D	Tạo biểu diễn cục bộ từ chuỗi điểm G1, G2.
BatchNorm + ReLU	Ổn định phân bố kích hoạt và thêm phi tuyến.
Bi-LSTM	Biểu diễn quan hệ giữa hai mốc điểm theo hai hướng.
Dropout	Giảm nguy cơ mô hình ghi nhớ dữ liệu huấn luyện.
Softmax	Tạo xác suất cho ba lớp Low, Medium, High.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Về tensor shape, mỗi bản ghi được biểu diễn thành chuỗi hai bước thời gian. Mỗi bước chứa một giá trị điểm sau chuẩn hóa. Khối Conv1D biến đổi chuỗi ngắn này thành biểu diễn có số kênh lớn hơn, sau đó Bi-LSTM đọc biểu diễn theo hai chiều.

Dropout được đặt sau các khối biểu diễn để giảm khả năng mô hình phụ thuộc quá mức vào một số activation cụ thể [10]. Với dữ liệu nhỏ, regularization là thành phần quan trọng vì mô hình có thể ghi nhớ tập huấn luyện nếu không được kiểm soát.

BatchNorm hỗ trợ ổn định huấn luyện bằng cách chuẩn hóa phân phối activation theo mini-batch [11]. Trong thực nghiệm nhỏ, thành phần này không bảo đảm tăng metric trong mọi trường hợp, nhưng giúp quá trình huấn luyện ít dao động hơn.

Linear head tạo ba logits. Trong huấn luyện với cross-entropy, logits được đưa trực tiếp vào hàm mất mát theo cách triển khai chuẩn của PyTorch [19]. Softmax chỉ cần thiết khi cần diễn giải đầu ra thành xác suất.

Ensemble 11 mô hình cơ sở được dùng ở giai đoạn suy luận cuối. Xác suất theo từng lớp được lấy trung bình, sau đó quy tắc quyết định sinh nhãn cuối. Vì vậy, tên mô hình cuối nên được hiểu là CNN-BiLSTM ensemble, không phải một mạng đơn.

Do chuỗi chỉ gồm hai mốc đánh giá, CNN-BiLSTM không được diễn giải như mô hình hóa toàn bộ quá trình học tập dài hạn. Kiến trúc được dùng để khảo sát biểu diễn có thứ tự giữa hai mốc điểm trong phạm vi đề tài. Đây là giới hạn phương pháp cần được nêu rõ để tránh phóng đại vai trò của Bi-LSTM.

Lớp tuyến tính cuối sinh ba logits tương ứng với Low, Medium và High. Softmax được sử dụng ở giai đoạn suy luận để chuyển logits thành xác suất. Cách mô tả này chính xác hơn so với việc xem Softmax là một tầng học tham số độc lập trong kiến trúc.

Với ensemble, mỗi mô hình cơ sở có cùng kiến trúc nhưng khác seed khởi tạo. Sau khi lấy xác suất từ từng mô hình, hệ thống tính trung bình xác suất theo từng lớp. Nhãn cuối được chọn từ xác suất tổng hợp này, không phải từ một mô hình đơn lẻ.

3.5. Tối ưu và lựa chọn mô hình

Siêu tham số được lựa chọn thông qua Optuna và nested cross-validation. Vòng ngoài có 5 fold để ước lượng hiệu năng, vòng trong có 4 fold để chọn cấu hình. Mỗi lần tìm kiếm sử dụng 16 thử nghiệm Optuna. Tập kiểm tra xác nhận không được dùng trong bước chọn cấu hình.

Bảng 4. Protocol chọn mô hình

Thành phần	Thiết lập
Outer CV	StratifiedKFold 5 fold, seed 42.
Inner CV	4 fold trên phần huấn luyện.

Optuna	16 thử nghiệm cho mỗi tìm kiếm bên trong.
Tiêu chí chính	F1-Macro.
Quy tắc chọn	Ưu tiên Macro-F1 trung bình cao; khi gần bằng nhau xét độ lệch chuẩn và độ phức tạp.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Không gian tìm kiếm của Optuna bao gồm learning rate, weight decay, số kênh CNN, kích thước hidden của LSTM, dropout, batch size, số epoch tối đa, patience và tỷ lệ SMOTE. Các tham số này chi phối cả năng lực biểu diễn lẫn mức regularization của mô hình.

Early stopping được dùng để dừng huấn luyện khi validation không cải thiện sau một số epoch [12]. Cơ chế này đặc biệt hữu ích với dữ liệu nhỏ vì tiếp tục huấn luyện quá lâu có thể làm mô hình học thuộc tập huấn luyện.

Trong báo cáo, cấu hình cuối không được chọn bằng cách nhìn vào tập kiểm tra xác nhận. Cấu hình được chọn từ quy trình validation/nested CV; tập kiểm tra chỉ được dùng sau cùng để xác nhận.

Khi nhiều cấu hình có kết quả gần nhau, độ lệch chuẩn và độ phức tạp mô hình cần được xem xét. Một cấu hình có trung bình cao hơn rất nhỏ nhưng dao động lớn hơn có thể không phải lựa chọn tốt hơn trong dữ liệu nhỏ.

Quy tắc quyết định cuối cùng được áp dụng trên xác suất đã tổng hợp của ensemble. Nếu quy tắc ngưỡng được dùng trong cấu hình, ngưỡng đó phải được chọn từ validation hoặc kết quả ngoài fold, không được chọn lại trên tập kiểm tra xác nhận. Khi không có lớp nào thỏa điều kiện ngưỡng, cách xử lý an toàn là chọn lớp có xác suất cao nhất.

Tập kiểm tra xác nhận chỉ được dùng sau khi cấu hình đã được đóng băng. Điều này giúp tách vai trò của tập kiểm tra khỏi quá trình chọn mô hình. Nếu tập kiểm tra được dùng để điều chỉnh seed, ngưỡng hoặc siêu tham số, kết quả công bố sẽ không còn là xác nhận độc lập của cấu hình đã chọn.

Bảng 5. Đối chiếu công bằng giữa mô hình đối chứng và mô hình đề xuất

Nội dung	HistGradientBoosting	CNN-BiLSTM
----------	----------------------	------------

		ensemble
Mục tiêu	Phân loại ba lớp Low/Medium/High	Phân loại ba lớp Low/Medium/High
Đầu vào chính	Cùng tập đặc trưng được xác định trong protocol thực nghiệm	Chuỗi G1, G2
Chọn mô hình	Trong nested cross- validation	Trong nested cross- validation
Metric chính	Macro-F1	Macro-F1
Diễn giải	Mô hình đối chứng mạnh cho dữ liệu bảng	Mô hình học sâu khảo sát biểu diễn tuần tự ngắn

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

3.6. Vai trò lưu trữ dữ liệu bằng PostgreSQL

PostgreSQL được sử dụng để lưu trữ dữ liệu học tập, kết quả dự đoán và thông tin khuyến nghị. Việc tổ chức dữ liệu tập trung hỗ trợ quản lý dữ liệu đầu vào, truy xuất kết quả mô hình và phục vụ chức năng khuyến nghị học tập.

Trong báo cáo chính, PostgreSQL chỉ được xem là thành phần lưu trữ và phục vụ hệ thống. Nó giúp dữ liệu đầu vào, kết quả dự đoán và khuyến nghị được quản lý tập trung. Tuy nhiên, PostgreSQL không phải nguyên nhân làm metric mô hình cao hơn và không được đưa vào như đóng góp thuật toán.

3.7. Logic khuyến nghị học tập

Từ kết quả dự đoán, hệ thống đưa ra gợi ý học tập tương ứng với từng mức thành tích. Nhóm dự đoán có nguy cơ cao được khuyến nghị củng cố kiến thức nền và theo dõi tiến độ; nhóm trung bình được khuyến nghị duy trì kế hoạch học tập và cải thiện nội dung còn yếu; nhóm đạt kết quả cao được định hướng duy trì thành tích và mở rộng kiến thức.

Bảng 6. Ánh xạ dự đoán thành khuyến nghị học tập

Mức dự đoán	Mức nguy cơ	Hướng khuyến nghị
Low	Cao	Ôn tập kiến thức nền, chia nhỏ mục tiêu học tập, theo dõi tiến độ thường xuyên.
Medium	Trung bình	Duy trì kế hoạch học, củng cố phần còn yếu, tăng luyện tập theo chủ đề.
High	Thấp	Duy trì kết quả, mở rộng kiến thức và luyện

Chương 3. Phương pháp đề xuất và thiết kế thực nghiệm

		bài nâng cao.
--	--	---------------

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Khuyến nghị trong đề tài là khuyến nghị theo luật dựa trên mức thành tích dự đoán, không phải hệ thống cá nhân hóa sâu. Điều này cần được gọi đúng tên vì hệ thống chưa học hành vi người dùng theo thời gian và chưa có dữ liệu phản hồi để tối ưu hóa hiệu quả can thiệp.

Ưu điểm của cách tiếp cận theo luật là dễ giải thích: người học thuộc nhóm Low sẽ nhận gợi ý củng cố nền tảng, nhóm Medium nhận gợi ý duy trì và cải thiện phần còn yếu, còn nhóm High nhận gợi ý mở rộng kiến thức. Hạn chế là mức độ cá nhân hóa còn thấp.

3.8. Biện minh thiết kế thực nghiệm

Thiết kế thực nghiệm của đề tài bắt đầu bằng việc xác định mục tiêu dự đoán trước khi chọn mô hình. Mục tiêu là phân loại ba mức thành tích từ G1 và G2, không phải tối đa hóa metric bằng mọi đặc trưng có sẵn. Cách xác định này giúp phạm vi mô hình nhất quán với câu hỏi nghiên cứu.

Việc giữ G3 chỉ để tạo nhãn là nguyên tắc quan trọng. Vì G3 là kết quả cuối cùng, bất kỳ thông tin trực tiếp nào từ G3 trong đặc trưng đầu vào đều làm mất ý nghĩa dự đoán. Điều này đặc biệt cần nhấn mạnh trong các bài toán giáo dục, nơi điểm số các kỳ có thể tương quan mạnh với nhau.

Quá trình chia dữ liệu cần được thực hiện trước các bước học tham số tiền xử lý. Nếu scaler hoặc oversampling nhìn thấy toàn bộ dữ liệu, mô hình sẽ hưởng lợi từ thông tin của tập kiểm tra. Dù sai lệch có thể nhỏ, nó vẫn làm kết quả thiếu tin cậy về mặt phương pháp.

Nested CV được dùng để giảm thiên lệch lựa chọn mô hình. Trong mỗi fold ngoài, quá trình chọn siêu tham số diễn ra bên trong phân huấn luyện. Fold ngoài chỉ dùng để đánh giá cấu hình đã chọn. Cấu trúc này tốn thời gian hơn nhưng phù hợp khi dữ liệu nhỏ.

Tập kiểm tra xác nhận được giữ riêng để đánh giá cấu hình cuối. Nó không thay thế nested CV, mà bổ sung một bước xác nhận cụ thể. Vì số mẫu kiểm tra chỉ

là 79, kết quả trên tập này cần được phân tích bằng confusion matrix và metric theo lớp.

Mô hình đối chứng HistGradientBoosting được chọn vì nó thường hoạt động tốt với dữ liệu bảng. Nếu CNN-BiLSTM không vượt rõ đối chứng này, điều đó không làm đề tài thất bại; nó cho thấy mô hình đề xuất cần được diễn giải như một hướng cạnh tranh trong điều kiện cụ thể.

Cấu hình cuối sử dụng weighted cross-entropy để xử lý mất cân bằng ở mức hàm mất mát. SMOTE xử lý ở mức dữ liệu huấn luyện. Hai cách này có thể bổ sung nhau, nhưng cũng làm tăng số thành phần cần kiểm soát trong thực nghiệm.

Early stopping và dropout được dùng để giảm overfitting. Với 316 mẫu huấn luyện, mô hình học sâu có thể dễ dàng học thuộc nếu huấn luyện quá lâu hoặc có quá nhiều tham số. Vì vậy, các cơ chế regularization không phải chi tiết phụ mà là điều kiện cần để huấn luyện hợp lý.

Việc dùng ensemble 11 seed làm tăng độ ổn định nhưng cũng khiến chi phí tính toán cao hơn. Trong môi trường triển khai thật, có thể cân cân nhắc giữa ensemble đầy đủ và mô hình đơn được hiệu chỉnh tốt hơn.

Thiết kế PostgreSQL trong hệ thống giúp quản lý dữ liệu và kết quả, nhưng trong báo cáo chính chỉ cần nêu vai trò lưu trữ. Các chi tiết kỹ thuật về bảng, trigger hoặc quyền truy cập không làm thay đổi bản chất mô hình và không nên chiếm trọng tâm khóa luận.

Khuyến nghị học tập được đặt sau dự đoán như một lớp ứng dụng. Nó không tham gia huấn luyện mô hình và không ảnh hưởng metric phân loại. Điều này giúp tách rõ đánh giá mô hình và đánh giá chức năng hỗ trợ người học.

Tổng thể, thiết kế thực nghiệm cố gắng cân bằng ba yêu cầu: đúng protocol đánh giá, đủ đơn giản để giải thích và đủ thực tế để kết nối với chức năng khuyến nghị học tập.

3.9. Công thức và diễn giải các thành phần chính

Với mỗi mẫu đầu vào $x = [G1, G2]$, mô hình cơ sở sinh vector logits z gồm ba phần tử tương ứng với ba lớp Low, Medium và High. Softmax chuyển logits thành xác suất p bằng cách chuẩn hóa hàm mũ của từng logit trên tổng ba logit.

Trong ensemble, nếu có M mô hình cơ sở, xác suất cuối của lớp k được tính bằng trung bình cộng xác suất lớp k qua M mô hình. Quy tắc này đơn giản nhưng có ưu điểm là giữ nguyên thang xác suất và dễ giải thích.

Hàm mất mát cross-entropy có trọng số tăng đóng góp của các lớp ít mẫu hơn. Nếu lớp High hoặc Low có ít mẫu hơn Medium, trọng số lớp giúp lỗi ở các lớp này ảnh hưởng nhiều hơn đến quá trình cập nhật mô hình.

SMOTE trong không gian đặc trưng $G1/G2$ tạo các điểm nội suy giữa những mẫu thuộc lớp thiểu số. Vì đầu vào chỉ có hai đặc trưng, trực quan có thể hiểu SMOTE như tạo thêm điểm trong mặt phẳng điểm số, nhưng các điểm đó vẫn chỉ là mẫu huấn luyện tổng hợp.

Early stopping theo dõi metric validation. Khi validation không cải thiện sau một số epoch, huấn luyện dừng lại để tránh mô hình tiếp tục tối ưu trên nhiễu của tập train. Đây là một dạng regularization theo thời gian huấn luyện.

Dropout ngẫu nhiên bỏ một phần activation trong huấn luyện, buộc mô hình không phụ thuộc quá mức vào một đường truyền cụ thể. Khi suy luận, dropout tắt và toàn bộ mạng được sử dụng để tạo dự đoán.

BatchNorm chuẩn hóa activation trong mini-batch, giúp gradient ổn định hơn. Với mạng nhỏ, BatchNorm không phải lúc nào cũng tạo cải thiện lớn, nhưng nó thường giúp huấn luyện ít nhạy với scale đầu vào.

Các công thức trên cho thấy mô hình cuối là tổ hợp của nhiều cơ chế: biểu diễn phi tuyến, xử lý chuỗi ngắn, regularization, cân bằng lớp và ensemble. Do đó, kết quả cuối là hiệu ứng tổng hợp, chưa thể quy riêng cho một thành phần nếu chưa làm ablation.

3.10. Kiểm soát diễn giải mô hình và dữ liệu

Khi dùng G1 và G2 làm chuỗi đầu vào, báo cáo cần tránh gọi đây là dữ liệu nhiều học kỳ hoặc tiến trình học tập dài hạn. Hai mốc đánh giá chỉ cho thấy một phần ngắn của quá trình học trong bộ dữ liệu.

Cách diễn giải hợp lý là mô hình học quan hệ giữa hai tín hiệu điểm số trước và mức kết quả cuối. Mô hình không nhìn thấy hành vi học tập chi tiết như thời gian làm bài, mức độ tham gia lớp học hoặc tiến độ ôn tập theo từng tuần.

Bởi vậy, nếu mô hình dự đoán Low, kết quả đó nên được hiểu là nguy cơ theo quan sát điểm số, không phải chẩn đoán nguyên nhân. Người học có thể thấp điểm vì nhiều lý do khác nhau mà mô hình không biết.

Tương tự, nếu mô hình dự đoán High, hệ thống không thể kết luận người học không cần hỗ trợ. Nó chỉ cho thấy theo dữ liệu G1/G2, mẫu đó giống nhóm có G3 cao trong tập huấn luyện.

Việc nhấn mạnh giới hạn diễn giải giúp báo cáo có tính học thuật hơn. Một khóa luận tốt không chỉ trình bày mô hình đạt kết quả cao, mà còn chỉ rõ mô hình không trả lời được những câu hỏi nào.

Trong triển khai thực tế, cần kết hợp dự đoán với đánh giá của giảng viên, phản hồi của người học và dữ liệu quá trình. Đây là hướng mở rộng tự nhiên nếu đề tài được phát triển sau khóa luận.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Thiết lập thực nghiệm

Thực nghiệm sử dụng 395 bản ghi của bộ student-mat. Dữ liệu được chia thành 316 bản ghi huấn luyện và 79 bản ghi kiểm tra xác nhận. Mô hình đối chứng là HistGradientBoosting, một mô hình mạnh cho dữ liệu bảng.

Bảng 7. Thiết lập thực nghiệm chính

Hạng mục	Giá trị
Dataset	student-mat, 395 bản ghi

Đầu vào mô hình	G1, G2
Đầu ra	3 lớp từ G3: Low, Medium, High
Tập huấn luyện	316 bản ghi
Tập kiểm tra xác nhận	79 bản ghi
Mô hình đối chứng	HistGradientBoosting
Mô hình đề xuất	CNN-BiLSTM ensemble

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.


Tập huấn luyện gồm 316 bản ghi, còn tập kiểm tra xác nhận gồm 79 bản ghi. Với kích thước này, mỗi lỗi dự đoán trên tập kiểm tra có ảnh hưởng đáng kể đến phần trăm metric. Chẳng hạn 7 lỗi trên 79 mẫu tương ứng Accuracy 0,9114.

Mô hình đối chứng HistGradientBoosting được chọn vì đây là đại diện mạnh cho dữ liệu bảng. Việc so sánh với một đối chứng yếu sẽ làm kết luận thiếu thuyết phục; do đó, chọn mô hình đối chứng mạnh giúp đánh giá CNN-BiLSTM nghiêm túc hơn.

4.2. Phân bố lớp

Phân bố lớp cho thấy nhóm Medium chiếm tỷ lệ lớn nhất. Vì dữ liệu không cân bằng hoàn toàn, báo cáo ưu tiên F1-Macro cùng metric theo từng lớp thay vì chỉ dựa vào Accuracy.

Phân bố ba lớp từ điểm G3



Hình 3. Phân bố ba lớp từ điểm G3

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.


Phân bố toàn bộ dữ liệu gồm 130 mẫu Low, 192 mẫu Medium và 73 mẫu High. Lớp Medium chiếm nhiều nhất, trong khi High có ít mẫu hơn. Điều này giải thích vì sao báo cáo không chỉ dựa vào Accuracy.

Nếu một mô hình dự đoán quá nhiều mẫu thành Medium, Accuracy có thể vẫn tương đối cao nhưng Recall của Low hoặc High sẽ giảm. Vì vậy, bảng kết quả theo lớp và confusion matrix là phần bắt buộc để hiểu chất lượng dự đoán.

4.3. So sánh với mô hình đối chứng

Trong nested cross-validation, CNN-BiLSTM đạt Macro-F1 trung bình 0,8736 với độ lệch chuẩn 0,0381. Mô hình đối chứng HistGradientBoosting đạt 0,8690 với độ lệch chuẩn 0,0358. Chênh lệch trung bình nhỏ, vì vậy kết luận phù hợp là mô hình đề xuất có hiệu năng cạnh tranh.

So sánh Macro-F1 trong nested cross-validation



Hình 4. So sánh Macro-F1 giữa CNN-BiLSTM và mô hình đối chứng

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Bảng 8. Kết quả nested cross-validation

Mô hình	Macro-F1 trung bình	Độ lệch chuẩn
HistGradientBoosting	0,8690	0,0358
CNN-BiLSTM ensemble	0,8736	0,0381

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Kết quả nested CV của hai mô hình nằm rất gần nhau: 0,8736 so với 0,8690. Khoảng cách này nhỏ hơn độ lệch chuẩn của cả hai mô hình, nên không nên diễn giải là CNN-BiLSTM vượt trội rõ rệt.

Giá trị của CNN-BiLSTM trong đề tài nằm ở việc đáp ứng yêu cầu khảo sát kiến trúc học sâu và tạo được hiệu năng cạnh tranh, không phải ở việc đánh bại mô hình dữ liệu bằng bằng một khoảng cách lớn.

Kết quả này cũng cho thấy với dữ liệu nhỏ và đầu vào chỉ G1/G2, mô hình đơn giản hoặc mô hình cây tăng cường vẫn là đối chứng rất mạnh. Đây là điểm quan trọng để báo cáo giữ cân bằng khoa học.

4.4. Kết quả trên tập kiểm tra xác nhận

Trên tập kiểm tra 79 bản ghi, mô hình đạt Accuracy 0,9114 và F1-Macro 0,9256. Precision-Macro đạt 0,9235 và Recall-Macro đạt 0,9305.

Bảng 9. Metric trên tập kiểm tra xác nhận

Metric	Giá trị	Diễn giải
Accuracy	0,9114	Tỷ lệ dự đoán đúng tổng thể.
Precision-Macro	0,9235	Trung bình Precision của ba lớp.
Recall-Macro	0,9305	Trung bình Recall của ba lớp.
F1-Macro	0,9256	Chỉ số chính để đánh giá cân bằng giữa các lớp.
RMSE	0,2977	Chẩn đoán trên mã lớp 0/1/2, không phải đầu ra hồi quy.
R ²	0,8226	Chẩn đoán trên mã lớp 0/1/2, không phải đầu ra hồi quy.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Accuracy 0,9114 tương ứng 72 dự đoán đúng trên 79 mẫu kiểm tra. Vì tập kiểm tra không lớn, báo cáo đặt con số này trong bối cảnh của các metric khác thay vì xem nó là kết luận độc lập.

F1-Macro 0,9256 cho thấy hiệu năng trung bình theo lớp cao hơn kết quả nested CV trung bình. Sự khác biệt này có thể đến từ thành phần split, số mẫu ít hoặc cấu hình cuối hoạt động tốt trên tập xác nhận hiện tại.

4.5. Kết quả theo từng lớp

Bảng 10. Precision, Recall và F1 theo từng lớp

Lớp	Precision	Recall	F1	Support
Low	0.8276	0.9231	0.8727	26
Medium	0.9429	0.8684	0.9041	38
High	1.0000	1.0000	1.0000	15

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Lớp Low có Recall 0,9231, nghĩa là phần lớn mẫu Low được phát hiện đúng. Precision của Low là 0,8276, thấp hơn hai lớp còn lại, cho thấy một số mẫu Medium bị dự đoán nhầm thành Low.

Lớp Medium có F1 0,9041, thấp hơn High nhưng vẫn ở mức tốt. Lớp này là vùng trung gian giữa Low và High nên có thể chứa nhiều trường hợp biên hơn, đặc biệt gần ngưỡng G3 bằng 9/10 hoặc 14/15.

Lớp High đạt F1 1,0000 trên 15 mẫu. Đây là kết quả tốt trong tập kiểm tra hiện tại, nhưng support nhỏ nên cần trình bày cùng cảnh báo về độ ổn định khi gặp dữ liệu mới.

4.6. Ma trận nhầm lẫn và phân tích lỗi

Ma trận nhầm lẫn cho thấy lỗi chủ yếu nằm giữa Low và Medium: 2 mẫu Low bị dự đoán thành Medium và 5 mẫu Medium bị dự đoán thành Low. Lớp High có 15/15 mẫu được dự đoán đúng.

Ma trận nhầm lẫn trên tập kiểm tra

		Low	Medium	High
Nhân thực tế	Low	24	2	0
	Medium	5	33	0
	High	0	0	15
		Nhân dự đoán		

Hình 5. Ma trận nhầm lẫn trên tập kiểm tra xác nhận

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.


Có 5 mẫu Medium bị dự đoán thành Low. Trong bối cảnh ứng dụng hỗ trợ học tập, lỗi này có xu hướng thận trọng hơn vì hệ thống có thể đưa ra hỗ trợ nhiều hơn mức cần thiết. Tuy nhiên, nếu xảy ra thường xuyên, nó có thể làm người học nhận khuyến nghị không phù hợp.

Có 2 mẫu Low bị dự đoán thành Medium. Đây là lỗi đáng chú ý hơn vì nhóm cần hỗ trợ có thể bị đánh giá nhẹ hơn nguy cơ thật. Do đó, khi triển khai thực tế, nhóm gần ranh giới Low/Medium nên được xem xét thêm bằng thông tin sự phạm.

Không có lỗi liên quan đến lớp High trong tập kiểm tra. Tuy nhiên, vì chỉ có 15 mẫu High, kết quả này cần được kiểm chứng trên dữ liệu lớn hơn trước khi kết luận mô hình ổn định với nhóm thành tích cao.

4.7. Đường Precision-Recall

Đường Precision-Recall cho từng lớp được sử dụng để quan sát quan hệ giữa Precision và Recall khi thay đổi ngưỡng xác suất. Đây là cách nhìn bổ sung bên cạnh F1-Macro.



Hình 6. Đường Precision-Recall theo từng lớp

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Đường Precision-Recall cho lớp High gần mức lý tưởng vì mô hình tách tốt lớp này trong split hiện tại. Với lớp Low và Medium, đường cong giảm ở một số vùng Recall cao, phản ánh sự đánh đổi giữa phát hiện nhiều mẫu và giữ Precision.

Trong thực tế, nếu mục tiêu ưu tiên phát hiện nhóm Low, hệ thống có thể chấp nhận Precision thấp hơn để tăng Recall. Tuy nhiên, báo cáo không điều chỉnh ngưỡng theo tập kiểm tra; biểu đồ chỉ dùng để phân tích sau đánh giá.

4.8. Kết quả khuyến nghị học tập

Từ nhãn dự đoán, hệ thống sinh khuyến nghị học tập theo ba mức nguy cơ. Chức năng này không thay thế đánh giá của giảng viên mà đóng vai trò gợi ý ban đầu để người học có định hướng ôn tập phù hợp.

Bảng 11. Ví dụ khuyến nghị học tập

Trường hợp	Gợi ý học tập
Dự đoán Low	Ôn lại kiến thức nền, lập kế hoạch học theo tuần, ưu tiên bài tập cơ bản và trao đổi với giảng viên khi gặp khó khăn.
Dự đoán Medium	Duy trì nhịp học hiện tại, tập trung cải thiện chủ đề còn yếu và luyện thêm bài tập vận dụng.
Dự đoán High	Duy trì kết quả, thử bài tập nâng cao và hỗ trợ nhóm học tập nếu phù hợp.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Khuyến nghị Low tập trung vào việc giảm rủi ro: ôn nền tảng, chia nhỏ kế hoạch và trao đổi với giảng viên khi gặp khó khăn. Khuyến nghị Medium tập trung vào duy trì nhịp học và cải thiện chủ đề yếu. Khuyến nghị High tập trung vào duy trì kết quả và mở rộng kiến thức.

Các gợi ý này được thiết kế để dễ hiểu và không phụ thuộc vào thuật ngữ kỹ thuật của mô hình. Người học không cần biết kiến trúc CNN-BiLSTM để hiểu vì sao mình nhận được nhóm gợi ý tương ứng.

Tuy nhiên, khuyến nghị hiện chưa được kiểm chứng bằng phản hồi người học. Vì vậy, báo cáo chỉ kết luận hệ thống tạo được gợi ý hợp lý về mặt logic, chưa kết luận gợi ý làm tăng kết quả học tập.

Chênh lệch giữa kết quả nested cross-validation và kết quả trên tập kiểm tra xác nhận cần được diễn giải thận trọng. Macro-F1 trung bình trong nested CV là 0,8736, trong khi F1-Macro trên tập kiểm tra xác nhận là 0,9256. Với dữ liệu nhỏ, một tập kiểm tra 79 mẫu có thể có thành phần lớp thuận lợi hơn hoặc ít trường hợp biên hơn so với các fold khác.

Vì lý do đó, nested cross-validation được xem là ước lượng ổn định hơn về hiệu năng kỳ vọng, còn tập kiểm tra xác nhận cho biết cấu hình cuối hoạt động như thế nào trên một split đã giữ riêng. Báo cáo không sử dụng kết quả 0,9256 để khẳng định mô hình vượt trội tuyệt đối so với đối chứng.

Lớp High đạt Precision, Recall và F1 đều bằng 1,0000 trên 15 mẫu kiểm tra. Kết quả này cho thấy mô hình xử lý tốt các trường hợp High trong split hiện tại, nhưng support chỉ gồm 15 mẫu nên chưa đủ để kết luận rằng mô hình luôn nhận diện hoàn hảo lớp High trên dữ liệu mới.

Các lỗi còn lại tập trung giữa Low và Medium. Đây là dạng lỗi hợp lý về mặt bài toán vì ranh giới giữa G3 bằng 9 và G3 bằng 10 nằm sát nhau. Một thay đổi nhỏ trong kết quả học tập cuối cùng có thể làm mẫu chuyển từ Low sang Medium, trong khi G1 và G2 chưa chắc thể hiện rõ ranh giới đó.

Khi so sánh với HistGradientBoosting, cần hiểu đây là mô hình đối chứng mạnh cho dữ liệu bảng. Chênh lệch Macro-F1 trung bình 0,0046 trong nested CV là nhỏ so với độ lệch chuẩn của hai mô hình. Vì vậy, kết luận đúng mức là CNN-BiLSTM ensemble có hiệu năng cạnh tranh và phù hợp với yêu cầu khảo sát kiến trúc học sâu của đề tài.

Bảng 12. Diễn giải chênh lệch giữa nested CV và tập kiểm tra xác nhận

Kết quả	Giá trị	Cách diễn giải
Nested CV CNN-BiLSTM	$0,8736 \pm 0,0381$	Ước lượng ổn định hơn về hiệu năng kỳ vọng trên dữ liệu nhỏ.
Tập kiểm tra xác nhận	F1-Macro 0,9256	Xác nhận cấu hình cuối trên 79 mẫu đã tách riêng.
Chênh lệch	Khoảng 0,0520	Có thể do biến động split và số mẫu nhỏ; không dùng để kết luận vượt trội tuyệt đối.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

4.9. Hạn chế của kết quả thực nghiệm

Hạn chế lớn nhất là kích thước dữ liệu chỉ gồm 395 bản ghi. Mô hình sử dụng chuỗi rất ngắn gồm hai mốc G1 và G2 nên không thể diễn giải như mô hình hóa toàn bộ tiến trình học tập dài hạn.

Nghiên cứu chưa thực hiện ablation như CNN-only, Bi-LSTM-only, G2-only hoặc logistic regression, vì vậy chưa thể quy hiệu năng cuối cho từng thành phần kiến trúc riêng lẻ. Khuyến nghị hiện được xây dựng theo luật và chưa được đánh giá tác động thực tế thông qua phản hồi người học hoặc nghiên cứu can thiệp.

Một hạn chế khác là chưa có ablation để tách đóng góp của từng thành phần. Chưa thể biết phần tăng hiệu năng đến từ Conv1D, Bi-LSTM, ensemble, SMOTE hay weighted loss. Đây là hướng cần bổ sung nếu tiếp tục nghiên cứu.

Dữ liệu chỉ có một môn học trong bộ student-mat nên mô hình chưa được kiểm chứng trên nhiều bối cảnh môn học. Một mô hình hoạt động tốt với môn Toán chưa chắc giữ nguyên hiệu năng với các môn có cấu trúc đánh giá khác.

Ngoài ra, các biến xã hội và hành vi học tập trong bộ dữ liệu gốc không được dùng trong mô hình cuối. Điều này giúp bài toán rõ ràng hơn nhưng cũng làm mô hình bỏ qua nhiều thông tin có thể hữu ích.

4.10. Thảo luận tổng hợp kết quả

Kết quả thực nghiệm cho thấy mô hình dự đoán tốt trên tập kiểm tra xác nhận, nhưng cách diễn giải cần đặt trong bối cảnh dữ liệu nhỏ. Accuracy 0,9114 là kết quả tích cực, song chỉ tương ứng với 72/79 mẫu đúng. Một vài lỗi thay đổi có thể làm metric biến động đáng kể.

F1-Macro 0,9256 cao hơn nested CV trung bình. Điều này không nhất thiết mâu thuẫn, vì nested CV đo hiệu năng qua nhiều fold, còn tập kiểm tra xác nhận là một split cụ thể. Với dữ liệu nhỏ, khác biệt giữa các split là hiện tượng có thể xảy ra.

Khi so sánh CNN-BiLSTM với HistGradientBoosting, kết quả nested CV mới là căn cứ công bằng hơn. Khoảng cách 0,0046 cho thấy CNN-BiLSTM nhỉnh hơn nhẹ nhưng không vượt trội mạnh. Đây là kết luận trung thực và phù hợp với số liệu.

Phân tích theo lớp cho thấy mô hình đạt kết quả tốt nhất ở lớp High. Tuy nhiên, lớp này có support 15 trên tập kiểm tra, nên kết quả hoàn hảo cần được xem là tín hiệu tích cực trong split hiện tại, không phải bảo đảm tuyệt đối.

Lớp Low có Recall cao, điều này có lợi trong bối cảnh phát hiện nhóm cần hỗ trợ. Dù vậy, Precision thấp hơn cho thấy một số mẫu Medium bị đưa xuống Low. Trong ứng dụng thật, lỗi này có thể dẫn đến hỗ trợ nhiều hơn mức cần thiết.

Lỗi Low-Medium phản ánh tính chất gần ranh giới của bài toán. Khi G3 ở gần ngưỡng 9/10, chỉ một điểm khác biệt có thể đổi lớp. Vì mô hình chỉ nhìn G1/G2, việc phân biệt các trường hợp biên là khó.

Precision-Recall curve giúp xác nhận rằng chất lượng xác suất khác nhau theo từng lớp. Lớp High có AP cao, trong khi Low và Medium có đường cong biến động hơn. Điều này phù hợp với confusion matrix.

Kết quả RMSE và R^2 chỉ nên được xem như chẩn đoán trên mã lớp thứ tự. Nếu trình bày chúng như kết quả hồi quy, người đọc có thể hiểu sai mục tiêu mô hình. Báo cáo vì vậy giữ F1-Macro làm metric chính.

Chức năng khuyến nghị giúp kết nối dự đoán với hành động học tập. Tuy nhiên, vì chưa có phản hồi người học, phần này chỉ chứng minh được logic sinh gợi ý, chưa chứng minh hiệu quả cải thiện thành tích.

Từ góc độ khoa học, kết quả mạnh nhất của đề tài là quy trình đánh giá có kiểm soát và phân tích thận trọng. Đề tài không khẳng định mô hình sâu luôn tốt hơn mô hình nông, mà cho thấy CNN-BiLSTM ensemble đạt hiệu năng cạnh tranh trong điều kiện đã nêu.

Từ góc độ ứng dụng, mô hình có thể là thành phần hỗ trợ ra quyết định ban đầu. Nếu triển khai thật, hệ thống cần thêm dữ liệu mới, cơ chế giám sát sai lệch và đánh giá tác động của khuyến nghị.

Do đó, kết luận cuối nên cân bằng: mô hình đạt kết quả tốt trên bộ dữ liệu benchmark, nhưng vẫn cần mở rộng dữ liệu, ablation và đánh giá người dùng trước khi xem là giải pháp hoàn chỉnh.

4.11. Ý nghĩa thực tiễn và giới hạn sử dụng

Trong môi trường đào tạo, một mô hình dự đoán chỉ hữu ích khi kết quả được dùng đúng cách. Nếu xem nhãn Low như kết luận cố định về năng lực người học, hệ thống có thể gây tác động tiêu cực. Vì vậy, dự đoán nên được dùng như tín hiệu cần quan sát thêm.

Nhóm dự đoán Low nên được hiểu là nhóm có nguy cơ trong phạm vi dữ liệu điểm số, không phải nhóm chắc chắn thất bại. Giáo viên hoặc cố vấn cần kết hợp thêm thông tin về thái độ học tập, hoàn cảnh cá nhân và quá trình tham gia lớp học.

Nhóm Medium là nhóm cần được chú ý vì nhiều lỗi xảy ra ở ranh giới Low-Medium. Những người học này có thể chuyển xuống nhóm nguy cơ nếu không duy trì tiến độ, hoặc chuyển lên nhóm tốt hơn nếu được hỗ trợ đúng thời điểm.

Nhóm High không nên chỉ được bỏ qua vì mô hình dự đoán tốt. Khuyến nghị cho nhóm này có thể tập trung vào duy trì động lực, mở rộng kiến thức và tham gia hỗ trợ nhóm học tập, nhưng vẫn cần tránh tạo áp lực không cần thiết.

Các khuyến nghị trong báo cáo có tính gợi ý, không phải kế hoạch học tập cá nhân hóa đầy đủ. Một lộ trình cá nhân hóa thật sự cần biết người học yếu ở chủ đề nào, có bao nhiêu thời gian học, phản hồi ra sao với gợi ý trước đó và mục tiêu cá nhân là gì.

Nếu triển khai trong hệ thống thật, cần có cơ chế phản hồi. Người học hoặc giảng viên nên có quyền xác nhận gợi ý có phù hợp hay không. Phản hồi này có thể trở thành dữ liệu cho phiên bản recommender nâng cao hơn.

Ngoài ra, cần quan tâm đến đạo đức dữ liệu. Dữ liệu học tập là dữ liệu nhạy cảm; việc dự đoán và gợi ý cần minh bạch, hạn chế định kiến và không dùng để gán nhãn người học một cách cứng nhắc.

Những giới hạn này không làm giảm giá trị của khóa luận, mà xác định ranh giới sử dụng đúng. Một mô hình dự đoán tốt trong thí nghiệm vẫn cần được kiểm chứng thêm trước khi trở thành công cụ hỗ trợ giáo dục thực tế.

4.12. Phân tích ý nghĩa từng nhóm kết quả

Với nhóm Low, Recall cao là tín hiệu tốt vì mục tiêu giáo dục thường ưu tiên phát hiện sớm nhóm cần hỗ trợ. Tuy nhiên, Precision thấp hơn nghĩa là có một số người học trung bình bị xếp vào nhóm nguy cơ cao. Trong ứng dụng thật, điều này cần được xử lý bằng cách diễn đạt khuyến nghị nhẹ nhàng, không gán nhãn tiêu cực.

Với nhóm Medium, mô hình phải phân biệt các trường hợp gần hai ranh giới: gần Low và gần High. Đây là lớp khó vì nó nằm giữa thang điểm. Kết quả F1 0,9041 cho thấy mô hình xử lý khá tốt, nhưng confusion matrix vẫn cho thấy lỗi với Low.

Với nhóm High, kết quả 15/15 đúng tạo ấn tượng mạnh nhưng phải đi kèm cảnh báo support nhỏ. Nếu tập kiểm tra có thêm nhiều mẫu High hơn hoặc chứa các trường hợp biên gần G3 bằng 15, kết quả có thể thay đổi.

Nhìn theo hệ thống khuyến nghị, ba nhóm kết quả tạo ra ba kiểu hỗ trợ khác nhau. Low cần giảm rủi ro, Medium cần củng cố và High cần mở rộng. Cách ánh xạ này dễ hiểu nhưng chưa đủ để cá nhân hóa theo nguyên nhân học tập cụ thể.

Nhìn theo nghiên cứu mô hình, lỗi Low-Medium gợi ý rằng ranh giới điểm số là nơi cần phân tích thêm. Nếu có dữ liệu chi tiết hơn, có thể kiểm tra liệu các lỗi này liên quan đến sự thay đổi từ G2 sang G3, số lần vắng học hoặc các yếu tố nền khác hay không.

Những phân tích này giúp chuyển báo cáo từ việc nêu metric sang giải thích metric. Đây là yêu cầu quan trọng của một khóa luận, vì hội đồng thường quan tâm không chỉ mô hình đạt bao nhiêu mà còn vì sao kết quả có hình dạng như vậy.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết quả đạt được

Khóa luận đã xây dựng được mô hình CNN-BiLSTM ensemble để dự đoán thành tích học tập ba lớp từ hai mốc điểm G1 và G2. Mô hình đạt F1-Macro 0,9256 trên tập kiểm tra xác nhận và có hiệu năng nested cross-validation cạnh tranh với mô hình đối chứng HistGradientBoosting.

Đề tài cũng xây dựng chức năng khuyến nghị học tập theo luật dựa trên kết quả dự đoán, giúp chuyển đầu ra của mô hình thành gợi ý học tập dễ hiểu hơn cho người dùng cuối.

5.2. Hạn chế

Dữ liệu thực nghiệm có quy mô nhỏ và thuộc bối cảnh học sinh trung học Bồ Đào Nha, do đó chưa thể khẳng định khả năng áp dụng trực tiếp cho sinh viên Việt Nam. Đầu vào G1, G2 chỉ gồm hai mốc đánh giá nên không phản ánh toàn bộ quá trình học tập dài hạn.

Mô hình có năng lực tương đối lớn so với số mẫu huấn luyện. Dropout, early stopping, SMOTE và ensemble giúp giảm rủi ro overfitting nhưng không loại bỏ hoàn toàn rủi ro này. Phần khuyến nghị mới dừng ở mức logic theo luật, chưa có đánh giá tác động thực tế.

5.3. Hướng phát triển

Hướng phát triển đầu tiên là kiểm chứng mô hình trên dữ liệu lớn hơn, nhiều môn học hơn và gần với bối cảnh đại học Việt Nam hơn.

Hướng thứ hai là bổ sung các thí nghiệm ablation và baseline đơn giản như G2-only, logistic regression, CNN-only hoặc Bi-LSTM-only. Hướng thứ ba là đánh giá khuyến nghị học tập thông qua phản hồi của người học, giảng viên hoặc nghiên cứu can thiệp theo thời gian.

Nhìn tổng thể, kết quả cho thấy hai điểm G1 và G2 đã chứa tín hiệu dự báo đáng kể cho G3. Điều này phù hợp với trực giác giáo dục: kết quả ở các mốc đánh giá trước thường liên quan đến kết quả cuối cùng. Tuy nhiên, chính vì tín hiệu này mạnh, cần tránh diễn giải mô hình như phát hiện đầy đủ nguyên nhân của thành tích học tập.

Hướng phát triển có giá trị nhất là mở rộng dữ liệu theo thời gian và theo nhiều môn học. Khi có nhiều mốc đánh giá hơn, vai trò của LSTM hoặc Bi-LSTM sẽ có cơ sở mạnh hơn vì mô hình thật sự được học trên chuỗi dài hơn. Khi đó, có thể so sánh kiến trúc tuần tự với các mô hình dữ liệu bảng trong điều kiện công bằng hơn.

Một hướng khác là đánh giá khuyến nghị thông qua phản hồi người học hoặc nghiên cứu can thiệp. Chỉ khi có dữ liệu về việc người học nhận khuyến nghị, thực

hiện hành động và cải thiện kết quả, mới có thể kết luận về hiệu quả thực tế của thành phần khuyến nghị.

5.4. Kết luận

Trong phạm vi khóa luận, mô hình CNN-BiLSTM ensemble đã đáp ứng mục tiêu dự đoán thành tích học tập trên bộ dữ liệu student-mat và tạo được đầu ra khuyến nghị học tập có giải thích. Kết quả cho thấy hướng kết hợp học sâu với đánh giá thực nghiệm có kiểm soát là phù hợp cho bài toán dự đoán thành tích học tập, nhưng vẫn cần mở rộng dữ liệu và kiểm chứng thực tế trước khi triển khai trong môi trường đào tạo thật.

5.5. Bài học rút ra từ quá trình thực hiện

Bài học đầu tiên là dữ liệu nhỏ đòi hỏi quy trình đánh giá nghiêm ngặt hơn, không phải ít nghiêm ngặt hơn. Khi số mẫu ít, mỗi quyết định về split, chọn siêu tham số hoặc xử lý mất cân bằng đều có thể làm kết quả thay đổi. Vì vậy, báo cáo cần trình bày rõ cách đánh giá thay vì chỉ tập trung vào metric cuối.

Bài học thứ hai là mô hình phức tạp cần được đặt cạnh mô hình đối chứng mạnh. Nếu không có HistGradientBoosting, rất dễ kết luận CNN-BiLSTM tốt chỉ vì không có chuẩn so sánh phù hợp. Kết quả nested CV cho thấy đối chứng dữ liệu bằng vẫn rất cạnh tranh.

Bài học thứ ba là khuyến nghị học tập cần được diễn giải đúng mức. Một gợi ý theo luật có thể hữu ích để minh họa đầu ra hệ thống, nhưng chưa đủ để gọi là cá nhân hóa sâu. Sự thận trọng này giúp báo cáo tránh overclaim.

Bài học thứ tư là các hình và bảng metric chỉ có giá trị khi đi kèm phân tích. Confusion matrix cho thấy lỗi tập trung ở Low-Medium; PR curve cho thấy chất lượng xác suất theo lớp; bảng per-class giúp giải thích vì sao F1-Macro cao. Những bảng chứng này bổ sung cho nhau.

Bài học cuối cùng là cần phân biệt rõ kết quả thực nghiệm và kết luận triển khai. Kết quả trên student-mat cho thấy hướng tiếp cận khả thi trong phạm vi benchmark, nhưng triển khai thực tế cần dữ liệu mới, giám sát đạo đức và đánh giá tác động của khuyến nghị.

Khi bảo vệ khóa luận, các câu hỏi có khả năng xuất hiện nhiều nhất là vì sao chỉ dùng G1/G2, vì sao dùng Bi-LSTM khi chuỗi ngắn, vì sao baseline gần bằng mô hình đề xuất và vì sao High đạt F1 bằng 1,0000. Báo cáo đã bổ sung phần trả lời trực tiếp cho các điểm này để người đọc thấy rõ giới hạn và lý do thiết kế.

Một điểm quan trọng khác là không nhầm lẫn giữa kết quả mô hình và ý nghĩa giáo dục. Mô hình dự đoán nhóm thành tích, còn việc hỗ trợ người học cần thêm đối thoại, quan sát và phản hồi. Vì vậy, hệ thống được mô tả như công cụ hỗ trợ, không phải cơ chế ra quyết định tự động.

Các hình và bảng trong Chương 4 được giữ ở mức cần thiết để tránh làm báo cáo giống phụ lục kiểm thử. Mỗi hình đều phục vụ một câu hỏi: dữ liệu phân bố ra sao, mô hình so với đối chứng thế nào, lỗi nằm ở đâu và xác suất phân biệt các lớp tốt đến mức nào.

Nhìn lại toàn bộ quy trình, đóng góp của đề tài là sự kết hợp giữa mô hình học sâu, đánh giá thực nghiệm có đối chứng và đầu ra khuyến nghị dễ hiểu. Ba thành phần này tạo thành một hệ thống hoàn chỉnh ở mức khóa luận, dù mỗi thành phần vẫn còn hướng phát triển riêng.

Nếu tiếp tục mở rộng, ưu tiên không nên là thêm kiến trúc phức tạp ngay lập tức, mà là thu thập dữ liệu phù hợp hơn, tăng số mốc đánh giá và thực hiện ablation. Khi đó có thể đánh giá rõ hơn liệu CNN, Bi-LSTM hay ensemble thật sự đóng góp bao nhiêu vào hiệu năng.

Từ góc nhìn kỹ năng nghiên cứu, đề tài cho thấy việc trình bày trung thực quan trọng không kém việc đạt kết quả cao. Một kết quả vừa phải nhưng được đánh giá đúng protocol và phân tích kỹ có giá trị hơn một kết quả cao nhưng thiếu đối chứng hoặc thiếu giải thích.

Vì vậy, bản báo cáo cuối được định hướng theo tinh thần thận trọng: nêu đúng mô hình đã xây dựng, đúng dữ liệu đã dùng, đúng metric đã đạt và đúng giới hạn chưa giải quyết. Đây là cách trình bày phù hợp hơn cho một khóa luận kỹ thuật có yếu tố thực nghiệm.

Báo cáo cũng cố gắng giữ cân bằng giữa phần thuật toán và phần ứng dụng. Nếu chỉ trình bày CNN-BiLSTM, đề tài sẽ dừng ở mức mô hình dự đoán; nếu chỉ trình bày khuyến nghị, đề tài thiếu nền tảng đánh giá định lượng. Sự kết hợp hai phần giúp sản phẩm có câu chuyện hoàn chỉnh hơn.

Tóm lại, khóa luận không chỉ trả lời mô hình dự đoán được bao nhiêu, mà còn trả lời mô hình dự đoán như thế nào, được kiểm chứng ra sao, sai ở đâu và có thể chuyển thành hỗ trợ học tập ở mức nào. Đây là trục nội dung chính của bản báo cáo đã được tinh chỉnh.

Trong quá trình đọc kết quả, cần nhớ rằng điểm số là biểu hiện cuối cùng của nhiều yếu tố học tập. Mô hình dùng G1 và G2 nên chỉ nhìn thấy một lát cắt rất hẹp của thực tế. Điều này giải thích vì sao báo cáo luôn tách kết quả dự đoán khỏi kết luận về nguyên nhân.

Nếu có thêm dữ liệu quá trình như bài nộp theo tuần, thời lượng học, tương tác trên hệ thống học trực tuyến hoặc phản hồi của giảng viên, hướng nghiên cứu có thể mở rộng sang mô hình chuỗi đúng nghĩa. Khi đó, vai trò của Bi-LSTM sẽ được kiểm chứng trong điều kiện phù hợp hơn.

Đối với hội đồng chấm khóa luận, phần quan trọng không phải chỉ là tên kiến trúc CNN-BiLSTM mà là sự nhất quán giữa câu hỏi nghiên cứu, dữ liệu, mô hình, metric và kết luận. Bản báo cáo đã được chỉnh để các phần này liên kết trực tiếp với nhau.

Vì vậy, những giới hạn được nêu trong báo cáo không phải là điểm yếu cần che giấu, mà là phần bắt buộc của một nghiên cứu thực nghiệm nghiêm túc. Chúng chỉ ra điều gì đã được chứng minh và điều gì cần tiếp tục kiểm chứng.

TÀI LIỆU THAM KHẢO

- [1] P. Cortez and A. M. G. Silva, "Using data mining to predict secondary school student performance," in Proc. 5th Future Business Technology Conf., 2008, pp. 5-12.
- [2] C. Romero and S. Ventura, "Educational data mining: A review of the state of the art," IEEE Trans. Syst., Man, Cybern. C, vol. 40, no. 6, pp. 601-618, 2010.
- [3] C. Romero and S. Ventura, "Data mining in education," Wiley Interdiscip. Rev. Data Min. Knowl. Discov., vol. 3, no. 1, pp. 12-27, 2013.
- [4] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," Proc. IEEE, vol. 86, no. 11, pp. 2278-2324, 1998.
- [5] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Comput., vol. 9, no. 8, pp. 1735-1780, 1997.
- [6] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," IEEE Trans. Signal Process., vol. 45, no. 11, pp. 2673-2681, 1997.
- [7] B. Lakshminarayanan, A. Pritzel, and C. Blundell, "Simple and scalable predictive uncertainty estimation using deep ensembles," in Proc. NeurIPS, 2017.
- [8] N. V. Chawla et al., "SMOTE: Synthetic minority over-sampling technique," J. Artif. Intell. Res., vol. 16, pp. 321-357, 2002.
- [9] H. He, Y. Bai, E. A. Garcia, and S. Li, "ADASYN: Adaptive synthetic sampling approach for imbalanced learning," in Proc. IEEE IJCNN, 2008.
- [10] N. Srivastava et al., "Dropout: A simple way to prevent neural networks from overfitting," J. Mach. Learn. Res., vol. 15, pp. 1929-1958, 2014.

- [11] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in Proc. ICML, 2015.
- [12] L. Prechelt, "Early stopping - but when?" in Neural Networks: Tricks of the Trade, Springer, 1998.
- [13] T. Akiba et al., "Optuna: A next-generation hyperparameter optimization framework," in Proc. KDD, 2019.
- [14] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in Proc. IJCAI, 1995.
- [15] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," J. Mach. Learn. Res., vol. 11, pp. 2079-2107, 2010.
- [16] J. Davis and M. Goadrich, "The relationship between Precision-Recall and ROC curves," in Proc. ICML, 2006.
- [17] D. M. W. Powers, "Evaluation: From precision, recall and F-measure to ROC," J. Mach. Learn. Technol., vol. 2, no. 1, pp. 37-63, 2011.
- [18] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," J. Mach. Learn. Res., vol. 12, pp. 2825-2830, 2011.
- [19] A. Paszke et al., "PyTorch: An imperative style, high-performance deep learning library," in Adv. Neural Inf. Process. Syst., 2019.
- [20] G. Lemaître, F. Nogueira, and C. K. Aridas, "Imbalanced-learn: A Python toolbox to tackle imbalanced datasets," J. Mach. Learn. Res., vol. 18, 2017.
- [21] F. Ricci, L. Rokach, B. Shapira, and P. B. Kantor, Eds., Recommender Systems Handbook. Springer, 2011.
- [22] N. Tintarev and J. Masthoff, "A survey of explanations in recommender systems," in Proc. IEEE ICDE Workshops, 2007.
- [23] Y. Zhang and X. Chen, "Explainable recommendation: A survey and new perspectives," Found. Trends Inf. Retr., vol. 14, no. 1, pp. 1-101, 2020.
- [24] A. M. Shahiri, W. Husain, and N. A. Rashid, "A review on predicting student performance using data mining techniques," Procedia Computer Science, vol. 72, pp. 414-422, 2015.

PHỤ LỤC

Phụ lục A. Siêu tham số cấu hình cuối

Bảng 13. Siêu tham số chính của CNN-BiLSTM ensemble

Nhóm	Giá trị
Learning rate	0.009386
Weight decay	0.00012016
Conv1D channels	32
Kernel size	3
Bi-LSTM hidden dimension	96
Dropout head	0.1458
Dropout sequence	0.0602
Batch size	64
Max epochs	100
Early stopping patience	12
Oversampling	SMOTE, ratio 0.3755
Loss	Weighted cross-entropy
Số mô hình cơ sở	11

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Phụ lục B. Pseudocode CNN-BiLSTM ensemble

Input: tập huấn luyện với hai đặc trưng G1, G2 và nhãn Low/Medium/High.

Bước 1: Chuẩn hóa dữ liệu huấn luyện và áp dụng SMOTE trên phần huấn luyện nếu cần.

Bước 2: Với mỗi seed trong danh sách 11 seed, huấn luyện một CNN-BiLSTM cùng kiến trúc.

Bước 3: Với mỗi mẫu kiểm tra, lấy xác suất dự đoán từ từng mô hình cơ sở.

Bước 4: Trung bình hóa xác suất của 11 mô hình để tạo xác suất cuối.

Bước 5: Áp dụng quy tắc quyết định đã chọn trên validation. Nếu cấu hình sử dụng ngưỡng, ngưỡng không được chọn lại trên tập kiểm tra; nếu không có lớp nào thỏa điều kiện, chọn lớp có xác suất cao nhất.

Bước 6: Từ nhãn dự đoán và mức độ tin cậy, sinh khuyến nghị học tập theo luật.

Phụ lục C. Bảng metric đầy đủ

Bảng 14. Metric đầy đủ trên tập kiểm tra xác nhận

Metric	Giá trị
Accuracy	0.911392405063
F1-Macro	0.925612287256
Precision-Macro	0.923481116585
R2	0.822642719692
RMSE	0.297670278894
Recall-Macro	0.930499325236

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Phụ lục D. Ví dụ khuyến nghị học tập

Bảng 15. Một số ví dụ khuyến nghị học tập

Mức dự đoán	Nội dung khuyến nghị
Low	Tập trung ôn kiến thức nền, chia nhỏ mục tiêu, làm lại bài tập cơ bản và trao đổi với giảng viên để xác định phần còn yếu.
Medium	Duy trì lịch học đều, bổ sung bài tập vận dụng và theo dõi các chủ đề có xác suất rủi ro cao hơn.
High	Tiếp tục duy trì thói quen học hiện tại, thử bài nâng cao và hỗ trợ bạn học nếu phù hợp.

Nguồn: Tác giả xây dựng từ kết quả thực nghiệm.

Phụ lục E. Thông tin tái lập thực nghiệm tối giản

Để tái lập phần đánh giá, cần sử dụng cùng bộ dữ liệu student-mat gồm 395 bản ghi, cùng quy tắc tạo nhãn từ G3, cùng cách tách 316 bản ghi huấn luyện và 79 bản ghi kiểm tra, cùng cấu hình CNN-BiLSTM ensemble được trình bày ở Phụ lục

A. Các metric trong báo cáo được tính từ dự đoán trên tập kiểm tra xác nhận và có thể kiểm tra lại bằng các thư viện đánh giá chuẩn như scikit-learn.