

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP

XÂY DỰNG MÔ HÌNH HỌC KẾT HỢP
ĐỂ DỰ ĐOÁN THÀNH TÍCH HỌC TẬP
CỦA SINH VIÊN

GIẢNG VIÊN HƯỚNG DẪN: NGUYỄN THỊ PHƯƠNG TRANG
SINH VIÊN THỰC HIỆN: TRẦN HOÀNG PHÚC - 23DH112780

TP. HỒ CHÍ MINH - THÁNG 6-2026

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP

**XÂY DỰNG MÔ HÌNH HỌC KẾT HỢP
ĐỂ DỰ ĐOÁN THÀNH TÍCH HỌC TẬP
CỦA SINH VIÊN**

GIẢNG VIÊN HƯỚNG DẪN: NGUYỄN THỊ PHƯƠNG TRANG
SINH VIÊN THỰC HIỆN: TRẦN HOÀNG PHÚC - 23DH112780

TP. HỒ CHÍ MINH - THÁNG 6-2026

LỜI CẢM ƠN

LỜI CAM ĐOAN

MỤC LỤC

LỜI CẢM ƠN.....	i
LỜI CAM ĐOAN.....	ii
MỤC LỤC	iii
DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ THUẬT NGỮ.....	vi
DANH MỤC CÁC BẢNG.....	vii
DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ	viii
CHƯƠNG 1. MỞ ĐẦU.....	1
1.1. Lý do chọn đề tài	1
1.2. Mục tiêu nghiên cứu.....	1
1.3. Đối tượng và phạm vi nghiên cứu	1
1.4. Phương pháp nghiên cứu.....	1
1.5. Ý nghĩa khoa học và thực tiễn.....	1
1.6. Bố cục khóa luận dự kiến	1
CHƯƠNG 2. TỔNG QUAN VÀ CƠ SỞ LÝ THUYẾT	2
2.1. Educational Data Mining và dự đoán thành tích học tập	2
2.2. Mạng tích chập một chiều	2
2.3. LSTM và BiLSTM	2
2.4. Attention pooling.....	2
2.5. Multi-Layer Perceptron và categorical embedding.....	2
2.6. Phân loại có thứ tự.....	2
2.7. Xử lý mất cân bằng dữ liệu	2
2.8. Tối ưu siêu tham số bằng Optuna.....	2
2.9. Các chỉ số đánh giá mô hình	2
2.10. Các nghiên cứu liên quan	2

CHƯƠNG 3. PHƯƠNG PHÁP VÀ MÔ HÌNH ĐỀ XUẤT	3
3.1. Bài toán và đầu ra của hệ thống	3
3.2. Tổ chức dữ liệu đầu vào	3
3.3. Kiến trúc hai nhánh	4
3.4. Nhánh CNN-BiLSTM và attention pooling	5
3.5. Nhánh Context MLP	5
3.6. Fusion và đầu ra	5
3.7. Tiền xử lý, chọn đặc trưng và kiểm soát leakage	5
3.8. Huấn luyện, Optuna và ensemble	6
3.9. Bộ luật sinh learning path	7
3.10. Lưu trữ PostgreSQL	7
CHƯƠNG 4. KẾT QUẢ THỰC HIỆN VÀ TIẾN ĐỘ HIỆN TẠI	9
4.1. Dữ liệu và locked split	9
4.2. Kết quả locked test	9
4.3. So sánh CV và locked test	10
4.4. Phân tích theo lớp	11
4.5. Confidence và learning path	12
4.6. Trạng thái các hạng mục	13
4.7. Hạn chế cần xử lý	14
4.8. Công việc tiếp theo	14
CHƯƠNG 5. KẾT LUẬN	15
5.1. Kết quả đạt được	15
5.2. Phạm vi của kết quả tiến độ	15
TÀI LIỆU THAM KHẢO	16

PHỤ LỤC A. NGUỒN ARTIFACTS ĐỐI CHIẾU	17
--	----

DANH MỤC CÁC KÝ HIỆU, CHỮ VIẾT TẮT VÀ THUẬT NGỮ

Bảng 0.1. Danh mục chữ viết tắt và thuật ngữ

Ký hiệu	Diễn giải
CNN	Convolutional Neural Network
BiLSTM	Bidirectional Long Short-Term Memory
MLP	Multi-Layer Perceptron
EDM	Educational Data Mining
ADASYN	Adaptive Synthetic Sampling
SMOTENC	SMOTE for mixed numerical and categorical data
CV	Cross-validation
SWA	Stochastic Weight Averaging
F1-Macro	Trung bình F1 không trọng số theo lớp
Locked test	Tập kiểm thử được cô lập trước tối ưu mô hình

DANH MỤC CÁC BẢNG

Bảng 0.1. Danh mục chữ viết tắt và thuật ngữ	vi
Bảng 3.1. Tổ chức đầu vào theo bộ dữ liệu.....	3
Bảng 3.2. Thành phần chính của kiến trúc	4
Bảng 3.3. Cấu hình tốt nhất đang được dùng	6
Bảng 4.1. Quy mô dữ liệu và locked test	9
Bảng 4.2. Metric locked test hiện tại.....	9
Bảng 4.3. Chênh lệch giữa CV và locked test.....	10
Bảng 4.4. Trạng thái thực hiện tại thời điểm báo cáo	13
Bảng A.1. Tập nguồn dùng trong báo cáo tiến độ.....	17

DANH MỤC CÁC HÌNH VẼ, ĐỒ THỊ

Hình 3.1. Quy trình tổng thể của hệ thống dự đoán và khuyến nghị	3
Hình 3.2. Kiến trúc CNN-BiLSTM kết hợp Context MLP.....	4
Hình 3.3. Cơ chế tách dữ liệu và kiểm soát rò rỉ thông tin	6
Hình 3.4. Luồng xử lý của Rule-based Learning Path Engine.....	7
Hình 3.5. Quan hệ giữa các bảng lưu kết quả PostgreSQL	8
Hình 4.1. Phân bố ba lớp trên toàn bộ dữ liệu.....	9
Hình 4.2. So sánh metric phân loại trên locked test	10
Hình 4.3. F1-Macro trên cross-validation và locked test	11
Hình 4.4. Ma trận nhầm lẫn trên ba locked test	11
Hình 4.5. F1-score theo lớp Low, Medium và High	12
Hình 4.6. Phân bố confidence của ensemble.....	12
Hình 4.7. Phân bố risk band do bộ luật sinh ra	13

CHƯƠNG 1. MỞ ĐẦU

- 1.1. Lý do chọn đề tài**
- 1.2. Mục tiêu nghiên cứu**
- 1.3. Đối tượng và phạm vi nghiên cứu**
- 1.4. Phương pháp nghiên cứu**
- 1.5. Ý nghĩa khoa học và thực tiễn**
- 1.6. Bố cục khóa luận dự kiến**


CHƯƠNG 2. TỔNG QUAN VÀ CƠ SỞ LÝ THUYẾT

- 2.1. Educational Data Mining và dự đoán thành tích học tập**
- 2.2. Mạng tích chập một chiều**
- 2.3. LSTM và BiLSTM**
- 2.4. Attention pooling**
- 2.5. Multi-Layer Perceptron và categorical embedding**
- 2.6. Phân loại có thứ tự**
- 2.7. Xử lý mất cân bằng dữ liệu**
- 2.8. Tối ưu siêu tham số bằng Optuna**
- 2.9. Các chỉ số đánh giá mô hình**
- 2.10. Các nghiên cứu liên quan**

CHƯƠNG 3. PHƯƠNG PHÁP VÀ MÔ HÌNH ĐỀ XUẤT

3.1. Bài toán và đầu ra của hệ thống

Hệ thống nhận hồ sơ học tập hoặc dữ liệu tương tác của người học và dự đoán một trong ba mức Low, Medium, High. Sau bước dự đoán, bộ luật sử dụng lớp dự đoán, độ tin cậy và các dấu hiệu rủi ro trong dữ liệu gốc để tạo learning path. Đầu ra cuối gồm nhãn, xác suất theo lớp, confidence, risk band, risk factor và danh sách hành động theo giai đoạn.



Dự đoán → phân tích rủi ro theo luật → lộ trình học tập → lưu PostgreSQL

Hình 3.1. Quy trình tổng thể của hệ thống dự đoán và khuyến nghị

3.2. Tổ chức dữ liệu đầu vào

Mỗi mẫu được tách thành nhánh chuỗi và nhánh ngữ cảnh. Student-Mat và Student-Por được xây dựng từ bộ Student Performance [1]; xAPI dựa trên bộ dữ liệu tương tác học tập được giới thiệu trong [2]. Với hai tập Student, chuỗi gồm G1, G2. Với xAPI, chuỗi gồm raisedhands, VisITedResources, AnnouncementsView và Discussion. Các biến còn lại được chia thành biến số và biến phân loại; biến số được chuẩn hóa Min-Max, còn biến phân loại được mã hóa chỉ số và học embedding trong mô hình.


Bảng 3.1. Tổ chức đầu vào theo bộ dữ liệu

Bộ dữ liệu	Chuỗi	Ngữ cảnh	Đầu ra
Student-Mat	G1, G2	Điểm, chuyên cần, gia đình, xã hội	Softmax 3 lớp

Bộ dữ liệu	Chuỗi	Ngữ cảnh	Đầu ra
Student-Por	G1, G2	Điểm, chuyên cần, gia đình, xã hội	Softmax 3 lớp
xAPI	4 chỉ báo tương tác	Nhân khẩu học, học kỳ, hỗ trợ, vắng học	2 logit ordinal

3.3. Kiến trúc hai nhánh

Kiến trúc hiện tại là StudentHybridModel trong src/models.py. Nhánh CNN-BiLSTM học biểu diễn từ chuỗi ngắn; nhánh Context MLP học biểu diễn từ biến số và embedding của biến phân loại. Hai vector được ghép tại tầng fusion trước classifier. Mô hình không ghép thêm thuật toán phân loại truyền thống ở đầu ra.



Hình 3.2. Kiến trúc CNN-BiLSTM kết hợp Context MLP

Bảng 3.2. Thành phần chính của kiến trúc

Thành phần	Phép xử lý	Vai trò
Categorical embedding	nn.Embedding cho từng biến	Học biểu diễn biến phân loại
Conv1D	Conv1D - BatchNorm - ReLU - Dropout	Trích xuất mẫu cục bộ
BiLSTM	LSTM hai chiều	Mô hình hóa quan hệ giữa các bước chuỗi
Attention pooling	Softmax trọng số theo bước	Tổng hợp vector chuỗi
Context MLP	Hai tầng Linear với ReLU	Học biểu diễn ngữ cảnh
Fusion	Concatenate - Linear - ReLU - Dropout	Kết hợp hai nhánh

Thành phần	Phép xử lý	Vai trò
Classifier	3 logit hoặc 2 logit ordinal	Sinh xác suất ba mức

3.4. Nhánh CNN-BiLSTM và attention pooling

Tensor chuỗi có dạng batch x T x 1. Trước Conv1D, tensor được chuyển sang batch x 1 x T. Lớp Conv1D dùng padding để giữ chiều dài chuỗi, sau đó BatchNorm, ReLU và dropout. Đầu ra được chuyển lại về batch x T x channels và đưa vào BiLSTM. Thành phần LSTM và biến thể hai chiều dựa trên nguyên lý trong [3], [4]. Vì BiLSTM hai chiều, kích thước biểu diễn tại mỗi bước bằng 2 lần hidden dimension. Attention pooling học một điểm số cho từng bước, chuẩn hóa bằng softmax và tính tổng có trọng số để thu vector chuỗi.

$$h_{seq} = \sum_{t=1..T} \alpha_t h_t, \text{ trong đó } \alpha_t = \text{softmax}(\text{score}(h_t)).$$

3.5. Nhánh Context MLP


Các biến số được ghép với embedding của từng biến phân loại. Vector này đi qua hai tầng fully connected; tầng thứ nhất có ReLU và dropout, tầng thứ hai có ReLU. Kích thước embedding được Optuna chọn cho xAPI; nếu không được chỉ định, mã nguồn tự xác định theo cardinality và giới hạn tối đa 50 chiều.

3.6. Fusion và đầu ra

Vector chuỗi và vector ngữ cảnh được nối lại rồi đưa qua fusion layer. Student-Mat và Student-Por sử dụng ba logit và softmax. xAPI sử dụng hai logit biểu diễn xác suất vượt qua ngưỡng Low và Medium. Ba xác suất được tính lần lượt là $1-p(>\text{Low})$, $p(>\text{Low})-p(>\text{Medium})$ và $p(>\text{Medium})$, sau đó chuẩn hóa. Mã nguồn hiện kẹp xác suất lớp Medium tại 0 nếu hiệu hai ngưỡng âm; chưa có ràng buộc đơn điệu trực tiếp giữa hai logit.

3.7. Tiền xử lý, chọn đặc trưng và kiểm soát leakage

Locked test 20% được tách bằng stratified split với seed 42 trước tối ưu. Trong từng seed ensemble, validation được tách khỏi train pool trước khi fit bộ tiền xử lý và resampling. Biến số dùng MinMaxScaler; biến phân loại dùng LabelEncoder. FeatureSelector dùng Pearson cho biến số và Chi-square cho biến phân loại với ngưỡng p-value 0,1, đồng thời giữ các biến chuỗi bắt buộc.



Hình 3.3. Cơ chế tách dữ liệu và kiểm soát rò rỉ thông tin

Nguồn: Tác giả tổng hợp từ mã nguồn và artifacts thực nghiệm của đề tài.

Student-Mat và Student-Por dùng ADASYN [5]; xAPI dùng SMOTENC vì có cả biến số và biến phân loại. Một điểm cần tiếp tục xử lý là ADASYN đang nhận mã danh mục đã label encoding như biến số, sau đó giá trị tổng hợp được ép về số nguyên khi đưa vào embedding. Đây là hạn chế hiện tại của pipeline Student.

3.8. Huấn luyện, Optuna và ensemble

Optuna [6] tối đa hóa F1-Macro trên repeated stratified 5-fold cross-validation, lặp ba lần. Optimizer là Adam; learning rate được điều chỉnh bằng ReduceLROnPlateau và huấn luyện dừng sớm theo validation F1. Sau mỗi seed, pipeline đánh giá thêm mô hình SWA [7] và chỉ dùng SWA nếu validation F1 cao hơn. Dự đoán ensemble là trung bình xác suất của các checkpoint theo seed.

Bảng 3.3. Cấu hình tốt nhất đang được dùng

Siêu tham số	Student-Mat	Student-Por	xAPI
Learning rate	0.002854	0.002240	0.002409
Weight decay	3.24e-04	1.24e-05	1.65e-05
Batch size	16	16	8
Resampling	ADASYN	ADASYN	SMOTENC
Sampling ratio	0.524	0.409	0.433
CNN channels	64	64	32

Siêu tham số	Student-Mat	Student-Por	xAPI
LSTM hidden	64	32	96
Context hidden	32	128	256
Fusion hidden	64	128	128
Checkpoint hiện có	5	5	11

Cơ sở dữ liệu Optuna xAPI hiện có 100 trial, gồm 59 COMPLETE và 41 PRUNED; best CV F1 là 0.823258. Mã nguồn hiện đặt mục tiêu tối đa 250 trial cho xAPI và 50 trial cho mỗi tập Student. Không còn study database của hai tập Student để xác minh số trial hoàn tất.

3.9. Bộ luật sinh learning path

RuleBasedLearningPathEngine đọc các chỉ báo như khoảng cách điểm, số lần vắng, thời gian học, lịch sử trượt, tương tác lớp học, hỗ trợ phụ huynh và mức sử dụng tài nguyên. Mỗi risk factor có mức ưu tiên, lý do và hành động. Hệ thống ghép các hành động thành lộ trình Tuần 1, Tuần 1-2, Tuần 2-4 hoặc chu kỳ theo dõi định kỳ. Learning path là khuyến nghị hỗ trợ cố vấn, không phải quyết định tự động đối với người học.

Quy trình sinh lộ trình học tập




Hình 3.4. Luồng xử lý của Rule-based Learning Path Engine

3.10. Lưu trữ PostgreSQL

Mô-đun evaluation.py ghi phiên chạy, dữ liệu locked test, xác suất, metric và learning path trong một transaction. Schema hiện có các bảng paper_runs,

paper_predictions, paper_evaluation_metrics và paper_learning_recommendations. Workspace chưa có database dump hoặc log run id để xác nhận một lần ghi thành công; vì vậy trạng thái hiện tại được ghi là đã hoàn thành mã nguồn nhưng chưa kiểm chứng vận hành cơ sở dữ liệu.

Các bảng PostgreSQL dùng để lưu kết quả



Hình 3.5. Quan hệ giữa các bảng lưu kết quả PostgreSQL


CHƯƠNG 4. KẾT QUẢ THỰC HIỆN VÀ TIẾN ĐỘ HIỆN TẠI

4.1. Dữ liệu và locked split

Bảng 4.1. Quy mô dữ liệu và locked test

Bộ dữ liệu	Toàn bộ	Train pool	Locked test	Phân bố test Low/Medium/High
Student-Mat	395	316	79	26 / 38 / 15
Student-Por	649	519	130	20 / 84 / 26
xAPI	480	384	96	26 / 42 / 28

Tỷ lệ lớp trong toàn bộ dữ liệu



Hình 4.1. Phân bố ba lớp trên toàn bộ dữ liệu

Hai tập Student không có ô thiếu hoặc bản ghi trùng trong dữ liệu gốc. xAPI có hai bản ghi trùng hoàn toàn theo kiểm tra hiện tại. Student-Por lệch lớp mạnh nhất, với lớp Medium chiếm 418/649 mẫu; đây là lý do báo cáo dùng F1-Macro làm chỉ số chính thay vì chỉ dựa vào Accuracy.

4.2. Kết quả locked test

Bảng 4.2. Metric locked test hiện tại

Dataset	Accuracy	Precision	Recall	F1-Macro	RMSE	R ²
Student-Mat	0.8608	0.8600	0.8995	0.8690	0.3731	0.7213
Student-Por	0.8462	0.7967	0.8394	0.8156	0.3922	0.5626
xAPI	0.7812	0.7940	0.7879	0.7850	0.4677	0.6108

CHƯƠNG 4. KẾT QUẢ THỰC HIỆN VÀ TIẾN ĐỘ HIỆN TẠI



Hình 4.2. So sánh metric phân loại trên locked test


Student-Mat đạt F1-Macro 0,8690, cao nhất trong ba tập. Student-Por đạt 0,8156; chênh lệch giữa Accuracy và F1-Macro phản ánh ảnh hưởng của lớp Medium chiếm ưu thế. xAPI đạt 0,7850. Các số liệu trong bảng đã được tính lại từ prediction CSV và khớp với metric JSON.

4.3. So sánh CV và locked test

Bảng 4.3. Chênh lệch giữa CV và locked test

Dataset	Best CV F1	Locked-test F1	Chênh lệch
Student-Mat	0.9035	0.8690	0.0345
Student-Por	0.8804	0.8156	0.0648
xAPI	0.8233	0.7850	0.0382

CHƯƠNG 4. KẾT QUẢ THỰC HIỆN VÀ TIẾN ĐỘ HIỆN TẠI



Hình 4.3. F1-Macro trên cross-validation và locked test

Mức giảm F1 lần lượt là 0,0345; 0,0648; và 0,0382. Student-Por có khoảng cách lớn nhất. Kết quả cho thấy mô hình vẫn giữ được phần lớn hiệu năng CV trên dữ liệu khóa, nhưng chưa đủ để kết luận không overfit vì mỗi dataset mới có một locked split và chưa lưu learning curve theo epoch của từng seed.

4.4. Phân tích theo lớp


Ma trận nhầm lẫn trên locked test

Hàng: nhãn thật; cột: nhãn dự đoán

Student-Mat				Student-Por				xAPI						
		Low	Medium	High			Low	Medium	High			Low	Medium	High
	Low	25	1	0		Low	15	5	0		Low	24	2	0
	Medium	7	28	3		Medium	8	71	5		Medium	7	32	3
	High	0	0	15		High	0	2	24		High	0	9	19

Hình 4.4. Ma trận nhầm lẫn trên ba locked test


CHƯƠNG 4. KẾT QUẢ THỰC HIỆN VÀ TIẾN ĐỘ HIỆN TẠI



Hình 4.5. F1-score theo lớp Low, Medium và High


Toàn bộ 52 lỗi của ba dataset là lỗi giữa hai lớp kề nhau; không có trường hợp Low bị dự đoán thành High hoặc ngược lại. Điểm yếu rõ nhất là xAPI lớp High: 9/28 mẫu High bị hạ xuống Medium, Recall High bằng 0,6786. Với Student-Por, lớp Low có F1 bằng 0,70, thấp hơn hai lớp còn lại.

4.5. Confidence và learning path



Hình 4.6. Phân bố confidence của ensemble

CHƯƠNG 4. KẾT QUẢ THỰC HIỆN VÀ TIẾN ĐỘ HIỆN TẠI



Hình 4.7. Phân bố risk band do bộ luật sinh ra

Confidence trung bình của mẫu dự đoán đúng cao hơn mẫu dự đoán sai ở cả ba dataset. Rule engine hiện sinh risk band High cho 58/79 mẫu Student-Mat, 68/130 mẫu Student-Por và 48/96 mẫu xAPI. Các tỷ lệ này phản ánh ngưỡng heuristic hiện tại, chưa phải xác suất nguy cơ đã được hiệu chuẩn bằng nghiên cứu can thiệp.

4.6. Trạng thái các hạng mục

Bảng 4.4. Trạng thái thực hiện tại thời điểm báo cáo

Hạng mục	Trạng thái	Bằng chứng hiện có
Tách train pool và locked test	Hoàn thành	CSV processed cho 3 dataset
Tiền xử lý và feature engineering	Hoàn thành	src/data_pipeline.py
Mô hình CNN-BiLSTM + Context MLP	Hoàn thành	src/models.py và checkpoint
Optuna và cấu hình cuối	Đã có kết quả	Best params; xAPI DB 100 trial
Ensemble nhiều seed	Hoàn thành theo artifacts	5/5/11 checkpoint
Đánh giá locked test	Hoàn thành	Metric JSON và prediction CSV
Learning path theo luật	Hoàn thành mã nguồn	CSV recommendation và rule engine
PostgreSQL	Chưa kiểm chứng	Schema và hàm ghi đã có; chưa có DB

CHƯƠNG 4. KẾT QUẢ THỰC HIỆN VÀ TIẾN ĐỘ HIỆN TẠI

Hạng mục	Trạng thái	Bằng chứng hiện có
	vận hành	dump
Ablation và learning curve	Chưa có dữ liệu	Chưa có artifacts
External validation và user study	Chưa thực hiện	Chưa có dataset/biên bản đánh giá

4.7. Hạn chế cần xử lý

-

4.8. Công việc tiếp theo

CHƯƠNG 5. KẾT LUẬN

5.1. Kết quả đạt được

Tại thời điểm báo cáo, pipeline chính đã chạy từ dữ liệu đầu vào đến dự đoán ba lớp và sinh learning path. Kiến trúc CNN-BiLSTM + Context MLP đã có checkpoint và kết quả locked test cho ba dataset. F1-Macro hiện đạt 0,8690 trên Student-Mat, 0,8156 trên Student-Por và 0,7850 trên xAPI.

5.2. Phạm vi của kết quả tiến độ

Các kết quả hiện tại đủ để xác nhận kiến trúc và quy trình thực nghiệm có thể vận hành. Tuy nhiên, báo cáo chưa xem ablation, external validation, fairness audit, PostgreSQL run và đánh giá hiệu quả learning path là hạng mục đã hoàn thành. Những nội dung này được giữ trong kế hoạch tiếp theo và chỉ được đưa vào kết luận cuối khi có artifacts kiểm chứng.

TÀI LIỆU THAM KHẢO

- [1] P. Cortez and A. M. G. Silva, 'Using Data Mining to Predict Secondary School Student Performance,' UCI Machine Learning Repository, 2008.
- [2] E. A. Amrieh, T. Hamtini, and I. Aljarah, 'Mining Educational Data to Predict Student's Academic Performance Using Ensemble Methods,' International Journal of Database Theory and Application, vol. 9, no. 8, pp. 119-136, 2016.
- [3] S. Hochreiter and J. Schmidhuber, 'Long Short-Term Memory,' Neural Computation, vol. 9, no. 8, pp. 1735-1780, 1997.
- [4] M. Schuster and K. K. Paliwal, 'Bidirectional Recurrent Neural Networks,' IEEE Transactions on Signal Processing, vol. 45, no. 11, pp. 2673-2681, 1997.
- [5] H. He, Y. Bai, E. A. Garcia, and S. Li, 'ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning,' Proc. IJCNN, pp. 1322-1328, 2008.
- [6] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, 'Optuna: A Next-generation Hyperparameter Optimization Framework,' Proc. KDD, 2019.
- [7] P. Izmailov, D. Podoprikin, T. Garipov, D. Vetrov, and A. G. Wilson, 'Averaging Weights Leads to Wider Optima and Better Generalization,' Proc. UAI, pp. 876-885, 2018.

PHỤ LỤC

PHỤ LỤC A. NGUỒN ARTIFACTS ĐỐI CHIẾU

Bảng A.1. Tập nguồn dùng trong báo cáo tiến độ

Nội dung	Đường dẫn
Mã mô hình	src/models.py
Tiền xử lý	src/data_pipeline.py
Huấn luyện	src/train_pipeline.py; scripts/run_pipeline.py
Learning path	src/explainability.py
PostgreSQL	src/evaluation.py; database/schema.sql
Metric	reports/final/metrics/*_locked_test_metrics.json
Dự đoán	reports/final/predictions/*_predictions.csv
Optuna xAPI	models/saved/final/xapi_3class_optuna.db
Audit bổ sung	scratch/final_report_empirical_audit.json