

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

LUẬN VĂN TỐT NGHIỆP

DỰ ĐOÁN VÀ KHUYẾN NGHỊ THÀNH
TÍCH HỌC TẬP CỦA SINH VIÊN BẰNG
KIẾN TRÚC LẠI CNN-BiLSTM VÀ
CONTEXT MLP

*Predicting and Recommending Student Academic Performance using a Hybrid CNN-
BiLSTM + Context MLP Architecture*

Sinh viên thực hiện: [HỌ VÀ TÊN SINH VIÊN]

Mã số sinh viên: [MSSV]

Giảng viên hướng dẫn: [HỌ VÀ TÊN GIẢNG VIÊN]

Ngành / Chuyên ngành: [TÊN NGÀNH / CHUYÊN NGÀNH]

Thành phố Hồ Chí Minh, 2026

TRƯỜNG ĐẠI HỌC NGOẠI NGỮ - TIN HỌC TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN

KHÓA LUẬN TỐT NGHIỆP

**DỰ ĐOÁN VÀ KHUYẾN NGHỊ THÀNH
TÍCH HỌC TẬP CỦA SINH VIÊN BẰNG KIẾN
TRÚC LẠI CNN-BiLSTM VÀ CONTEXT MLP**

Giảng viên hướng dẫn: [HỌ VÀ TÊN GIẢNG VIÊN]

Sinh viên thực hiện: [HỌ VÀ TÊN SINH VIÊN]

Mã số sinh viên: [MSSV]

TP. HỒ CHÍ MINH - 2026

LỜI CẢM ƠN

Trong quá trình thực hiện khóa luận, tác giả đã nhận được sự hướng dẫn, hỗ trợ và góp ý từ giảng viên, nhà trường, gia đình và bạn bè. Tác giả xin bày tỏ lòng biết ơn sâu sắc đến giảng viên hướng dẫn [HỌ VÀ TÊN GIẢNG VIÊN], người đã định hướng phương pháp nghiên cứu, góp ý về thiết kế thực nghiệm và hỗ trợ tác giả hoàn thiện báo cáo theo chuẩn mực khoa học.

Tác giả trân trọng cảm ơn Trường Đại học Ngoại ngữ - Tin học Thành phố Hồ Chí Minh và Khoa Công nghệ Thông tin đã cung cấp môi trường học tập, nền tảng kiến thức và điều kiện cần thiết để triển khai đề tài. Tác giả cũng cảm ơn gia đình và bạn bè đã đồng hành trong suốt quá trình thu thập tài liệu, xây dựng hệ thống, thực hiện thí nghiệm và biên soạn khóa luận.

Mặc dù đã nỗ lực kiểm tra nội dung và kết quả, khóa luận khó tránh khỏi những hạn chế. Tác giả kính mong nhận được các ý kiến phản biện để tiếp tục hoàn thiện hệ thống và phương pháp nghiên cứu trong tương lai.

LỜI CAM ĐOAN

Tác giả cam đoan khóa luận này là kết quả nghiên cứu và triển khai của cá nhân dưới sự hướng dẫn của giảng viên hướng dẫn. Các kết quả thực nghiệm được trích xuất từ mã nguồn, tệp metric, tệp dự đoán và nhật ký huấn luyện trong dự án; không có số liệu đánh giá nào được tự ý tạo ra hoặc sửa đổi nhằm làm tăng kết quả.

Các tài liệu, công trình và dữ liệu tham khảo được ghi nguồn theo chuẩn IEEE. Những nội dung kế thừa từ nghiên cứu trước được diễn giải và trích dẫn rõ ràng. Tác giả chịu trách nhiệm về tính trung thực của nội dung, tính tái lập của quy trình thực nghiệm và việc sử dụng kết quả đúng mục đích học thuật.

TP. Hồ Chí Minh, tháng ... năm 2026

Sinh viên thực hiện
[HỌ VÀ TÊN SINH VIÊN]

TÓM TẮT

Nghiên cứu xây dựng hệ thống phân loại thành tích học tập theo ba mức Low, Medium và High, đồng thời sinh lộ trình hỗ trợ cá nhân hóa. Thành phần dự đoán sử dụng kiến trúc hai nhánh: CNN-BiLSTM xử lý chuỗi điểm hoặc chỉ báo tương tác, còn Context MLP xử lý các biến số và biến phân loại mô tả bối cảnh học tập. Quy trình thực nghiệm tách locked test 20% trước tối ưu, tách validation trước resampling và huấn luyện ensemble 11 seed. Student-Mat và Student-Por sử dụng ADASYN; xAPI sử dụng SMOTENC.

Trên locked test, F1-Macro đạt 0,8690 đối với Student-Mat, 0,8156 đối với Student-Por và 0,7850 đối với xAPI. Accuracy tương ứng là 0,8608, 0,8462 và 0,7812. Chênh lệch giữa Optuna best CV và locked test lần lượt là 0,0345, 0,0648 và 0,0382. Kết quả hỗ trợ khả năng khái quát hóa nhưng không đủ để khẳng định tuyệt đối rằng mô hình không overfit.

Sau dự đoán, một MLP riêng xếp hạng sáu yếu tố rủi ro và chuyển các rủi ro được chọn thành lộ trình theo giai đoạn bằng thư viện mẫu hành động có cấu trúc. MLP chỉ được huấn luyện trên train pool; locked test chỉ dùng để đánh giá độ trung thành với bộ tiêu chí chuyên môn. PostgreSQL lưu phiên chạy, dự đoán, xác suất, metric và khuyến nghị. Các khuyến nghị chưa phải bằng chứng nhân quả về hiệu quả can thiệp.

Từ khóa: Educational Data Mining; dự đoán thành tích học tập; CNN-BiLSTM; Context MLP; F1-Macro; SMOTE; ADASYN; Optuna; learning path.

ABSTRACT

This thesis develops a three-class student-performance predictor and an MLP-based risk-ranking module for staged learning-path recommendations. The predictor combines a CNN-BiLSTM branch for short ordered academic or interaction indicators with a context MLP for numerical and categorical attributes. A locked 20% test set is isolated before model development. The verified locked-test F1-Macro scores are 0.8690 for Student-Mat, 0.8156 for Student-Por and 0.7850 for xAPI. A separate 64-32-6 MLP ranks six observable risk dimensions; its offline metrics measure fidelity to explicit domain criteria, not causal improvement in academic outcomes. PostgreSQL provides operational traceability.

MỤC LỤC

LỜI CẢM ƠN.....	i
LỜI CAM ĐOAN.....	ii
TÓM TẮT	iii
ABSTRACT	iv
MỤC LỤC	v
DANH MỤC BẢNG	viii
DANH MỤC HÌNH	ix
DANH MỤC TỪ VIẾT TẮT	ix
CHƯƠNG 1. GIỚI THIỆU	1
1.1. Bối cảnh nghiên cứu.....	1
1.2. Phát biểu bài toán	1
1.3. Mục tiêu nghiên cứu.....	2
1.4. Câu hỏi nghiên cứu.....	2
1.5. Phạm vi và đóng góp	3
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ BỐI CẢNH NGHIÊN CỨU	4
2.1. Educational Data Mining và dự đoán thành tích.....	4
2.2. CNN cho quan hệ cục bộ.....	4
2.3. LSTM và BiLSTM	4
2.4. Context MLP và fusion	5
2.5. Xử lý mất cân bằng.....	5
2.6. Optuna và tối ưu siêu tham số	5
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG	6

3.1. Quy trình nghiên cứu tổng thể	6
3.2. Kiến trúc hai nhánh	7
3.3. Nhánh CNN-BiLSTM	7
3.4. Nhánh Context MLP	8
3.5. Hàm mất mát và ensemble	8
3.6. MLP Learning Path Engine	8
CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU ...	11
4.1. Mô tả bộ dữ liệu	11
4.2. Tách dữ liệu và chống rò rỉ	12
4.3. Feature engineering	13
4.4. Chuẩn hóa, mã hóa và chọn đặc trưng	14
4.5. SMOTE/ADASYN và Weighted Cross-Entropy	Error! Bookmark not defined.
4.6. Optuna và cấu hình huấn luyện	14
4.7. Chỉ số đánh giá	16
CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC	17
5.1. Nguyên tắc đánh giá	17
5.2. Kết quả locked test tổng hợp	17
5.3. CV so với locked test	18
5.4. Phân tích theo lớp và ma trận nhầm lẫn	19
5.5. Đánh giá xử lý mất cân bằng	22
5.6. Giới hạn năng lực và biểu diễn trên xAPI	22
5.7. Diễn giải RMSE và R^2	23
5.8. Những đánh giá chưa thể kết luận	24
5.9. Kết luận khoa học của chương	25

CHƯƠNG 6. THẢO LUẬN VÀ TRIỂN KHAI THỰC TIỄN.....	27
6.1. Ý nghĩa thực tiễn của dự đoán.....	27
6.2. Vận hành Learning Path.....	27
6.3. Tích hợp PostgreSQL	28
6.4. Kiến trúc triển khai đề xuất	29
6.5. Rủi ro đạo đức và quản trị	29
6.6. Hạn chế của nghiên cứu	30
CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	31
7.1. Kết luận	31
7.2. Hướng phát triển.....	31
7.3. Tuyên bố cuối cùng	32
TÀI LIỆU THAM KHẢO	33
PHỤ LỤC A. NGUỒN SỐ LIỆU THỰC NGHIỆM	34
PHỤ LỤC B. CHECKLIST TÁI LẬP	34
PHỤ LỤC C. CÁC PHÂN TÍCH CẦN BỔ SUNG KHI CÓ DỮ LIỆU	35

DANH MỤC BẢNG

Bảng 0.1. Danh mục từ viết tắt.....	ix
Bảng 3.1. Cấu trúc chức năng của mô hình lai.....	7
Bảng 3.2. Từ điểm rủi ro MLP đến learning path	9
Bảng 4.1. So sánh ba bộ dữ liệu	11
Bảng 4.2. Thiết lập tối ưu siêu tham số.....	14
Bảng 4.3. Siêu tham số tốt nhất được dùng trong báo cáo chính thức	15
Bảng 5.1. Metric locked-test cuối cùng.....	17
Bảng 5.2. So sánh F1-Macro CV và locked test	18
Bảng 5.3. Metric theo lớp từ classification report.....	19
Bảng 5.4. Ma trận nhầm lẫn Student-Mat	21
Bảng 5.5. Ma trận nhầm lẫn Student-Por	21
Bảng 5.6. Ma trận nhầm lẫn xAPI.....	21
Bảng 6.1. Vai trò các bảng PostgreSQL.....	28
Bảng A.1. Truy vết nguồn dữ liệu dùng trong luận văn.....	34

DANH MỤC HÌNH

Hình 3.1. Quy trình tổng thể của hệ thống dự đoán và khuyến nghị	6
Hình 3.2. Kiến trúc nội bộ CNN-BiLSTM + Context MLP	7
Hình 3.3. Luồng xử lý của MLP Learning Path Engine	9
Hình 4.1. Phân bố lớp trong ba tập locked test	12
Hình 4.2. Giao thức tách dữ liệu và kiểm soát rò rỉ	13
Hình 5.1. So sánh các metric phân loại trên locked test.....	18
Hình 5.2. So sánh F1-Macro giữa cross-validation và locked test.....	19
Hình 5.3. Ma trận nhầm lẫn của ba bộ dữ liệu	21
Hình 5.4. F1-score theo từng lớp Low, Medium và High	22
Hình 5.5. Permutation feature importance trên ba bộ dữ liệu	23
Hình 5.6. Phân bố độ tin cậy của dự đoán ensemble.....	24
Hình 6.1. Phân bố risk band do Learning Path Engine tạo ra	28
Hình 6.2. Quan hệ giữa các bảng lưu trữ PostgreSQL.....	29

DANH MỤC TỪ VIẾT TẮT

Bảng 0.1. Danh mục từ viết tắt

Từ viết tắt	Diễn giải
CNN	Convolutional Neural Network
BiLSTM	Bidirectional Long Short-Term Memory
MLP	Multilayer Perceptron
EDM	Educational Data Mining
SMOTE	Synthetic Minority Over-sampling Technique
ADASYN	Adaptive Synthetic Sampling
CV	Cross-validation

Từ viết tắt	Diễn giải
TPE	Tree-structured Parzen Estimator
RMSE	Root Mean Squared Error
R^2	Coefficient of Determination
LMS	Learning Management System

CHƯƠNG 1. GIỚI THIỆU

1.1. Bối cảnh nghiên cứu

Chuyển đổi số trong giáo dục tạo ra lượng lớn dữ liệu về điểm số, chuyên cần, hoạt động trên hệ thống quản lý học tập, đặc điểm xã hội và mức độ tham gia của người học. Educational Data Mining và Learning Analytics sử dụng các nguồn dữ liệu này để mô tả hành vi, phát hiện rủi ro và hỗ trợ can thiệp sớm. Trong thực tế, giá trị của hệ thống không chỉ nằm ở việc dự đoán đúng nhân thành tích, mà còn ở khả năng giải thích tín hiệu rủi ro, duy trì khả năng khái quát hóa khi chuyển sang người học chưa quan sát, và chuyển kết quả dự đoán thành hành động giáo dục có thể kiểm tra.

Dữ liệu giáo dục thường đồng thời chứa hai cấu trúc. Thứ nhất là cấu trúc có thứ tự hoặc gần thời gian, chẳng hạn điểm giai đoạn G1-G2 hoặc các chỉ báo tương tác được sắp theo một quy ước nhất định. Thứ hai là dữ liệu bảng mô tả bối cảnh, chẳng hạn thời gian học, số lần trượt, hỗ trợ gia đình, loại trường, chủ đề, mức độ hài lòng và chuyên cần. Một mô hình chỉ dùng MLP có thể bỏ qua quan hệ theo thứ tự; ngược lại, một mô hình tuần tự thuần túy khó tận dụng đầy đủ các biến bối cảnh dị thể. Vì vậy, kiến trúc lai hai nhánh là lựa chọn hợp lý về mặt thiết kế.

1.2. Phát biểu bài toán

Bài toán chính là phân loại mỗi người học vào một trong ba mức thành tích Low, Medium hoặc High. Đối với Student-Mat và Student-Por, điểm cuối kỳ G3 được rời rạc hóa thành Low = 0-9, Medium = 10-14 và High = 15-20. Đối với xAPI, nhãn L, M và H có sẵn được ánh xạ thành 0, 1 và 2. Đầu ra của mô hình bao gồm nhãn dự đoán, vector xác suất ba lớp và độ tin cậy. Đầu ra của mô-đun khuyến nghị là một lộ trình theo giai đoạn, được tạo từ tổ hợp giữa lớp dự đoán, độ tin cậy và các yếu tố rủi ro quan sát được.

Các thách thức khoa học và kỹ thuật trọng yếu gồm:

- Mất cân bằng lớp làm Accuracy có thể che khuất chất lượng ở lớp thiểu số; do đó F1-Macro là chỉ số trung tâm.
- Dữ liệu nhỏ làm mô hình sâu nhạy với seed, lựa chọn siêu tham số và cách chia tập.
- Dữ liệu hỗn hợp số-phân loại gây khó khăn cho nội suy tổng hợp của SMOTE/ADASYN.
- Chuỗi Student chỉ dài hai bước G1-G2; chuỗi xAPI gồm bốn chỉ báo tổng hợp, không phải nhật ký theo timestamp.
- Kết quả CV có thể lạc quan do lựa chọn cấu hình tốt nhất trong nhiều trial; locked test phải được cô lập hoàn toàn.
- Khuyến nghị dựa trên MLP cần được phân biệt với can thiệp đã được kiểm chứng nhân quả.

1.3. Mục tiêu nghiên cứu

- Xây dựng mô hình lai CNN-BiLSTM + Context MLP cho phân loại thành tích học tập ba lớp.
- Thiết kế quy trình dữ liệu chống rò rỉ, bao gồm locked test, fit tiền xử lý trên train, chọn đặc trưng trong train và resampling chỉ trên train.
- Tối ưu siêu tham số bằng Optuna và Stratified 5-fold CV, sau đó huấn luyện ensemble nhiều seed.
- Đánh giá bằng Accuracy, Precision-Macro, Recall-Macro, F1-Macro, RMSE và R^2 trên locked test.
- Phân tích chênh lệch CV-test, mất cân bằng lớp, ma trận nhầm lẫn và giới hạn năng lực biểu diễn.
- Sinh learning path dựa trên MLP và tích hợp PostgreSQL để theo dõi toàn bộ vòng đời dự đoán.

1.4. Câu hỏi nghiên cứu

- Kiến trúc lai có đạt F1-Macro ổn định trên ba bộ dữ liệu có cấu trúc khác nhau hay không?
- Khoảng cách giữa CV tốt nhất và locked test phản ánh mức độ khái quát hóa như thế nào?

- Mất cân bằng lớp được phản ánh ra sao trong Precision, Recall, F1 theo lớp và ma trận nhầm lẫn?
- Những giới hạn biểu diễn nào xuất hiện khi áp dụng CNN-BiLSTM cho chuỗi rất ngắn hoặc chỉ báo tổng hợp xAPI?
- Làm thế nào chuyển dự đoán thành lộ trình học tập có thể truy vết mà không tuyên bố quá mức về hiệu quả can thiệp?

1.5. Phạm vi và đóng góp

Nghiên cứu giới hạn ở ba bộ dữ liệu công khai Student-Mat, Student-Por và xAPI-Edu-Data; nhiệm vụ đầu ra là phân loại ba lớp. Kiến trúc được giới hạn ở CNN, BiLSTM, attention pooling, MLP và fusion dense. Hệ thống không sử dụng Transformer, DeepFM, DCN-V2 hoặc tìm kiếm phản thực tế trong mô hình chính. Đóng góp thực hành nằm ở một pipeline end-to-end tái lập được, tách locked test, lưu metric và dự đoán, sinh khuyến nghị dựa trên MLP và cung cấp schema PostgreSQL. Đóng góp khoa học nằm ở việc đánh giá nghiêm ngặt chênh lệch CV-test và công khai các giới hạn của dữ liệu, biểu diễn và giao thức.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ BỐI CẢNH NGHIÊN CỨU

2.1. Educational Data Mining và dự đoán thành tích

Educational Data Mining nghiên cứu các phương pháp khai phá mẫu từ dữ liệu giáo dục để hỗ trợ hiểu biết về người học và quá trình học. Bộ Student Performance của UCI được xây dựng từ dữ liệu trường trung học Bồ Đào Nha và thường được dùng để dự đoán điểm G3 từ đặc điểm cá nhân, gia đình, nhà trường và điểm các giai đoạn trước [1]. xAPI-Edu-Data được thu thập từ môi trường Kalboard 360, nhấn mạnh các thuộc tính hành vi như raisedhands, VisITedResources, AnnouncementsView và Discussion [2]. Hai họ dữ liệu đại diện cho hai tình huống: dự đoán dựa mạnh vào lịch sử điểm và dự đoán dựa trên tương tác LMS cùng bối cảnh.

2.2. CNN cho quan hệ cục bộ

Convolution một chiều áp dụng bộ lọc trượt trên trục thứ tự để học các mẫu cục bộ. Với đầu vào X thuộc $\mathbb{R}^{(T \times C)}$, một kênh đầu ra tại vị trí t có thể được mô tả khái quát bởi $h_t = \sigma(W * X_{(t:t+k-1)} + b)$. Trong hệ thống, Conv1D được theo sau bởi BatchNorm, ReLU và Dropout. Vai trò dự kiến là tái mã hóa sự kết hợp cục bộ giữa các mốc điểm hoặc chỉ báo tương tác trước khi đưa vào BiLSTM. Tuy nhiên, khi T chỉ bằng 2 hoặc 4, không gian mẫu cục bộ rất hạn chế; đây là một giới hạn cần được đánh giá thay vì mặc định rằng CNN luôn mang lại lợi ích.

2.3. LSTM và BiLSTM

LSTM sử dụng các cổng vào, quên và đầu ra để điều khiển dòng thông tin qua trạng thái ô nhớ, qua đó giảm khó khăn gradient suy giảm trong RNN truyền thống [3]. BiLSTM mở rộng bằng hai hướng xử lý: hướng thuận và hướng nghịch; biểu diễn tại mỗi vị trí là phép ghép hai trạng thái [4]. Trong bài toán này, BiLSTM không được dùng để dự báo tương lai theo thời gian thực, mà để mã hóa toàn bộ chuỗi đầu

vào đã quan sát trước thời điểm dự đoán. Vì vậy, điều kiện triển khai là mọi phần tử của chuỗi phải sẵn có tại thời điểm suy luận, tránh rò rỉ thông tin tương lai.

2.4. Context MLP và fusion

Nhánh Context MLP nhận các biến số sau chuẩn hóa Min-Max và các biến phân loại sau Label Encoding. Trong triển khai hiện tại, biến phân loại được chuẩn hóa theo cardinality thay vì embedding; sau đó vector context đi qua hai tầng tuyến tính với ReLU và Dropout. Vector chuỗi từ attention pooling được ghép với vector context, qua tầng fusion và classifier ba lớp. Cách thiết kế này đơn giản, phù hợp dữ liệu nhỏ, nhưng việc ánh xạ danh mục thành số có thể tạo quan hệ thứ tự giả giữa các giá trị không có thứ tự.

2.5. Xử lý mất cân bằng

SMOTE tạo mẫu tổng hợp bằng nội suy giữa các quan sát lớp thiểu số [5], trong khi ADASYN ưu tiên các vùng khó phân loại [6]. Final model v1 giữ ADASYN cho Student-Mat và Student-Por; xAPI yêu cầu SMOTE và được thực thi bằng SMOTENC do có các biến phân loại. Weighted loss tiếp tục giảm thiên lệch về lớp phổ biến.


2.6. Optuna và tối ưu siêu tham số

Optuna cung cấp không gian tìm kiếm define-by-run, TPE sampler và pruning [7]. Final model v1 sử dụng Optuna best CV để chọn cấu hình, sau đó huấn luyện ensemble 11 seed. Student-Mat và Student-Por có best CV F1 lần lượt 0,9035 và 0,8804; study xAPI lưu trong SQLite có best CV F1 0,8233. Locked test được cô lập khỏi quá trình chọn siêu tham số.

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU VÀ KIẾN TRÚC HỆ THỐNG

3.1. Quy trình nghiên cứu tổng thể

1. Nạp dữ liệu gốc và chuyển nhãn về bài toán ba lớp.
2. Tách stratified locked test 20% với random seed 42 trước tối ưu.
3. Trong từng fold CV: feature engineering, fit encoder/scaler trên train fold, resampling train fold, chọn đặc trưng trên train fold và transform validation fold.
4. Optuna tối đa hóa trung bình F1-Macro của 5 fold.
5. Huấn luyện ensemble với các seed 42, 123, 155, 156 và 2025; trung bình hóa xác suất.
6. Đánh giá locked test một lần, xuất metric, dự đoán, feature importance và learning path.
7. Ghi phiên chạy, dự đoán, metric và khuyến nghị vào PostgreSQL trong một giao dịch.



Hình 3.1. Quy trình tổng thể của hệ thống dự đoán và khuyến nghị

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.


3.2. Kiến trúc hai nhánh

Bảng 3.1. Cấu trúc chức năng của mô hình lai

Khối	Đầu vào	Phép biến đổi	Đầu ra
Nhánh tuần tự	G1-G2 hoặc 4 chỉ báo xAPI	Conv1D → BatchNorm → ReLU → Dropout → BiLSTM → Attention Pooling	Vector chuỗi 2h
Nhánh bối cảnh	Biến số và biến phân loại	Chuẩn hóa/mã hóa → Linear → ReLU → Dropout → Linear → ReLU	Vector context
Fusion	Vector chuỗi + context	Concatenate → Linear → ReLU → Dropout	Vector hợp nhất
Classifier	Vector hợp nhất	Linear(num_classes=3) → Softmax khi suy luận	P(Low), P(Medium), P(High)

Kiến trúc lai CNN-BiLSTM + Context MLP

Hai nhánh xử lý dữ liệu tuần tự và dữ liệu bối cảnh trước khi hợp nhất



Ensemble: trung bình hóa xác suất của 5 mô hình được huấn luyện với các seed cố định

Hình 3.2. Kiến trúc nội bộ CNN-BiLSTM + Context MLP

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

3.3. Nhánh CNN-BiLSTM

Tensor đầu vào tuần tự có dạng $\text{batch} \times T \times 1$. Trước Conv1D, tensor được chuyển thành $\text{batch} \times 1 \times T$. Conv1D dùng padding bằng $\text{floor}(\text{kernel}/2)$, vì vậy giữ gần nguyên chiều dài đối với kernel lẻ. Đầu ra được chuyển về $\text{batch} \times T \times \text{channels}$

và đưa qua LSTM hai chiều. Nếu kích thước ẩn mỗi hướng là h , đầu ra tại mỗi bước có kích thước $2h$. AttentionPooling1D học một điểm số vô hướng cho từng bước, chuẩn hóa bằng softmax và tính tổng có trọng số để thu vector chuỗi.

Với Student-Mat và Student-Por, $T = 2$ tương ứng G1 và G2. Với xAPI, $T = 4$ tương ứng raisedhands, VisITedResources, AnnouncementsView và Discussion. Cần nhấn mạnh rằng bốn biến xAPI là các tổng hợp hành vi theo thuộc tính, không phải chuỗi sự kiện có timestamp. Do đó, thuật ngữ 'sequential branch' mô tả cách tensor được xử lý trong mô hình hơn là khẳng định dữ liệu xAPI là time series chuẩn.

3.4. Nhánh Context MLP

Nhánh bối cảnh loại bỏ các cột đã dùng trong chuỗi để tránh lặp trực tiếp. Các biến số còn lại được đưa vào dưới dạng float. Mỗi biến phân loại sau Label Encoding được chia cho $\max(\text{cardinality}-1, 1)$ để đưa về xấp xỉ $[0,1]$. Các giá trị sau đó được ghép thành vector và đi qua hai tầng MLP. Cấu hình này giảm số tham số so với embedding riêng cho từng biến, phù hợp với cỡ mẫu 395-649-480, nhưng đánh đổi khả năng mô hình hóa quan hệ danh mục phi thứ tự.


3.5. Hàm mất mát và ensemble

Hàm mất mát là Weighted Cross-Entropy, trong đó trọng số được tính từ phân bố lớp gốc của train pool. Adam tối ưu tham số với learning rate và weight decay do Optuna chọn. ReduceLROnPlateau và early stopping hạn chế huấn luyện kéo dài khi validation không cải thiện. Mỗi seed tạo một mô hình độc lập; xác suất cuối là trung bình số học của năm vector xác suất. Dự đoán là argmax của xác suất trung bình, và confidence là xác suất lớn nhất.

3.6. MLP Learning Path Engine

Mô-đun khuyến nghị sử dụng MLP đầu vào 8 đặc trưng đối với Student-Mat/Student-Por và 7 đặc trưng đối với xAPI. Hai tầng ẩn có 64 và 32 nút, đầu ra gồm sáu logit rủi ro. Đặc trưng được chuẩn hóa bằng thống kê của train pool. Mô

hình được huấn luyện bằng BCEWithLogitsLoss trên nhãn weak supervision từ bộ tiêu chí chuyên môn có thể kiểm toán; locked test không tham gia huấn luyện.



Huấn luyện chỉ trên train pool; locked test chỉ dùng để đánh giá

Hình 3.3. Luồng xử lý của MLP Learning Path Engine

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

Bảng 3.2. Từ điểm rủi ro MLP đến learning path

Đầu ra MLP	Ý nghĩa	Mẫu hành động	Giai đoạn
attendance	Rủi ro chuyên cần	Xác minh nguyên nhân, học bù, theo dõi chuyên cần	Tuần 1
failure_history / grade_gap	Lỗi hỏng kiến thức	Chẩn đoán chủ đề yếu và luyện tập có phản hồi	Tuần 1-2
resource_usage / course_updates	Sử dụng học liệu thấp	Tăng truy cập LMS và hoàn thành tài nguyên trọng tâm	Tuần 1-2
class_engagement	Tương tác lớp học thấp	Đặt câu hỏi, phản hồi và tham gia thảo luận	Tuần 2-4
study_time / time_management	Nếp tự học chưa ổn định	Tăng giờ tự học có kế hoạch và điều chỉnh lịch	Tuần 2-4
parent_support / school_support	Thiếu phối hợp hỗ trợ	Thống nhất mục tiêu và lịch kiểm tra hằng tuần	Trong 2 tuần

MLP quyết định thứ tự ưu tiên của các yếu tố rủi ro. Phần diễn đạt hành động dùng mẫu nội dung theo từng nhóm rủi ro để bảo đảm câu chữ ổn định và có thể kiểm tra. Do huấn luyện bắt nguồn từ tiêu chí chuyên môn, metric offline phản ánh khả năng mô phỏng chính sách tham chiếu, không phản ánh tác động thực tế lên điểm số. LLM-Judge chưa được thực hiện vì chưa có bộ chấm độc lập hoặc đánh giá con người được cung cấp.


CHƯƠNG 4. THIẾT LẬP THỰC NGHIỆM VÀ TIỀN XỬ LÝ DỮ LIỆU

4.1. Mô tả bộ dữ liệu

Bảng 4.1. So sánh ba bộ dữ liệu

Bộ dữ liệu	Số mẫu	Số cột gốc	Đích	Chuỗi mô hình	Nguồn thông tin chính
Student-Mat	395	33	G3 $\rightarrow$ 3 lớp	G1, G2	Điểm, cá nhân, gia đình, trường học
Student-Por	649	33	G3 $\rightarrow$ 3 lớp	G1, G2	Điểm, cá nhân, gia đình, trường học
xAPI-Edu-Data	480	17	Class L/M/H	4 chỉ báo hành vi	Nhân khẩu, học phần, phụ huynh, tương tác LMS


Student-Mat và Student-Por có cùng schema 33 cột, khác môn học. G3 là điểm cuối kỳ trên thang 0-20. xAPI có 17 cột, trong đó Class là nhãn; các biến hành vi chính có thang đếm 0-100. Không có tuyên bố rằng ba tập đại diện cho cùng quần thể. Vì vậy, so sánh metric giữa tập chỉ mang tính mô tả năng lực của pipeline trên ba bối cảnh, không phải kiểm định trực tiếp bộ dữ liệu nào 'dễ' hay 'khó' nếu chưa kiểm soát phân bố và nhiễu nhãn.



Hình 4.1. Phân bố lớp trong ba tập locked test
Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

4.2. Tách dữ liệu và chống rò rỉ

Mỗi tập được tách stratified thành train pool 80% và locked test 20% bằng seed 42. Số mẫu locked test là 79, 130 và 96. Locked test không tham gia fit scaler/encoder, chọn đặc trưng, resampling, chọn epoch hoặc huấn luyện MLP khuyến nghị. Trong từng fold CV, toàn bộ tiền xử lý chỉ fit trên train fold; validation fold chỉ được transform.



Hình 4.2. Giao thức tách dữ liệu và kiểm soát rò rỉ

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

Trong giai đoạn ensemble cuối, toàn bộ train pool được tiền xử lý và resampling trước khi tách validation nội bộ 15% theo seed. Locked test vẫn hoàn toàn độc lập, nên metric cuối không bị fit trực tiếp. Tuy nhiên, validation nội bộ sau resampling có thể chứa mẫu tổng hợp liên quan gần với mẫu train và làm lựa chọn epoch lạc quan hơn. Đây là hạn chế giao thức cần sửa trong phiên bản tiếp theo bằng cách tách validation trước resampling.

4.3. Feature engineering

Các đặc trưng dẫn xuất được tạo theo quy tắc xác định trước:

- Student: $\text{grade_growth} = G2 - G1$; $\text{grade_avg} = (G1 + G2) / 2$; $\text{absence_study_ratio}$; failure_risk ; alcohol_risk ; social_risk .
- xAPI: $\text{engagement_score} = \text{tổng raisedhands, VisITedResources, AnnouncementsView, Discussion}$; absence_risk ; $\text{parent_support_signal}$.

Một lưu ý khoa học quan trọng là grade_avg và grade_growth được suy ra trực tiếp từ $G1 - G2$, vốn đồng thời được đưa vào nhánh tuần tự. Điều này làm tăng tính lặp

thông tin giữa hai nhánh, có thể giúp tối ưu nhưng cũng làm khó tách riêng đóng góp của CNN-BiLSTM và MLP. Cần ablation để xác định lợi ích độc lập của từng nhánh.

4.4. Chuẩn hóa, mã hóa và chọn đặc trưng

Biến số được Min-Max scaling. Biến phân loại được Label Encoding; giá trị chưa thấy ở validation/test ánh xạ về 0. FeatureSelector dùng Pearson cho biến số và Chi-square cho biến phân loại với $p\text{-value} < 0,1$. Các biến chuỗi bắt buộc được giữ lại. Cách chọn đơn biến giúp giảm chiều nhưng không nắm bắt tương tác đa biến và không hiệu chỉnh multiple comparisons. Do đó, $p\text{-value}$ chỉ là tiêu chí kỹ thuật chọn đặc trưng, không được diễn giải như bằng chứng nhân quả.

4.5. ADASYN, SMOTENC và Weighted Loss

Sampling strategy đặt số mẫu mục tiêu của mỗi lớp thiểu số bằng $\max(\text{số hiện có}, \text{tỷ lệ} \times \text{số lớp đa số})$. Số láng giềng được chặn bởi số mẫu nhỏ nhất trừ một để tránh lỗi ở fold nhỏ. Nếu resampling thất bại, pipeline ghi cảnh báo và quay về không oversampling. Song song, trọng số lớp được tính trên nhãn train gốc. Thiết kế này ưu tiên Recall lớp thiểu số, nhưng hiệu quả riêng của oversampling và class weighting chưa được cô lập.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Cần bảng ablation so sánh: không xử lý mất cân bằng; chỉ class weight; chỉ SMOTE; chỉ ADASYN; class weight + SMOTE; class weight + ADASYN.

4.6. Optuna và cấu hình huấn luyện

Bộ kết quả trong khóa luận thuộc phiên bản final model v1: chọn siêu tham số bằng Optuna, tách validation trước resampling và huấn luyện ensemble 11 seed. Báo cáo sử dụng đúng artifact của phiên bản này, không trộn kết quả từ lần chạy lại với hàm loss hoặc resampling khác.

Bảng 4.2. Thiết lập tối ưu siêu tham số

Thành phần	Student-Mat	Student-Por	xAPI
Số trial ghi nhận	50	50	100
CV	Repeated Stratified 5-fold $\times 3$	Repeated Stratified 5-fold $\times 3$	Repeated Stratified 5-fold $\times 3$
Epoch tối đa/trial	50	50	80
Early stopping patience	15	15	25
Sampler	TPE	TPE	TPE đa biến
Pruner	MedianPruner	MedianPruner	MedianPruner
Mục tiêu	F1-Macro trung bình	F1-Macro trung bình	F1-Macro trung bình

Bảng 4.3. Siêu tham số tốt nhất được dùng trong báo cáo chính thức

Siêu tham số	Student-Mat	Student-Por	xAPI
Learning rate	0,00285449	0,00056115	0,00240941
Weight decay	3.2425e-04	7.1145e-04	1.6526e-05
Batch size	16	16	8
Resampling thực thi	ADASYN	ADASYN	SMOTENC
Sampling ratio	0,5238	0,4936	0,4331
k-neighbors	5	5	9
CNN channels	64	32	32
CNN kernel	3	3	3
BiLSTM hidden	64	32	96

Siêu tham số	Student-Mat	Student-Por	xAPI
Context hidden	32	32	256
Fusion hidden	64	128	128
Dropout	0,1382	0,3099	0,2673 / 0,3829 / 0,2553

4.7. Chỉ số đánh giá

Accuracy là tỷ lệ dự đoán đúng. $\text{Precision}_k = \text{TP}_k / (\text{TP}_k + \text{FP}_k)$, $\text{Recall}_k = \text{TP}_k / (\text{TP}_k + \text{FN}_k)$, và F1_k là trung bình điều hòa của Precision_k và Recall_k . F1-Macro là trung bình không trọng số của F1 trên ba lớp, nên mỗi lớp có đóng góp ngang nhau bất kể support. RMSE được tính trên mã lớp thứ tự 0-1-2; R^2 so sánh sai số bình phương với phương sai nhãn. Vì phân loại là nhiệm vụ chính, F1-Macro là metric quyết định; RMSE và R^2 chỉ được dùng như chỉ số phụ phản ánh độ xa thứ tự giữa nhãn dự đoán và nhãn thật.

CHƯƠNG 5. ĐÁNH GIÁ MÔ HÌNH TRÊN CƠ SỞ KHOA HỌC

5.1. Nguyên tắc đánh giá


Chương này chỉ sử dụng locked-test metric, prediction, Optuna study và evaluation JSON của final model v1. Các artifact hậu tố v27 và kết quả từ các lần chạy khác cấu hình không được dùng. Mọi kết luận vượt quá dữ liệu hiện có tiếp tục được giới hạn hoặc đánh dấu cần bổ sung thực nghiệm.

5.2. Kết quả locked test tổng hợp

Bảng 5.1. Metric locked-test cuối cùng

Dataset	Acc	Prec.	Recall	F1	R MSE	R ²
Mat	0,861	0,860	0,899	0,869	0,373	0,721
Por	0,846	0,797	0,839	0,816	0,392	0,563
xAPI	0,781	0,794	0,788	0,785	0,468	0,611

Student-Mat đạt F1-Macro 0,8690, Student-Por đạt 0,8156, còn xAPI đạt 0,7850. Student-Mat có RMSE thấp nhất (0,3731) và R² cao nhất (0,7213). xAPI có F1-Macro và R² thấp nhất, cho thấy giới hạn rõ hơn khi biểu diễn bốn chỉ báo tổng hợp như một chuỗi ngắn.



Hình 5.1. So sánh các metric phân loại trên locked test

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

5.3. CV so với locked test


Bảng 5.2. So sánh F1-Macro CV và locked test

Dataset	Optuna best CV F1	Locked-test F1	Chênh lệch	Tỷ lệ giữ lại
Student-mat	0,9035	0,8690	0,0345	96,18%
Student-por	0,8804	0,8156	0,0648	92,65%
xAPI	0,8233	0,7850	0,0382	95,35%

Cả ba locked-test score thấp hơn Optuna best CV. Chênh lệch là 0,0345 ở Student-Mat, 0,0648 ở Student-Por và 0,0382 ở xAPI. Student-Por có gap lớn nhất; Student-Mat có gap nhỏ nhất. Điểm CV tốt nhất sau tối ưu có thể mang selection bias, nên locked test mới là số liệu chính để báo cáo hiệu năng cuối.

Không bộ dữ liệu nào sụp đổ hoàn toàn trên locked test, nhưng khoảng cách 2,4-5,5 điểm phần trăm vẫn đáng lưu ý. Một phép chia locked test duy nhất không thể chứng minh không overfit. Kết luận phù hợp là mô hình giữ được phần lớn hiệu

năng CV, trong khi Student-Por cho thấy độ nhạy khái quát hóa cao nhất trong lần chạy hiện tại.



Hình 5.2. So sánh F1-Macro giữa cross-validation và locked test

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Cần *mean $\pm$ standard deviation* của 5 fold cho cấu hình tốt nhất, kết quả *repeated stratified CV* hoặc *bootstrap confidence interval* của locked-test F1 để định lượng bất định.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Cần *train/validation loss* và *F1* theo epoch của từng seed để đánh giá trực tiếp *divergence*, thời điểm *early stopping* và *overfitting* động.

5.4. Phân tích theo lớp và ma trận nhầm lẫn

Bảng 5.3. Metric theo lớp từ classification report

Dataset	Lớp	Precision	Recall	F1	Support
Student-mat	Low	0,78	0,96	0,86	26

Dataset	Lớp	Precision	Recall	F1	Support
Student-mat	Medium	0,97	0,74	0,84	38
Student-mat	High	0,83	1,00	0,91	15
Student-por	Low	0,65	0,75	0,70	20
Student-por	Medium	0,91	0,85	0,88	84
Student-por	High	0,83	0,92	0,87	26
xAPI	Low	0,77	0,92	0,84	26
xAPI	Medium	0,74	0,76	0,75	42
xAPI	High	0,86	0,68	0,76	28

Student-Mat nhận diện toàn bộ 15 mẫu High và 25/26 mẫu Low, nhưng 5 mẫu Medium bị dự đoán thành Low và 3 mẫu Medium thành High. Điều này giải thích Recall Medium 0,79 thấp hơn hai lớp biên. Student-Por có 84 mẫu Medium, chiếm 64,6% locked test; mô hình nhận đúng 70 mẫu. Recall Low 0,85 nhưng Precision Low chỉ 0,65 do 9 mẫu Medium bị hạ xuống Low. Macro-F1 vì vậy thấp hơn Accuracy khoảng 2,2 điểm phần trăm, cho thấy Accuracy được hưởng lợi từ lớp Medium đông.

xAPI cho thấy cấu trúc lỗi rõ ở lớp lân cận: 7 Medium bị dự đoán Low, 5 Medium bị dự đoán High và 8 High bị dự đoán Medium. Không có lỗi nhảy trực tiếp giữa Low và High trong locked test, tức mô hình chủ yếu nhầm giữa các mức kề nhau. Điều này phù hợp với việc RMSE trên mã lớp không quá lớn như trường hợp nhảy hai bậc, nhưng Recall Medium và High đều chỉ 0,71.

Bảng 5.4. Ma trận nhầm lẫn Student-Mat


Thật / Dự đoán	Low	Medium	High
Low	25	1	0
Medium	7	28	3
High	0	0	15

Bảng 5.5. Ma trận nhầm lẫn Student-Por

Thật / Dự đoán	Low	Medium	High
Low	15	5	0
Medium	8	71	5
High	0	2	24


Bảng 5.6. Ma trận nhầm lẫn xAPI

Thật / Dự đoán	Low	Medium	High
Low	24	2	0
Medium	7	32	3
High	0	9	19



Hình 5.3. Ma trận nhầm lẫn của ba bộ dữ liệu

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.



Hình 5.4. F1-score theo từng lớp Low, Medium và High

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

5.5. Đánh giá xử lý mất cân bằng

Student-Por có phân bố locked test lệch mạnh về lớp Medium (20/84/26). Ma trận nhầm lẫn mới cho thấy lớp High vẫn được nhận diện tốt, nhưng nhiều mẫu Medium bị chuyển sang Low hoặc High. F1-Macro thấp hơn Accuracy, vì vậy Accuracy đơn lẻ sẽ đánh giá lạc quan chất lượng trên các lớp ít mẫu.


Student-Mat và Student-Por sử dụng ADASYN theo siêu tham số được chọn; xAPI sử dụng SMOTENC do không gian siêu tham số chọn SMOTE trên dữ liệu hỗn hợp. So sánh chéo dataset không cho phép kết luận phương pháp resampling nào tốt hơn; cần ablation trong từng dataset với cùng seed và kiến trúc.

5.6. Giới hạn năng lực và biểu diễn trên xAPI

xAPI đạt CV F1 0,8233 và locked-test F1 0,7850, chênh 0,0382. Dù gap không lớn nhất, xAPI vẫn có F1 tuyệt đối thấp nhất. Cấu hình hiện tại dùng CNN 32 kênh, BiLSTM hidden 96, Context MLP 256 và Fusion 128; việc tăng chiều nhánh context chưa giải quyết được hạn chế của chuỗi bốn chỉ báo tổng hợp.

Ba nguyên nhân hợp lý được rút ra từ dữ liệu và mã nguồn. Thứ nhất, bốn chỉ báo xAPI không có timestamp nên thứ tự đưa vào CNN-BiLSTM không tương đương chuỗi thời gian thật. Thứ hai, Label Encoding vẫn tạo quan hệ thứ tự trong biểu diễn danh mục, dù SMOTENC đã ngăn nội suy thành mã phân loại không hợp lệ. Thứ ba, cỡ mẫu nhỏ làm mô hình sâu nhạy với seed và cách chia dữ liệu.

Ma trận nhầm lẫn xAPI cho thấy ranh giới Medium-High là điểm yếu chính, với 8/28 mẫu High bị hạ xuống Medium và 5/42 mẫu Medium bị nâng lên High. Khi nhận được hình thành từ mức điểm rộng, các nhóm gần biên có thể chùng lún về hành vi. Nếu không có điểm số liên tục hoặc timestamp tương tác, mô hình khó học ranh giới tinh hơn.



Hình 5.5. Permutation feature importance trên ba bộ dữ liệu

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.


[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Cần ablation xAPI: Context MLP-only; CNN-BiLSTM-only; hybrid; thay Label Encoding bằng embedding; thay SMOTE bằng SMOTENC; dùng interaction logs theo thời gian nếu có.

5.7. Diễn giải RMSE và R^2

R^2 dương trên cả ba tập cho thấy dự đoán mã lớp giảm sai số bình phương so với baseline dự đoán giá trị trung bình của nhãn mã hóa. Student-Mat có R^2 0,7720; Student-Por 0,6063; xAPI 0,5737. Tuy nhiên, R^2 và RMSE phụ thuộc giả định khoảng cách Low-Medium bằng Medium-High. Đây là quy ước ordinal hợp lý nhưng không

phải thang đo khoảng được xác nhận. Vì vậy, hai metric không thay thế F1-Macro và không nên được dùng một mình để tuyên bố chất lượng phân loại.

5.8. Những đánh giá chưa thể kết luận



Hình 5.6. Phân bố độ tin cậy của dự đoán ensemble

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Không có *confidence interval* hoặc kiểm định *paired bootstrap* để kết luận khác biệt giữa ba dataset/model có ý nghĩa thống kê.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Không có *Brier score*, *Expected Calibration Error* hoặc *reliability diagram* để đánh giá xác suất/*confidence* có được hiệu chỉnh hay không.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Không có *metric fairness* theo giới tính, trường, quốc tịch hoặc nhóm xã hội; không được tuyên bố mô hình công bằng.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Không có *external validation* trên cơ sở giáo dục khác; *robustness* hiện chỉ được chứng minh trong ba phép chia nội bộ của ba dataset công khai.

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Không có thử nghiệm người dùng hoặc *A/B test* để đánh giá *learning path* cải thiện kết quả học tập.

5.9. Kết luận khoa học của chương


Kết quả locked test hiện tại cho thấy mô hình hoạt động tốt nhất trên Student-Mat (F1-Macro 0,8690), tiếp theo là Student-Por (0,8156) và xAPI (0,7850). Student-Por có CV-test gap lớn nhất. xAPI có hiệu năng tuyệt đối thấp nhất và tiếp tục bộc lộ giới hạn biểu diễn. Các kết luận về lợi ích riêng của resampling hoặc từng nhánh kiến trúc vẫn cần ablation.

5.10. Đánh giá offline mô-đun khuyến nghị

Mô-đun MLP được đánh giá trên locked test bằng Precision@K, Recall@K và NDCG@K so với nhãn tham chiếu từ bộ tiêu chí chuyên môn. Kết quả cao cần được hiểu là độ trung thành với chính sách tham chiếu, không phải hiệu quả can thiệp. LLM-Judge không được báo cáo vì chưa có đánh giá độc lập.

Bảng 5.7. Kết quả đánh giá MLP khuyến nghị trên locked test

Dataset	F1 đa nhãn	P@3	R@3	NDCG@3	LLM-Judge
Mat	0,938	0,561	0,940	0,988	Chưa chạy
Por	0,961	0,469	0,952	0,997	Chưa chạy
xAPI	0,978	0,674	0,836	1,000	Chưa chạy



Hình 5.7. Precision@3, Recall@3 và NDCG@3 của MLP khuyến nghị

CHƯƠNG 6. THẢO LUẬN VÀ TRIỂN KHAI THỰC TIỄN


6.1. Ý nghĩa thực tiễn của dự đoán

Một hệ thống dự đoán giáo dục hữu ích phải hỗ trợ ưu tiên nguồn lực chứ không thay thế đánh giá chuyên môn. Người học dự đoán Low hoặc có risk factor ưu tiên 1 có thể được đưa vào danh sách cố vấn xem xét. Người học Medium có confidence thấp cần được xem là trường hợp không chắc chắn, không phải nhãn cố định. Người học High vẫn có thể nhận khuyến nghị nếu xuất hiện rủi ro chuyên cần hoặc suy giảm G2 so với G1.

6.2. Vận hành Learning Path

1. Mô hình tạo nhãn, xác suất và confidence cho từng người học.
2. MLP khuyến nghị đọc feature snapshot, chuẩn hóa theo train pool và trả về xác suất cho sáu yếu tố rủi ro.
3. Risk band được xác định từ lớp dự đoán và mức ưu tiên rủi ro.
4. Các hành động được sắp theo Tuần 1, Tuần 1-2, Tuần 2-4 và kiểm tra cuối tuần.
5. Cố vấn xác nhận tính phù hợp, điều chỉnh mục tiêu và ghi nhận việc thực hiện.
6. Dữ liệu theo dõi mới được đưa vào lần đánh giá sau để so sánh xu hướng.

Trong vận hành, mỗi khuyến nghị cần có trạng thái proposed, accepted, modified, completed hoặc rejected; người thực hiện; ngày bắt đầu; ngày đánh giá; và outcome. Schema hiện tại lưu learning path dưới dạng JSONB nhưng chưa có bảng sự kiện thực thi chi tiết. Đây là phần cần mở rộng để đánh giá hiệu quả can thiệp thay vì chỉ đánh giá độ trung thành với tiêu chí tham chiếu.



Hình 6.1. Phân bố risk band do Learning Path Engine tạo ra

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.


6.3. Tích hợp PostgreSQL

Bảng 6.1. Vai trò các bảng PostgreSQL

Bảng	Mục đích	Trường quan trọng
paper_runs	Quản lý phiên chạy	generated_at, status, run_payload
paper_predictions	Lưu dự đoán locked test hoặc production	true/pred label, probability, confidence, original_features, seed
paper_evaluation_metrics	Lưu metric theo dataset và protocol	accuracy, precision_macro, recall_macro, f1_macro, rmse, r2
paper_learning_recommendations	Lưu risk và learning path	risk_band, feature_snapshot, recommended_learning_path
students / student_grades	Liên kết hồ sơ và điểm nguồn	dataset_name, source_row_index, G1, G2, G3, target_class

Việc lưu original_features và probability cho phép kiểm toán sau này: có thể tái tạo đầu vào, kiểm tra drift, xem confidence và đối chiếu learning path. Giao dịch ghi dữ liệu cần bảo đảm atomicity để tránh tồn tại prediction mà thiếu metric hoặc recommendation. Trong môi trường thật, cần bổ sung model_version, preprocessing_version, feature_schema_version, consent status, retention policy và audit log.

Mô hình lưu trữ PostgreSQL



Mỗi phiên chạy liên kết dự đoán, metric và khuyến nghị để hỗ trợ kiểm toán và tái lập

Hình 6.2. Quan hệ giữa các bảng lưu trữ PostgreSQL

Nguồn: Tác giả tổng hợp từ kết quả thực nghiệm của hệ thống.

6.4. Kiến trúc triển khai đề xuất

- Batch scoring định kỳ cho Student-Mat/Por khi có điểm G1-G2 mới.
- API scoring cho LMS khi chỉ báo xAPI được cập nhật.
- Model registry lưu trọng số, tham số, code commit và metric phê duyệt.
- Dashboard cố vấn hiển thị xác suất, risk factor và lộ trình; không chỉ hiển thị nhãn.
- Monitoring theo dõi phân bố feature, tỷ lệ lớp dự đoán, calibration và metric khi có nhãn thật.
- Cơ chế human-in-the-loop bắt buộc đối với mọi quyết định có ảnh hưởng đến người học.

6.5. Rủi ro đạo đức và quản trị

Dữ liệu học tập chứa thông tin nhạy cảm về kết quả, hành vi và bối cảnh gia đình. Hệ thống cần tuân thủ nguyên tắc tối thiểu hóa dữ liệu, phân quyền theo vai trò, mã hóa khi lưu và truyền, giới hạn thời gian lưu, và ghi log truy cập. Người học cần được thông báo mục đích sử dụng dữ liệu và có cơ chế phản hồi khi dự đoán sai. Không nên dùng nhãn Low để từ chối cơ hội học tập hoặc tạo kỳ vọng tiêu cực.

Các thuộc tính nhạy cảm có thể trở thành proxy cho bất bình đẳng xã hội. Do chưa có fairness audit, mô hình chỉ nên dùng để sàng lọc hỗ trợ. Bộ tiêu chí weak supervision và thư viện mẫu hành động của mô-đun khuyến nghị cần được hội đồng chuyên môn phê duyệt trước khi triển khai.

6.6. Hạn chế của nghiên cứu

- Cỡ mẫu nhỏ làm metric nhạy với cách chia tập và seed.
- Chuỗi đầu vào quá ngắn; xAPI không có nhật ký thời gian thực trong dữ liệu hiện dùng.
- Việc nội suy các mã danh mục trong ADASYN là một giới hạn phương pháp cần được kiểm tra bằng ablation; thay đổi resampling có thể làm thay đổi đáng kể kết quả và phải được tái tối ưu riêng.
- Validation nội bộ ensemble được tách sau resampling, có nguy cơ lạc quan khi chọn epoch.
- Thiếu ablation định lượng đóng góp của CNN, BiLSTM, attention, MLP, feature engineering và xử lý mất cân bằng.
- Thiếu khoảng tin cậy, calibration, fairness, external validation và kiểm định drift.
- MLP khuyến nghị học từ nhãn weak supervision dựa trên tiêu chí chuyên môn; chưa có đánh giá người dùng, đánh giá LLM độc lập hoặc bằng chứng nhân quả về hiệu quả can thiệp.
- RMSE/ R^2 trên mã lớp chỉ có ý nghĩa phụ thuộc giả định ordinal.

CHƯƠNG 7. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1. Kết luận

Luận văn đã xây dựng một pipeline hoàn chỉnh cho dự đoán và khuyến nghị thành tích học tập dựa trên kiến trúc lai CNN-BiLSTM + Context MLP. Thiết kế hai nhánh cho phép kết hợp chuỗi điểm/chỉ báo hành vi với thông tin bối cảnh; attention pooling tạo biểu diễn chuỗi cố định; fusion dense tạo dự đoán ba lớp. Quy trình thực nghiệm tách locked test trước tối ưu, sử dụng fold-wise preprocessing trong Optuna, xử lý mất cân bằng và ensemble nhiều seed.

Trên locked test, F1-Macro đạt 0,8690 cho Student-Mat, 0,8156 cho Student-Por và 0,7850 cho xAPI. Student-Mat giữ hiệu năng tốt nhất; Student-Por có generalization gap lớn nhất; xAPI là trường hợp hạn chế nhất về hiệu năng tuyệt đối.

MLP Learning Path Engine xếp hạng sáu yếu tố rủi ro và kết hợp chúng với thư viện mẫu hành động theo giai đoạn. PostgreSQL cung cấp khả năng lưu vết. Khuyến nghị vẫn cần human-in-the-loop vì metric hiện tại chỉ đo fidelity với bộ tiêu chí tham chiếu.

7.2. Hướng phát triển

7. Bổ sung nested CV hoặc repeated holdout để định lượng selection bias và độ ổn định của locked-test score.
8. Báo cáo bootstrap confidence interval, fold standard deviation và kiểm định paired khi so sánh cấu hình.
9. So sánh Label Encoding với embedding hoặc one-hot; thực hiện ablation không resampling, class weight, ADASYN, SMOTENC và các tỷ lệ lấy mẫu khác nhau.
10. Thu thập event log có timestamp để hình thành chuỗi xAPI thực, kèm masking cho chuỗi độ dài khác nhau.
11. Thực hiện ablation MLP-only, sequence-only, hybrid, không attention, không feature engineering và các chiến lược imbalance.
12. Đánh giá calibration bằng Brier score/ECE và áp dụng temperature scaling nếu cần.

13. Thực hiện fairness audit theo nhóm với tiêu chí phù hợp và quy trình phê duyệt đạo đức.
14. Thiết kế nghiên cứu can thiệp có đối chứng hoặc stepped-wedge để đo hiệu quả learning path.
15. Bổ sung drift monitoring, model registry, versioning và quy trình rollback trong PostgreSQL/MLOps.

7.3. Tuyên bố cuối cùng

Giá trị chính của nghiên cứu không chỉ là đạt metric cao, mà là xây dựng một quy trình có thể kiểm tra, thừa nhận bất định và tách bạch rõ dự đoán với khuyến nghị. Kết quả hiện tại đủ để chứng minh tính khả thi kỹ thuật của hệ thống trên ba bộ dữ liệu công khai, nhưng chưa đủ để coi mô hình là công cụ tự động ra quyết định giáo dục. Bước tiếp theo phải ưu tiên validation nghiêm ngặt, biểu diễn dữ liệu phù hợp và đánh giá tác động thực tế.

TÀI LIỆU THAM KHẢO

- [1] Cortez, P., & Silva, A. M. G. (2008). Using Data Mining to Predict Secondary School Student Performance. UCI Machine Learning Repository, Student Performance dataset. <https://archive.ics.uci.edu/dataset/320/student+performance>
- [2] Amrieh, E. A., Hamtini, T., & Aljarah, I. (2016). Mining Educational Data to Predict Student's Academic Performance Using Ensemble Methods. *International Journal of Database Theory and Application*, 9(8), 119-136. <https://doi.org/10.14257/ijdta.2016.9.8.13>
- [3] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- [4] Schuster, M., & Paliwal, K. K. (1997). Bidirectional Recurrent Neural Networks. *IEEE Transactions on Signal Processing*, 45(11), 2673-2681. <https://doi.org/10.1109/78.650093>
- [5] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. <https://doi.org/10.1613/jair.953>
- [6] He, H., Bai, Y., Garcia, E. A., & Li, S. (2008). ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning. *IEEE International Joint Conference on Neural Networks*, 1322-1328. <https://doi.org/10.1109/IJCNN.2008.4633969>
- [7] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of KDD 2019*. <https://doi.org/10.1145/3292500.3330701>
- [8] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. *Proceedings of the IEEE*, 86(11), 2278-2324. <https://doi.org/10.1109/5.726791>
- [9] Mã nguồn dự án: `src/models.py`, `src/data_pipeline.py`, `src/train_pipeline.py`, `src/explainability.py`, `src/evaluation.py` và `scripts/run_pipeline.py`.
- [10] Kết quả thực nghiệm dự án: `reports/final/metrics/*_locked_test_metrics.json`; `reports/final/*_final_report.txt`; `reports/final/predictions/*_predictions.csv`; `logs/xapi_150_stderr.log`.

PHỤ LỤC A. NGUỒN SỐ LIỆU THỰC NGHIỆM

Bảng A.1. Truy vết nguồn dữ liệu dùng trong luận văn

Nội dung	Tập nguồn
Metric Student-Mat	reports/final/metrics/student-mat_3class_locked_test_metrics.json
Metric Student-Por	reports/final/metrics/student-por_3class_locked_test_metrics.json
Metric xAPI	reports/final/metrics/xapi_3class_locked_test_metrics.json
Optuna best CV	reports/final/metrics/*_3class_optuna_cv.json
Ma trận nhầm lẫn	reports/final/predictions/*_3class_predictions.csv
Đánh giá khuyến nghị	reports/final/recommendations/*_evaluation.json
Kiến trúc dự đoán	src/models.py
Tiền xử lý	src/data_pipeline.py
MLP khuyến nghị	src/recommendation.py
PostgreSQL	database/schema.sql

PHỤ LỤC B. CHECKLIST TÁI LẬP

- Cố định seed và lưu phiên bản thư viện/môi trường.
- Tạo locked split một lần; không dùng locked test trong Optuna hoặc chọn epoch.
- Fit feature engineering state, scaler, encoder và selector chỉ trên train tương ứng.
- Resampling chỉ trên train; ghi lại method, ratio và k-neighbors.
- Lưu toàn bộ best params, fold score, seed score và checkpoint.
- Tính metric từ prediction CSV và đối chiếu classification report.
- Ghi model version, preprocessing version và schema version khi đưa vào PostgreSQL.
- Không tuyên bố hiệu quả khuyến nghị nếu chưa có dữ liệu can thiệp.

PHỤ LỤC C. CÁC PHÂN TÍCH CẦN BỔ SUNG KHI CÓ DỮ LIỆU

[REQUIRES EMPIRICAL DATA - DO NOT HALLUCINATE] Cần bổ sung learning curves, biểu đồ calibration, khoảng tin cậy, đánh giá fairness và biểu đồ ablation khi có dữ liệu thực nghiệm tương ứng.